

Limites d'échelle des champs de type *shot-noise* associés à un processus ponctuel de Poisson homogène



Auteur
Lilian THÉBAUD

Sous la direction de
Mme BIERMÉ Hermine
M. DURIEU Olivier

Année universitaire 2025-2026 - M2 Mathématiques

Remerciements.

Je tiens à adresser mes plus sincères remerciements à Madame BIERMÉ ainsi qu'à Monsieur DURIEU pour m'avoir proposé ce sujet de mémoire passionnant.

Je leur suis profondément reconnaissant pour leur accompagnement tout au long de ce travail. Leur disponibilité, leur bienveillance et la qualité de leurs conseils m'ont été précieux. Leurs remarques, toujours pertinentes et constructives, ont nourri ma réflexion et m'ont permis d'approfondir ma compréhension du sujet. Je les remercie également d'avoir pris le temps de me rencontrer et de répondre avec attention à mes questions.

Je leur exprime toute ma gratitude ainsi que mon respect le plus sincère.

Table des matières

1	Introduction	5
2	Préliminaire : La théorie de Karamata	6
2.1	Théorème de convergence uniforme : TCU	6
2.2	Théorème de caractérisation de Karamata	7
2.3	Théorème de représentation de Karamata	7
2.4	Inverse asymptotique	12
3	Limites d'échelle des champs de type <i>shot-noise</i> associés à un processus ponctuel de Poisson homogène	14
3.1	Second moment des amplitudes fini	14
3.1.1	Démonstration en utilisant la transformée de Laplace	15
3.1.2	Démonstration en utilisant la fonction caractéristique	20
3.2	Distribution d'amplitude à variation régulière.	24
3.2.1	Démonstration en utilisant la transformée de Laplace	26
3.2.2	Démonstration en utilisant la fonction caractéristique	31
4	Différentes simulations	36
4.1	Mise en place du code	36
4.2	Simulations	36
5	Conclusion	53

1 Introduction

Les champs de type *shot-noise* constituent une classe fondamentale de modèles aléatoires intervenant dans de nombreux domaines des probabilités appliquées, tels que les télécommunications, la théorie des files d'attente ou encore la modélisation spatiale. Ils décrivent l'accumulation d'impulsions aléatoires localisées dans l'espace, chacune étant pondérée par une amplitude aléatoire et modulée par une fonction de réponse déterministe.

Dans ce mémoire, nous considérons un champ de type *shot-noise* associé à un processus ponctuel de Poisson homogène $\Phi_\lambda = \sum_{n=1}^{+\infty} \delta_{X_n}$ sur $\mathbb{R}^d$ ($d \in \mathbb{N}^*$), avec l'intensité

$$\lambda = \mathbb{E} [\Phi_\lambda([0, 1]^d)] \in (0, +\infty).$$

Le champ est défini par

$$I_\lambda(z) := \sum_{n=1}^{+\infty} Y_n \ell(z - X_n), \quad z \in \mathbb{R}^d \quad (1.0.1)$$

où $Y_n, n \in \mathbb{N}$ sont des variables aléatoires non négatives, indépendantes et identiquement distribuées (i.i.d.) appelées *amplitudes*, qui sont aussi indépendantes de Φ_λ et ℓ est une fonction non négative et bornée sur $\mathbb{R}^d$ appelé *fonction réponse*.

L'objectif principal de ce mémoire est d'étudier le comportement asymptotique de la version centrée et normalisée du champ $I_\lambda(z)$ lorsque l'intensité λ tend vers l'infini. Autrement dit, nous cherchons à comprendre les limites d'échelle de ces champs aléatoires. Selon les propriétés de la loi des amplitudes, différents régimes limites peuvent apparaître : convergence vers un champ gaussien dans le cas d'un second moment fini, ou apparition de limites non gaussiennes lorsque la distribution des amplitudes présente une variation régulière.

Pour cela notre première section sera consacrée à la théorie de Karamata, qui est la théorie de la variation régulière, développée par Karamata. Cette théorie permet de décrire précisément le comportement asymptotique des distributions à queues lourdes et joue un rôle déterminant dans l'identification des bonnes normalisations ainsi que dans l'étude des limites non gaussiennes.

Dans la deuxième section nous mettrons en évidence la convergence. Nous commencerons par établir les résultats dans le cadre où les amplitudes admettent un moment d'ordre deux. Dans ce contexte, une normalisation en $\sqrt{\lambda}$ conduit à une convergence en loi de dimension finie vers un champ gaussien centré dont la covariance s'exprime explicitement en fonction de la fonction de réponse ℓ . Cette étude constitue une étape essentielle pour aborder ensuite le cas plus délicat où les amplitudes ne seront plus de moment d'ordre 2 et seront à variation régulière. On montrera que cela conduit à une convergence en loi finie dimensionnelle vers un champ α stable.

Enfin, dans la dernière partie, nous présenterons différentes illustrations numériques des résultats que nous aurons démontrés.

Ce travail s'inscrit ainsi à l'interface entre la théorie des processus ponctuels, l'analyse asymptotique et la théorie des champs aléatoires. Il met en évidence en particulier l'influence des propriétés de la distribution des amplitudes sur les régimes limites obtenus.

2 Préliminaire : La théorie de Karamata

La théorie de Karamata a pour objet l'étude de relations asymptotiques de la forme :

$$\lim_{x \rightarrow +\infty} \frac{L(\lambda x)}{L(x)} = g(\lambda) \in (0, +\infty).$$

On pourra consulter l'ouvrage [BING] pour plus détails sur ces fonctions.

Définition 2.0.1 :

Une fonction mesurable L définie sur un voisinage de l'infini $[X, \infty)$, et satisfaisant

$$\lim_{x \rightarrow +\infty} \frac{L(\lambda x)}{L(x)} = 1, \quad \forall \lambda > 0,$$

est dite à variation lente (à l'infini).

Définition 2.0.2 :

Une fonction mesurable L définie sur un voisinage de l'infini $[X, \infty)$, et satisfaisant

$$\lim_{x \rightarrow +\infty} \frac{L(\lambda x)}{L(x)} \in \mathbb{R}_+, \quad \forall \lambda > 0,$$

est dite à variation régulière (à l'infini). En particulier, la limite doit donc être finie.

2.1 Théorème de convergence uniforme : TCU

Théorème 2.1.1 :

Si L est à variation lente. Alors,

$$\lim_{x \rightarrow +\infty} \frac{L(\lambda x)}{L(x)} = 1,$$

est uniforme sur tous les compacts de $(0, +\infty)$.

Il existe différentes preuves de ce résultat, ici, on a souhaité faire la plus simple !

Démonstration du théorème 2.1.1. On définit

$$h(x) := \log L(e^x).$$

Donc,

$$\lim_{x \rightarrow +\infty} h(x+u) - h(x) = 0, \quad \forall u \in \mathbb{R}. \quad (2.1.1)$$

Il suffit de montrer la convergence uniforme sur tous les compacts de la forme $[0, A]$, $A > 0$.

Soit $A > 0$, prenons $\varepsilon \in (0, A)$ et posons pour $x > 0$,

$$I_x := [x, x+2A], \quad E_x := \{t \in I_x : |h(t) - h(x)| \geq \varepsilon\} \quad \text{et} \quad E_x^* = \{t \in [0, 2A] : |h(x+t) - h(x)| \geq \varepsilon\}.$$

On a : E_x, E_x^* sont mesurables car L l'est. De plus,

$$\int_{\mathbb{R}} \mathbb{1}_{E_x^*}(t) dt = \int_0^{2A} \mathbb{1}_{E_x^*}(t) dt = \int_x^{x+2A} \mathbb{1}_{E_x}(y-x) dy = \int_{\mathbb{R}} \mathbb{1}_{E_x}(t) dt.$$

Donc, si on note μ la mesure de Lebesgue, on a

$$\mu(E_x) = \mu(E_x^*).$$

Comme $\lim_{x \rightarrow +\infty} h(x+u) - h(x) = 0$, la fonction $t \mapsto \mathbb{1}_{E_x^*}(t)$ tend presque sûrement vers 0 quand x tend vers $+\infty$. En utilisant le théorème de convergence dominée, on a :

$$\lim_{x \rightarrow +\infty} \int_{\mathbb{R}} \mathbb{1}_{E_x^*}(t) dt = 0.$$

Donc, il existe un x_0 tels que pour tout $x \geq x_0$,

$$\mu(E_x^*) < \frac{1}{2}\varepsilon.$$

Soit maintenant $c \in [0, A]$, on a :

$$I_{x+c} \cap I_x = [x+c, x+2A]$$

est de longueur $2A - c \geq A$. De plus, pour tout $x \geq x_0$,

$$\mu\left(E_x \bigcup E_{x+c}\right) < \mu(E_x) + \mu(E_{x+c}) = \mu(E_x^*) + \mu(E_{x+c}^*) < \varepsilon < A.$$

Donc, pour $c \in [0, A]$, $x \geq x_0$,

$$(I_x \cap I_{x+c}) \setminus (E_x \cup E_{x+c})$$

a une mesure positive, donc est non vide. Soit t un point de cet ensemble, alors on a

$$|h(t) - h(x)| \leq \varepsilon \quad \text{et} \quad |h(t) - h(x+c)| \leq \varepsilon$$

Par conséquent, pour tout $c \in [0, A]$, $x \geq x_0$,

$$|h(x+c) - h(x)| \leq 2\varepsilon.$$

On a montré la convergence uniforme sur les compacts $[0, A]$, on a donc le résultat voulu. $\square$

2.2 Théorème de caractérisation de Karamata

Théorème 2.2.1 :

Toute fonction à variation régulière est de la forme

$$f(x) = x^\beta L(x)$$

où β est un nombre réel et L est une fonction à variation lente.

Cela implique que la fonction $g(a) = \lim_{x \rightarrow +\infty} \frac{L(ax)}{L(x)}$ dans la définition est nécessairement de la forme :

$$g(a) = a^\rho$$

pour un nombre réel ρ ; ce nombre est appelé l'indice de variation régulière, et la classe des fonctions de cet indice est notée R_ρ .

Démonstration du théorème 2.2.1. Admis (on pourra aller voir une démonstration dans le livre [BING]). $\square$

2.3 Théorème de représentation de Karamata

Nous abordons maintenant la question de savoir quelles fonctions L peuvent exactement satisfaire la condition de variation lente (définie précédemment par $L(\lambda x)/L(x) \rightarrow 1$ quand $x \rightarrow \infty$).

Théorème 2.3.1 :

La fonction L est à variation lente si et seulement si elle peut s'écrire sous la forme :

$$L(x) = c(x) \exp\left(\int_a^x \frac{\varepsilon(u)}{u} du\right) \quad (x \geq a) \quad (2.3.1)$$

pour un certain $a > 0$, où :

- ★ $c(\cdot)$ est une fonction mesurable positive telle que $c(x) \rightarrow c \in (0, \infty)$ quand $x \rightarrow \infty$;
- ★ $\varepsilon(\cdot)$ est une fonction mesurable telle que $\varepsilon(x) \rightarrow 0$ quand $x \rightarrow \infty$.

Nous pouvons réécrire 2.3.1 sous la forme :

$$L(x) = \exp\left(\eta(x) + \int_a^x \frac{\varepsilon(u)}{u} du\right) \quad (2.3.2)$$

où $\eta(x)$ et $\varepsilon(x)$ sont des fonctions mesurables bornées, avec $\eta(x) \rightarrow d \in \mathbb{R}$ et $\varepsilon(x) \rightarrow 0$ quand $x \rightarrow \infty$.

Comme dans la démonstration du théorème 2.1.1, nous noterons

$$h(x) := \log L(e^x).$$

Il s'agit donc de prouver que h satisfait 2.1.1 si et seulement si h peut s'écrire :

$$h(x) = d(x) + \int_b^x e(v) dv \quad (x \geq b) \quad (2.3.3)$$

en posant

$$b = \log a, \quad d(x) = \eta(e^x), \quad e(x) = \varepsilon(e^x),$$

avec

$$d(x) \rightarrow d \in \mathbb{R} \quad \text{et} \quad e(x) \rightarrow 0 \quad \text{quand} \quad x \rightarrow \infty.$$

Lemme 2.3.2 :

Si L est une fonction positive, mesurable, définie sur un intervalle $[A, \infty)$, et que :

$$\frac{L(\lambda x)}{L(x)} \rightarrow 1 \quad (x \rightarrow \infty) \quad \forall \lambda > 0,$$

alors L est bornée sur tout intervalle fini « suffisamment loin vers la droite » (c'est-à-dire pour des valeurs de x assez grandes). Si l'on pose $h(x) := \log L(e^x)$, alors h est également bornée sur les intervalles finis suffisamment loin vers la droite.

Démonstration du lemme 2.3.2. D'après le théorème de Convergence Uniforme (TCU) (théorème 2.1.1), nous pouvons trouver un x_0 suffisamment grand tel que :

$$|h(x+u) - h(x)| < 1 \quad \text{pour } x \geq x_0 \text{ et } u \in [0, 1],$$

d'où l'on déduit : $|h(x)| \leq 1 + |h(x_0)|$ sur l'intervalle $[x_0, x_0 + 1]$. Par une récurrence immédiate, on obtient $|h(x)| \leq n + |h(x_0)|$ sur $[x_0, x_0 + n]$ pour $n = 1, 2, \dots$. On en tire la conclusion pour h , de laquelle découle la conclusion pour $L(x) = \exp h(\log x)$. $\square$

Démonstration du théorème 2.3.1. Supposons que $L(x)$ s'écrit sous la forme de Karamata :

$$L(x) = c(x) \exp \left(\int_a^x \frac{\varepsilon(u)}{u} du \right).$$

On a donc :

$$\frac{L(\lambda x)}{L(x)} = \frac{c(\lambda x)}{c(x)} \cdot \frac{\exp \left(\int_a^{\lambda x} \frac{\varepsilon(u)}{u} du \right)}{\exp \left(\int_a^x \frac{\varepsilon(u)}{u} du \right)}.$$

En simplifiant, on obtient :

$$\frac{L(\lambda x)}{L(x)} = \underbrace{\frac{c(\lambda x)}{c(x)}}_{\text{Partie 1}} \cdot \underbrace{\exp \left(\int_x^{\lambda x} \frac{\varepsilon(u)}{u} du \right)}_{\text{Partie 2}}.$$

★ **Contrôle de la partie 1.** On sait que $c(x) \rightarrow c \in (0, \infty)$. Pour tout $\delta > 0$, il existe un seuil x_1 tel que pour tout $x \geq x_1$, on a

$$c(x) \in [c - \delta, c + \delta].$$

Alors, si λ est dans un intervalle compact $[a, b]$, λx tend aussi vers l'infini.

Ainsi

$$\frac{c(\lambda x)}{c(x)} \rightarrow \frac{c}{c} = 1.$$

Ce terme est donc encadré par $(1 \pm \delta)$ pour x assez grand.

★ **Contrôle de la partie 2.** On utilise que $\varepsilon(u) \rightarrow 0$.

Pour un $\delta > 0$ donné, choisissons x_2 tel que pour tout $u \geq x_2$, on ait $|\varepsilon(u)| \leq \delta$.

Si $x \geq x_2$ et $\lambda \in [a, b]$, alors pour tout u compris entre x et λx , on a $|\varepsilon(u)| \leq \delta$.

L'intégrale devient :

$$\left| \int_x^{\lambda x} \frac{\varepsilon(u)}{u} du \right| \leq \int_x^{\lambda x} \frac{|\varepsilon(u)|}{u} du \leq \delta \left| \int_x^{\lambda x} \frac{du}{u} \right| = \delta |\log \lambda|.$$

Puisque $\lambda \in [a, b]$, la valeur $|\log \lambda|$ est au maximum égale à $\max(|\log a|, |\log b|)$.

Ainsi, l'exponentielle est encadrée par :

$$\exp(-\delta M) \leq \exp \left(\int_x^{\lambda x} \frac{\varepsilon(u)}{u} du \right) \leq \exp(\delta M)$$

où $M = \max(|\log a|, |\log b|)$.

Conclusion : En combinant les deux parties, on voit que pour x assez grand :

$$\frac{L(\lambda x)}{L(x)} \in [(1 - \delta)e^{-\delta M}, (1 + \delta)e^{\delta M}].$$

Comme δ peut être choisi arbitrairement petit, la limite quand $x \rightarrow \infty$ est exactement 1.

Passons au sens réciproque : D'après le lemme 2.3.2, h est intégrable sur les intervalles finis suffisamment loin vers la droite, car elle y est bornée et mesurable. Pour un x_0 suffisamment grand, nous pouvons donc écrire :

$$h(x) = \int_x^{x+1} (h(x) - h(t)) dt + \int_{x_0}^x (h(t+1) - h(t)) dt + \int_{x_0}^{x_0+1} h(t) dt \quad (x \geq x_0).$$

Le dernier terme de droite est une constante, notons la c .

Si l'on pose

$$e(x) := h(x+1) - h(x),$$

alors $e(x) \rightarrow 0$ quand, $x \rightarrow \infty$ d'après la définition de la variation lente.

Le premier terme de droite

$$\int_0^1 (h(x) - h(x+u)) du,$$

tend vers zéro quand, $x \rightarrow \infty$ d'après le théorème de Convergence Uniforme (TCU) (théorème 2.1.1). Ainsi, 2.3.3 en découle avec :

$$d(x) = c + \int_0^1 (h(x) - h(x+u)) du.$$

□

Corollaire 2.3.3 :

Si f est une fonction à variation régulière d'indice ρ . Alors, pour $x \geq a$ (où $a > 0$), la fonction peut être représentée par :

$$f(x) = c(x)x^\rho \exp \left(\int_a^x \frac{\varepsilon(u)}{u} du \right) \quad (2.3.4)$$

où, lorsque $x \rightarrow \infty$:

- ★ $c(x) \rightarrow c \in (0, \infty)$;
- ★ $\varepsilon(x) \rightarrow 0$.

Démonstration du corollaire 2.3.3. On applique le théorème précédent et le théorème de caractérisation de Karamata. □

Du théorème 2.3.1, on en déduit aussi le théorème de Potter pour les fonctions à variation lente :

Théorème 2.3.4 : Inégalité de Potter pour les fonctions à variation lente.

Soit L une fonction lentement variable à l'infini. Alors, pour tout $A > 1$ et tout $\delta > 0$, il existe $X = X(A, \delta)$ tel que, pour tous $x, y \geq X$,

$$\frac{L(y)}{L(x)} \leq A \max \left\{ \left(\frac{y}{x} \right)^\delta, \left(\frac{y}{x} \right)^{-\delta} \right\}.$$

Démonstration du théorème 2.3.4. Puisque L est lentement variable à l'infini, le théorème de représentation de Karamata (théorème 2.3.1) assure l'existence d'une fonction mesurable $\varepsilon(\cdot)$ telle que

$$\lim_{x \rightarrow +\infty} \varepsilon(x) = 0,$$

et d'une fonction $c(\cdot)$ convergeant vers une constante strictement positive $c > 0$, pour lesquelles

$$L(x) = c(x) \exp \left(\int_{x_0}^x \frac{\varepsilon(u)}{u} du \right), \quad x \geq x_0,$$

pour un certains $x_0 > 0$.

Soient $x, y \geq x_0$. On obtient alors

$$\frac{L(y)}{L(x)} = \frac{c(y)}{c(x)} \exp \left(\int_x^y \frac{\varepsilon(u)}{u} du \right).$$

★ **Contrôle du facteur $c(y)/c(x)$.**

Soit $\eta > 0$. Posons

$$A = \frac{c + \eta}{c - \eta} > 1.$$

Comme $c(x) \rightarrow c > 0$ lorsque $x \rightarrow \infty$, il existe $x_1 > 0$ tel que, pour tout $x \geq x_1$,

$$c - \eta \leq c(x) \leq c + \eta.$$

En particulier, pour tous $x, y \geq x_1$,

$$\frac{c(x)}{c(y)} < \frac{c + \eta}{c - \eta} < A.$$

★ **Contrôle de l'exponentielle.** Puisque $\varepsilon(u) \rightarrow 0$, il existe x_2 tel que pour tout $u \geq x_2$,

$$|\varepsilon(u)| \leq \delta.$$

Ainsi, pour $x, y \geq x_2$,

$$\left| \int_x^y \frac{\varepsilon(u)}{u} du \right| \leq \delta \left| \int_x^y \frac{du}{u} \right| = \delta |\log(y/x)|.$$

Par conséquent,

$$\exp \left(\int_x^y \frac{\varepsilon(u)}{u} du \right) \leq \max \left\{ \left(\frac{y}{x} \right)^\delta, \left(\frac{y}{x} \right)^{-\delta} \right\}.$$

En posant $X = \max(x_1, x_2)$, on obtient pour tous $x, y \geq X$,

$$\frac{L(y)}{L(x)} \leq A \max \left\{ \left(\frac{y}{x} \right)^\delta, \left(\frac{y}{x} \right)^{-\delta} \right\}.$$

La preuve est ainsi achevée. □

Théorème 2.3.5 :

Soit L une fonction à variation lente. Alors

$$L(x) \sim L_1(x),$$

où $L_1 \in C^\infty([a, \infty))$, et $h_1(x) := \log L_1(e^x)$ possède, pour $n = 1, 2, \dots$, la propriété suivante :

$$\lim_{x \rightarrow +\infty} h_1^{(n)}(x) = 0.$$

Ainsi, L_1 est à variation lente avec la représentation

$$L_1(x) = \exp \left(c_1 + \int_a^x \varepsilon_1(u) \frac{du}{u} \right),$$

où $c_1 = h_1(\log a)$ et $\varepsilon_1(x) = h_1'(\log x)$.

Démonstration du théorème 2.3.5. Soit $p(\cdot)$ une densité de probabilité C^∞ sur $\mathbb{R}$, de support $[0, 1]$. Par exemple, on peut poser

$$q(x) := \begin{cases} \exp \left(-\frac{1}{x} - \frac{1}{1-x} \right) & \text{pour } 0 < x < 1 \\ 0 & \text{pour } x \leq 0 \text{ et } x \geq 1 \end{cases}.$$

On a

$$q^{(n)}(x) = \begin{cases} \frac{P_n(x)}{x^{2n}(1-x)^{2n}} \cdot \exp \left(-\frac{1}{x} - \frac{1}{1-x} \right) & \text{pour } 0 < x < 1 \\ 0 & \text{pour } x \leq 0 \text{ et } x \geq 1 \end{cases}$$

où $P_n(x)$ est un polynôme. On a par les croissances comparées :

$$\lim_{x \rightarrow 0^+} q^{(n)}(x) = 0 \quad \text{et} \quad \lim_{x \rightarrow 1^-} q^{(n)}(x) = 0.$$

Donc, q est bien une fonction C^∞ à support dans $[0, 1]$.

Pour obtenir une probabilité, on définit

$$p(x) := \frac{q(x)}{\int_0^1 q(t) dt}, \text{ pour tout } x.$$

En posant $h(x) := \log L(e^x)$, définissons :

$$\varepsilon(x) := (h(n+1) - h(n))p(x-n) \quad (n \leq x < n+1)$$

pour n suffisamment grand pour que $[n, \infty)$ soit inclus dans le domaine de définition de h , disons $n \geq n_0$.

Alors $\varepsilon(\cdot)$ est de classe C^∞ sur chaque intervalle $(n, n+1)$, ainsi qu'aux extrémités car p et toutes ses dérivées s'annulent en 0 et 1.

Pour $k = 0, 1, \dots$, notons

$$M_k := \sup_x |p^{(k)}(x)|, \text{ où } p^{(0)} = p.$$

Tous les M_k sont finis (support compact et C^∞) et on a :

$$|\varepsilon^{(k)}(x)| = |h([x] + 1) - h([x])| \cdot |p^{(k)}(x - [x])| \leq |h([x] + 1) - h([x])| M_k.$$

Or, comme L est à variation lente, on a :

$$\lim_{x \rightarrow +\infty} h(x + 1) - h(x) = 0.$$

Donc

$$\lim_{x \rightarrow +\infty} |\varepsilon^{(k)}(x)| = 0.$$

Posons

$$h_1(x) := h(n_0) + \int_{n_0}^x \varepsilon(t) dt.$$

Par ce qui précède en utilisant le théorème fondamental de l'Analyse : $h_1 \in C^\infty$ et que toutes ses dérivées sont $o(1)$ quand $x \rightarrow \infty$.

Enfin, pour $x \geq n_0$:

$$\begin{aligned} h(x) - h_1(x) &= (h(x) - h(B)) - \int_{n_0}^x \varepsilon(t) dt \\ &= (h(x) - h(B)) - \int_{n_0}^{[x]} \varepsilon(t) dt - \int_{[x]}^x \varepsilon(t) dt. \end{aligned}$$

Or

$$\begin{aligned} \int_{n_0}^{[x]} \varepsilon(t) dt &= \sum_{k=n_0}^{[x]-1} \int_k^{k+1} (h(k+1) - h(k)) p(t-k) dt \\ &= \sum_{k=n_0}^{[x]-1} (h(k+1) - h(k)) \int_k^{k+1} p(t-k) dt \\ &= \sum_{k=n_0}^{[x]-1} (h(k+1) - h(k)) \int_0^1 p(t) dt \\ &= \sum_{k=n_0}^{[x]-1} (h(k+1) - h(k)) \\ &= \int_{n_0}^{[x]} \varepsilon(t) dt = h([x]) - h(n_0). \end{aligned}$$

Donc,

$$\begin{aligned} h(x) - h_1(x) &= h(x) - h([x]) - \int_{[x]}^x \varepsilon(t) dt \\ &= \underbrace{h(x) - h([x])}_A - \underbrace{(h([x] + 1) - h([x])) \int_0^{x-[x]} p(t) dt}_B. \end{aligned}$$

★ **Terme A :** Puisque $0 \leq x - [x] < 1$, on pose $\delta = x - [x]$. D'après le théorème de convergence uniforme, on obtient :

$$\lim_{x \rightarrow +\infty} h(x) - h([x]) = 0.$$

★ **Terme B :** Le facteur $\{h([x] + 1) - h([x])\}$ tend vers 0 (c'est le cas particulier du théorème de convergence uniforme où $\delta = 1$). L'intégrale $\int_0^{x-[x]} p(t) dt$ est toujours comprise entre 0 et 1 (car p est une densité de probabilité de support $[0, 1]$). Donc,

$$\lim_{x \rightarrow +\infty} (h([x] + 1) - h([x])) \int_0^{x-[x]} p(t) dt = 0.$$

Par conséquent

$$\lim_{x \rightarrow +\infty} h(x) - h_1(x) = 0.$$

Ainsi,

$$L(x) \sim L_1(x) := \exp h_1(\log x).$$

□

2.4 Inverse asymptotique

Théorème 2.4.1 :

Si $f \in R_\alpha$ (variation régulière d'indice α) avec $\alpha > 0$, alors il existe une fonction $g \in R_{1/\alpha}$ telle que :

$$f(g(x)) \sim g(f(x)) \sim x \quad (x \rightarrow \infty).$$

Ici, g (appelée « inverse asymptotique » de f) est déterminée de manière unique à une équivalence asymptotique près.

Démonstration du théorème 2.4.1. D'après 2.3.4,

$$f(x) \sim f_1(x) := x^\alpha L_1(x)$$

où L_1 est définie comme dans le théorème 2.3.5

Définissons

$$h(x) := \log f_1(e^x).$$

Alors,

$$h(x) = \log(e^{\alpha x} L_1(e^x)) = \alpha x + \log L_1(e^x) = \alpha x + h_1(x).$$

Donc,

$$h'(x) = \alpha + h_1'(x).$$

En utilisant le théorème 2.3.5, on obtient :

$$\lim_{x \rightarrow +\infty} h'(x) = \alpha > 0.$$

Il existe donc x_0 tel que h soit strictement croissante sur $[x_0, \infty)$ (on a bien : $\lim_{x \rightarrow +\infty} h(x) = +\infty$), et admet une fonction réciproque h^{-1} définie sur $[h(x_0), \infty)$.

On en déduit donc comme $h^{-1}(y) \rightarrow +\infty$ quand $y \rightarrow +\infty$:

$$\lim_{y \rightarrow +\infty} (h^{-1})'(y) = \lim_{y \rightarrow +\infty} \frac{1}{h'(h^{-1}(y))} = \frac{1}{\alpha}.$$

On définit alors

$$g(x) := \exp(h^{-1}(\log x)), \quad x \geq f_1(e^{x_0}).$$

Remarquons qu'on a :

$$\lim_{x \rightarrow +\infty} g(x) = +\infty. \quad (2.4.1)$$

Par construction, pour x suffisamment grand, on a

$$f_1(g(x)) = f_1(e^{h^{-1}(\log x)}) = \exp(h(h^{-1}(\log x))) = x \quad \text{et} \quad g(f_1(x)) = \exp(h^{-1}(h(\log x))) = \exp(\log(x)) = x.$$

Montrons que $g \in R_{1/\alpha}$. Soit x suffisamment grand et $\lambda \in \mathbb{R}_+$, on a

$$\log \frac{g(\lambda x)}{g(x)} = \log g(\lambda x) - \log g(x) = h^{-1}(\log(\lambda x)) - h^{-1}(\log x).$$

Appliquons le théorème des accroissements finis à la fonction h^{-1} sur l'intervalle $[\log x, \log x + \log \lambda]$.

Il existe ξ_x compris entre $\log x$ et $\log x + \log \lambda$ tel que

$$h^{-1}(\log x + \log \lambda) - h^{-1}(\log x) = (h^{-1})'(\xi_x) \log \lambda.$$

Donc, en passant à la limite quand x tend vers $+\infty$ (on a $\xi_x \rightarrow +\infty$) on obtient :

$$\lim_{x \rightarrow +\infty} \log \frac{g(\lambda x)}{g(x)} = \frac{1}{\alpha} \log \lambda.$$

On en déduit : $g \in R_{1/\alpha}$.

Puisque $f(x) \sim f_1(x)$ et $g(x) \rightarrow \infty$,

$$f(g(x)) \sim f_1(g(x)) = x.$$

On écrit

$$f(x) = f_1(x) t_x \quad \text{avec} \quad t_x := \frac{f(x)}{f_1(x)} \longrightarrow 1.$$

Or

$$g(y) = y^{1/\alpha} L_2(y),$$

où L_2 est lentement variable.

Donc

$$\frac{g(f(x))}{g(f_1(x))} = \left(\frac{f(x)}{f_1(x)} \right)^{1/\alpha} \frac{L_2(f(x))}{L_2(f_1(x))} = t_x^{1/\alpha} \frac{L_2(t_x f_1(x))}{L_2(f_1(x))}.$$

Or, il existe $A > 1$ tel que $t_x \in (0, A]$ donc par le théorème de convergence uniforme (théorème 2.1.1), on obtient :

$$\lim_{x \rightarrow +\infty} \frac{L_2(t_x f_1(x))}{L_2(f_1(x))} = \lim_{x \rightarrow +\infty} t_x^{1/\alpha} = 1.$$

Par conséquent,

$$\lim_{x \rightarrow +\infty} \frac{g(f(x))}{g(f_1(x))} = 1,$$

c'est-à-dire

$$g(f(x)) \sim g(f_1(x)) = x.$$

Montrons l'unicité. Soit g_0 une autre fonction qui vérifie :

$$\lim_{x \rightarrow +\infty} g_0(x) = +\infty \quad \text{et} \quad f(g_0(x)) \sim x.$$

Puisque $g \in R_{1/\alpha}$ alors $g(x) = x^{1/\alpha} L(x)$ avec L une fonction à variation lente. Donc

$$\frac{g(f(g_0(x)))}{g(x)} = \left(\frac{f(g_0(x))}{x} \right)^{1/\alpha} \frac{L(f(g_0(x)))}{L(x)} = \left(\frac{f(g_0(x))}{x} \right)^{1/\alpha} \frac{L(t_x x)}{L(x)}.$$

En utilisant le théorème de convergence uniforme encore une fois et $f(g_0(x)) \sim x$ on obtient :

$$\lim_{x \rightarrow +\infty} \frac{g(f(g_0(x)))}{g(x)} = 1$$

c'est-à-dire $g(f(g_0(x))) \sim g(x)$. Comme

$$\lim_{x \rightarrow +\infty} g_0(x) = +\infty \quad \text{et} \quad g(f(x)) \sim x.$$

on obtient :

$$g_0 \sim g.$$

Par conséquent, g est unique asymptotiquement. □

3 Limites d'échelle des champs de type *shot-noise* associés à un processus ponctuel de Poisson homogène

Pour rappel, Φ_λ est un processus ponctuel de Poisson homogène.

De plus, tout au long de ce mémoire, nous supposons que la fonction de répartition F_Y des amplitudes $Y_n, n \in \mathbb{N}$, possède une moyenne finie

$$p = \int_0^\infty t d\mathbb{P}_Y(t) < \infty,$$

et que la fonction de réponse ℓ est bornée et satisfait

$$\int_{\mathbb{R}^d} \ell(x) dx < \infty.$$

Avec cette condition, le champ de type *shot-noise* I_λ est également stationnaire sur $\mathbb{R}^d$ en utilisant la forme 3.0.1. En effet, remarquons d'abord grâce à 1.0.1 qu'on a :

$$I_\lambda(z) := \int_{\mathbb{R}^d \times \mathbb{R}_+} y \ell(z - x) d\phi(x, y) \quad (3.0.1)$$

où $\phi = \sum_{n=0}^{+\infty} \delta_{(X_n, Y_n)}$ est un processus stationnaire en la première variable car (Y_n) sont indépendantes de Φ_λ .

Ainsi,

$$I_\lambda(z + t) = \int_{\mathbb{R}^d \times \mathbb{R}_+} y \ell(z + t - x) d\phi(x, y) = \int_{\mathbb{R}^d \times \mathbb{R}_+} y \ell(z - s) d\phi(t + s, y).$$

Puisque ϕ est stationnaire, on $\phi(t + s, y) \stackrel{\mathcal{L}}{=} \phi(s, y)$. Ainsi,

$$I_\lambda(z + t) \stackrel{\mathcal{L}}{=} I_\lambda(z).$$

Par conséquent, I_λ bien stationnaire.

De plus, par indépendance des (Y_n) avec (X_n) et par Fubini positif, on a :

$$\mathbb{E}[I_\lambda(z)] = \mathbb{E}\left[\sum_{n=1}^{+\infty} Y_n \ell(z - X_n)\right] = \sum_{n=1}^{+\infty} \mathbb{E}[Y_n \ell(z - X_n)] = \sum_{n=1}^{+\infty} \mathbb{E}[Y_n] \mathbb{E}[\ell(z - X_n)] = \mathbb{E}[Y_1] \mathbb{E}\left[\sum_{n=1}^{+\infty} \ell(z - X_n)\right].$$

Or, par la formule de Campbell

$$\mathbb{E}\left[\sum_{n=1}^{+\infty} \ell(z - X_n)\right] = \mathbb{E}\left[\int_{\mathbb{R}^d} \ell(z - s) d\Phi_\lambda(s)\right] = \int_{\mathbb{R}^d} \ell(z - x) dM_{\Phi_\lambda}(x) = \int_{\mathbb{R}^d} \ell(x) dM_{\Phi_\lambda}(x) = \lambda \int_{\mathbb{R}^d} \ell(x) dx.$$

Ainsi,

$$\mathbb{E}[I_\lambda(z)] = \lambda p \int_{\mathbb{R}^d} \ell(x) dx < +\infty. \quad (3.0.2)$$

Remarque 3.0.1 :

On a alors pour tout $z \in \mathbb{R}^d$, $I_\lambda(z)$ est finie presque sûrement.

La version centrée et normalisée de I_λ est alors donnée par :

$$\tilde{I}_\lambda(z) = \frac{I_\lambda(z) - \mathbb{E}[I_\lambda(z)]}{g(\lambda)}, \quad z \in \mathbb{R}^d \quad (3.0.3)$$

où la fonction g est choisie de manière appropriée, et nous étudions sa limite lorsque $\lambda \rightarrow \infty$ au sens de la convergence des distributions de dimension finie.

3.1 Second moment des amplitudes fini

Dans cette sous-partie, nous supposons que la variable aléatoire Y_1 admet un second moment fini. Nous avons donc le résultat suivant :

Proposition 3.1.1 :

Soit $\Phi_\lambda = \sum_{n=1}^{\infty} \delta_{X_n}$ un processus ponctuel de Poisson homogène d'intensité $\lambda \in (0, \infty)$. Supposons que $\mathbb{E}[Y_1^2] < \infty$ et posons $g(\lambda) = \lambda^{1/2}$ dans (3.0.3). Alors, lorsque $\lambda \rightarrow \infty$, $\{\tilde{I}_\lambda(z)\}_{z \in \mathbb{R}^d}$ converge en loi de dimension finie vers un champ aléatoire gaussien $\{N(z)\}_{z \in \mathbb{R}^d}$ centré dont la fonction de covariance est :

$$\text{Cov}[N(z_1), N(z_2)] = \mathbb{E}[Y_1^2] \int_{\mathbb{R}^d} \ell(z_1 - x) \ell(z_2 - x) dx, \quad z_1, z_2 \in \mathbb{R}^d. \quad (3.1.1)$$

Remarque 3.1.2 :

Notez que la covariance dans (3.1.1) est finie puisque ℓ est bornée et intégrable par rapport à la mesure de Lebesgue sur $\mathbb{R}^d$. Soient b_ℓ et c_ℓ des constantes positives telles que $\ell(x) \in [0, b_\ell]$ pour tout $x \in \mathbb{R}^d$ et $\int_{\mathbb{R}^d} \ell(x) dx = c_\ell$. Alors, nous avons clairement :

$$\int_{\mathbb{R}^d} \ell(z_1 - x) \ell(z_2 - x) dx \leq b_\ell c_\ell < \infty. \quad (3.1.2)$$

Nous allons en donner deux preuves différentes, l'une en utilisant la transformée de Laplace et l'autre en utilisant la fonction caractéristique. Commençons par la première !

3.1.1 Démonstration en utilisant la transformée de Laplace

Avant de passer à la démonstration, nous allons énoncer et démontrer plusieurs lemmes qui nous seront utiles !

On pourra pour cela consulter les ouvrages [BACC] et [LAST] pour les lemmes et [ABUR] pour la proposition version Laplace.

Lemme 3.1.3 :

Soit X une variable aléatoire suivant une loi de Poisson de paramètre $\lambda > 0$, notée $X \sim \mathcal{P}(\lambda)$. La transformée de Laplace de X , définie pour tout $s \geq 0$ par $\mathcal{L}_X(s) = \mathbb{E}[e^{-sX}]$, est égale à :

$$\mathcal{L}_X(s) = \exp(\lambda(e^{-s} - 1)).$$

Démonstration du lemme 3.1.3 . Par définition de l'espérance pour une variable aléatoire discrète, nous avons :

$$\mathcal{L}_X(s) = \mathbb{E}[e^{-sX}] = \sum_{k=0}^{\infty} e^{-sk} \mathbb{P}(X = k).$$

En remplaçant $\mathbb{P}(X = k)$ par l'expression de la loi de Poisson :

$$\mathcal{L}_X(s) = \sum_{k=0}^{\infty} e^{-sk} \frac{e^{-\lambda} \lambda^k}{k!}.$$

On peut sortir le terme $e^{-\lambda}$ de la somme car il ne dépend pas de l'indice k :

$$\mathcal{L}_X(s) = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(e^{-s} \lambda)^k}{k!}.$$

Nous reconnaissons ici le développement en série entière de la fonction exponentielle, qui est défini par $e^u = \sum_{k=0}^{\infty} \frac{u^k}{k!}$ pour tout $u \in \mathbb{R}$. En posant $u = \lambda e^{-s}$, nous obtenons :

$$\mathcal{L}_X(s) = e^{-\lambda} e^{\lambda e^{-s}}.$$

En utilisant les propriétés de l'exponentielle ($e^a \cdot e^b = e^{a+b}$), nous pouvons regrouper les termes :

$$\mathcal{L}_X(s) = \exp(-\lambda + \lambda e^{-s}).$$

Ce qui se factorise finalement par :

$$\mathcal{L}_X(s) = \exp(\lambda(e^{-s} - 1)).$$

□

Lemme 3.1.4 :

La transformée de Laplace de Φ_λ est donnée par

$$\mathcal{L}_{\Phi_\lambda}(f) = \mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f \, d\Phi_\lambda \right) \right] = \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-f(x)}) \lambda dx \right),$$

pour toute fonction mesurable $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}_+$.

Démonstration du lemme 3.1.4. Prenons d'abord comme fonction $f = \alpha \mathbb{1}_A$ où $A \in \mathcal{B}(\mathbb{R}^d)$ et $\alpha \in \mathbb{R}_+$. On a donc

$$\mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f \, d\Phi_\lambda \right) \right] = \mathbb{E} [\exp(-\alpha \Phi_\lambda(A))] = \mathcal{L}_{\Phi_\lambda(A)}(\alpha).$$

Or $\Phi_\lambda(A) \sim \mathcal{P}(\lambda|A|)$ donc en appliquant le lemme 3.1.3 on obtient :

$$\mathcal{L}_{\Phi_\lambda(A)}(\alpha) = \exp(\lambda|A|(e^{-\alpha} - 1)).$$

Donc,

$$\mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f \, d\Phi_\lambda \right) \right] = \exp(-\lambda|A|(1 - e^{-\alpha})) = \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-f(x)}) \lambda dx \right).$$

La dernière égalité est vraie puisque les B_i sont disjoints et donc

$$\sum_{i=1}^n (1 - e^{\alpha_i \mathbb{1}_{B_i}(x)}) = 1 - e^{-f(x)} \text{ pour tout } x.$$

Maintenant prenons f étagée positive, donc il existe $\alpha_1, \dots, \alpha_n \geq 0$ et $B_1, \dots, B_n \in \mathcal{B}(\mathbb{R}^d)$ disjoints tels que

$$f = \sum_{i=1}^n \alpha_i \mathbb{1}_{B_i}.$$

On a donc

$$\mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f \, d\Phi_\lambda \right) \right] = \mathbb{E} \left[\exp \left(- \sum_{i=1}^n \alpha_i \Phi_\lambda(B_i) \right) \right].$$

En utilisant l'indépendance des $(\Phi_\lambda(B_i))$ car les B_i sont disjoints, on obtient :

$$\mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f \, d\Phi_\lambda \right) \right] = \prod_{i=1}^n \mathbb{E} [e^{-\alpha_i \Phi_\lambda(B_i)}].$$

Or,

$$\mathbb{E} [e^{-\alpha_i \Phi_\lambda(B_i)}] = \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-\alpha_i \mathbb{1}_{B_i}(x)}) \lambda dx \right).$$

Donc,

$$\mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f \, d\Phi_\lambda \right) \right] = \prod_{i=1}^n \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-\alpha_i \mathbb{1}_{B_i}(x)}) \lambda dx \right) = \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-f(x)}) \lambda dx \right).$$

Pour finir, on prend f mesurable positive. Alors, il existe une suite (f_n) de fonctions étagées positives qui converge en croissance vers f . On a donc par ce qui précède que pour tout $n \in \mathbb{N}$,

$$\mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f_n \, d\Phi_\lambda \right) \right] = \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-f_n(x)}) \lambda dx \right).$$

Regardons ce qui se passe à la limite de chaque côté de l'égalité :

★ **À gauche de l'égalité :** Soit $\omega \in \Omega$, en appliquant le théorème de convergence monotone sur l'espace $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d), \Phi_\lambda(\omega))$, on obtient :

$$\lim_{n \rightarrow +\infty} \int_{\mathbb{R}^d} f_n \, d\Phi_\lambda(\omega) = \int_{\mathbb{R}^d} f \, d\Phi_\lambda(\omega) \text{ en croissance.}$$

Ainsi, on a

$$\lim_{n \rightarrow +\infty} \int_{\mathbb{R}^d} f_n \, d\Phi_\lambda = \int_{\mathbb{R}^d} f \, d\Phi_\lambda \text{ p.s..}$$

Par conséquent,

$$\lim_{n \rightarrow +\infty} \exp \left(- \int_{\mathbb{R}^d} f_n d\Phi_\lambda \right) = \exp \left(- \int_{\mathbb{R}^d} f d\Phi_\lambda \right) \text{ p.s.}$$

Comme ces termes sont bornés par 1, le théorème de convergence dominée permet de nous donner

$$\lim_{n \rightarrow +\infty} \mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f_n d\Phi_\lambda \right) \right] = \mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f d\Phi_\lambda \right) \right].$$

★ **À droite de l'égalité :** De la même manière, la fonction $(1 - e^{-f_n(x)})$ est positive et croît vers $(1 - e^{-f(x)})$. Par le théorème de convergence monotone sur l'intégrale de Lebesgue par rapport à la mesure λdx :

$$\lim_{n \rightarrow \infty} \int_{\mathbb{R}^d} (1 - e^{-f_n(x)}) \lambda dx = \int_{\mathbb{R}^d} (1 - e^{-f(x)}) \lambda dx.$$

Donc,

$$\lim_{n \rightarrow \infty} \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-f_n(x)}) \lambda dx \right) = \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-f(x)}) \lambda dx \right).$$

Par conséquent,

$$\mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f d\Phi_\lambda \right) \right] = \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-f(x)}) \lambda dx \right).$$

□

Lemme 3.1.5 :

En gardant les mêmes notations, on a :

$$\mathbb{E} \left[\prod_{i=1}^{+\infty} u(X_i) \right] = \exp \left(- \int_{\mathbb{R}^d} (1 - u(x)) \lambda dx \right)$$

pour toute fonction $u : \mathbb{R}^d \rightarrow]0, 1]$.

Démonstration du lemme 3.1.5 . Soit $u : \mathbb{R}^d \rightarrow]0, 1]$. Alors,

$$\mathbb{E} \left[\prod_{i=1}^{+\infty} u(X_i) \right] = \mathbb{E} \left[\exp \left(\sum_{i=1}^{+\infty} \ln(u(X_i)) \right) \right].$$

Posons

$$f(x) := -\ln(u(x)) \geq 0 \text{ car } u \in]0, 1].$$

Alors,

$$\begin{aligned} \mathbb{E} \left[\prod_{i=1}^{+\infty} u(X_i) \right] &= \mathbb{E} \left[\exp \left(- \sum_{i=1}^{+\infty} f(X_i) \right) \right] \\ &= \mathbb{E} \left[\exp \left(- \int_{\mathbb{R}^d} f(x) d\Phi_\lambda(x) \right) \right]. \end{aligned}$$

En appliquant le lemme 3.1.4, on obtient :

$$\mathbb{E} \left[\prod_{i=1}^{+\infty} u(X_i) \right] = \exp \left(- \int_{\mathbb{R}^d} (1 - e^{-f(x)}) \lambda dx \right) = \exp \left(- \int_{\mathbb{R}^d} (1 - u(x)) \lambda dx \right).$$

□

Passons à la démonstration de la proposition :

Démonstration de la proposition 3.1.1. Considérons la transformée de Laplace de dimension finie de $\tilde{I}_\lambda(z)$ dans (3.0.3) en $z = (z_1, \dots, z_m) \in \mathbb{R}^{d \times m}$ pour $m \in \mathbb{N}$; c'est-à-dire que pour $s^\top = (s_1, \dots, s_m) \in [0, \infty)^m$:

$$\mathcal{L}_{\tilde{I}_\lambda}(s, z) := \mathbb{E} \left[\exp \left(- \sum_{j=1}^m s_j \tilde{I}_\lambda(z_j) \right) \right].$$

Donc, en utilisant la définition de $\tilde{I}_\lambda$ on obtient :

$$\mathcal{L}_{\tilde{I}_\lambda}(s, z) = \mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{j=1}^m s_j I_\lambda(z_j) \right) \right] \exp \left(\frac{1}{g(\lambda)} \sum_{j=1}^m s_j \mathbb{E}[I_\lambda(z_j)] \right). \quad (3.1.3)$$

En appliquant (3.0.2), nous réduisons l'intérieur de la seconde exponentielle de la dernière expression ci-dessus à :

$$\frac{1}{g(\lambda)} \sum_{j=1}^m s_j \mathbb{E}[I_\lambda(z_j)] = \frac{\lambda p}{g(\lambda)} \int_{\mathbb{R}^d} \xi_{s,z}(x) dx, \quad (3.1.4)$$

où $\xi_{s,z}(x) := \sum_{j=1}^m s_j \ell(z_j - x)$.

D'autre part, en utilisant le théorème de Fubini positif, on a :

$$\begin{aligned} \mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{j=1}^m s_j I_\lambda(z_j) \right) \right] &= \mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{j=1}^m s_j \sum_{n=1}^{+\infty} Y_n \ell(z_j - X_n) \right) \right] \\ &= \mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{n=1}^{+\infty} Y_n \sum_{j=1}^m s_j \ell(z_j - X_n) \right) \right] \text{ par Fubini positif} \\ \mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{j=1}^m s_j I_\lambda(z_j) \right) \right] &= \mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{n=1}^{+\infty} Y_n \xi_{s,z}(X_n) \right) \right]. \end{aligned}$$

Posons pour $L > 0$:

$$f_L(x) = \xi_{s,z}(x) \mathbb{1}_{[-L, L]^d}(x).$$

On a :

$$\lim_{L \rightarrow +\infty} f_L(x) = \xi_{s,z}(x) \text{ en croissance.}$$

Ainsi, par convergence monotone :

$$\sum_{n=1}^{+\infty} Y_n \xi_{s,z}(X_n) = \lim_{L \rightarrow +\infty} \sum_{n=1}^{+\infty} Y_n \xi_{s,z}(X_n) \mathbb{1}_{[-L, L]^d}(X_n) \text{ p.s. en croissance.}$$

Cela revient à compter le nombre de points du processus de Poisson qui sont tombés dans l'intervalle $[-L, L]^d$.

Ainsi, si on note N_L la variable aléatoire de loi de Poisson de paramètre $\lambda|[-L, L]^d|$ et on note $(X_1, \dots, X_{N_L})$ les points, on obtient :

$$\sum_{n=1}^{+\infty} Y_n \xi_{s,z}(X_n) \mathbb{1}_{[-L, L]^d}(X_n) = \sum_{k=1}^{N_L} Y_k \xi_{s,z}(X_k) \text{ p.s.}$$

Par conséquent, en utilisant la convergence dominée (la domination est donnée par 1), on obtient :

$$\mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{n=1}^{+\infty} Y_n \sum_{j=1}^m s_j \ell(z_j - X_n) \right) \right] = \lim_{L \rightarrow +\infty} \mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{k=1}^{N_L} Y_k \xi_{s,z}(X_k) \right) \right].$$

Or,

$$\begin{aligned} \mathbb{E} \left[\exp \left(-\frac{1}{g(\lambda)} \sum_{k=1}^{N_L} Y_k \xi_{s,z}(X_k) \right) \right] &= \mathbb{E} \left[\prod_{k=1}^{N_L} \exp \left(-\frac{Y_k \xi_{s,z}(X_k)}{g(\lambda)} \right) \right] \\ &= \mathbb{E} \left[\mathbb{E} \left[\prod_{k=1}^{N_L} \exp \left(-\frac{Y_k \xi_{s,z}(X_k)}{g(\lambda)} \right) \middle| N_L \right] \right]. \end{aligned}$$

Soit $l \in \mathbb{N}$,

$$\mathbb{E} \left[\prod_{k=1}^{N_L} \exp \left(-\frac{Y_k \xi_{s,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] = \mathbb{E} \left[\prod_{k=1}^l \exp \left(-\frac{Y_k \xi_{s,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right]$$

$$= \int_{\mathbb{R}^{2l}} \prod_{m=1}^l \exp\left(-\frac{y_m \xi_{s,z}(x_m)}{g(\lambda)}\right) d\mathbb{P}_{(Y_1, \dots, Y_l, X_1, \dots, X_l)}^{N_L=l}(y_1, \dots, y_l, x_1, \dots, x_l).$$

En utilisant que $(Y_n)_n$ sont indépendantes entre elles, de même loi et indépendantes des $(X_n)_n$ et de N_L , on obtient :

$$\begin{aligned} \mathbb{E} \left[\prod_{k=1}^{N_L} \exp\left(-\frac{Y_k \xi_{s,z}(X_k)}{g(\lambda)}\right) \middle| N_L = l \right] &= \int_{\mathbb{R}^l} \left(\int_{\mathbb{R}^l} \prod_{k=1}^l \exp\left(-\frac{y_k \xi_{s,z}(x_k)}{g(\lambda)}\right) d\mathbb{P}_{Y_1}(y_1) \dots d\mathbb{P}_{Y_l}(y_l) \right) d\mathbb{P}_{(X_1, \dots, X_l)}^{N_L=l}(x_1, \dots, x_l) \\ &= \int_{\mathbb{R}^l} \prod_{k=1}^l \mathbb{E} \left[\exp\left(-\frac{Y_1 \xi_{s,z}(x_k)}{g(\lambda)}\right) \right] d\mathbb{P}_{(X_1, \dots, X_l)}^{N_L=l}(x_1, \dots, x_l) \\ &= \int_{\mathbb{R}^l} \prod_{k=1}^l \mathcal{L}_Y \left(\frac{\xi_{s,z}(x_k)}{g(\lambda)} \right) d\mathbb{P}_{(X_1, \dots, X_l)}^{N_L=l}(x_1, \dots, x_l) \\ \mathbb{E} \left[\prod_{k=1}^{N_L} \exp\left(-\frac{Y_k \xi_{s,z}(X_k)}{g(\lambda)}\right) \middle| N_L = l \right] &= \mathbb{E} \left[\prod_{k=1}^{N_L} \mathcal{L}_Y \left(\frac{\xi_{s,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right], \end{aligned}$$

où $\mathcal{L}_Y(u) = \mathbb{E}[e^{-uY_1}]$ désigne la transformée de Laplace de Y_1 . Par conséquent,

$$\begin{aligned} \mathbb{E} \left[\exp\left(-\frac{1}{g(\lambda)} \sum_{k=1}^{N_L} Y_k \xi_{s,z}(X_k)\right) \right] &= \mathbb{E} \left[\mathbb{E} \left[\prod_{k=1}^{N_L} \mathcal{L}_Y \left(\frac{\xi_{s,z}(X_k)}{g(\lambda)} \right) \middle| N_L \right] \right] \\ &= \mathbb{E} \left[\prod_{k=1}^{N_L} \mathcal{L}_Y \left(\frac{\xi_{s,z}(X_k)}{g(\lambda)} \right) \right]. \end{aligned}$$

Puis par convergence dominée (la domination est donnée par 1), on obtient :

$$\mathbb{E} \left[\exp\left(-\frac{1}{g(\lambda)} \sum_{j=1}^m s_j I_\lambda(z_j)\right) \right] = \mathbb{E} \left[\prod_{n=1}^{\infty} \mathcal{L}_Y \left(\frac{\xi_{s,z}(X_n)}{g(\lambda)} \right) \right].$$

En appliquant le lemme 3.1.5 avec $u = \mathcal{L}_Y \circ \frac{\xi_{s,z}}{g(\lambda)}$ on obtient :

$$\mathbb{E} \left[\exp\left(-\frac{1}{g(\lambda)} \sum_{j=1}^m s_j I_\lambda(z_j)\right) \right] = \exp\left(-\lambda \int_{\mathbb{R}^d} \left[1 - \mathcal{L}_Y \left(\frac{\xi_{s,z}(x)}{g(\lambda)} \right)\right] dx\right). \quad (3.1.5)$$

Par conséquent, en injectant (3.1.4) et (3.1.5) dans (3.1.3)

$$\begin{aligned} \mathcal{L}_{\tilde{I}_\lambda}(s, z) &= \exp\left(-\lambda \int_{\mathbb{R}^d} \left[1 - \mathcal{L}_Y \left(\frac{\xi_{s,z}(x)}{g(\lambda)} \right)\right] dx\right) \exp\left(\frac{\lambda p}{g(\lambda)} \int_{\mathbb{R}^d} \xi_{s,z}(x) dx\right) \\ &= \exp\left(\lambda \int_{\mathbb{R}^d} \frac{p}{g(\lambda)} \xi_{s,z}(x) - 1 + \mathcal{L}_Y \left(\frac{\xi_{s,z}(x)}{g(\lambda)} \right) dx\right). \end{aligned}$$

Or,

$$\mathcal{L}_Y(s) = \int_0^\infty e^{-st} d\mathbb{P}_Y(t), \quad 1 = \int_0^{+\infty} 1 d\mathbb{P}_Y(t) \quad \text{et} \quad p = \int_0^\infty t d\mathbb{P}_Y(t).$$

Donc, en posant

$$\psi(u) = e^{-u} - 1 + u.$$

On obtient :

$$\mathcal{L}_{\tilde{I}_\lambda}(s, z) = \exp\left(\lambda \int_{\mathbb{R}^d} \int_0^\infty \psi\left(\frac{\xi_{s,z}(x)}{g(\lambda)} t\right) d\mathbb{P}_Y(t) dx\right). \quad (3.1.6)$$

Prenons maintenant

$$g(\lambda) = \lambda^{1/2}.$$

Alors, puisque $\psi(u) = u^2/2 + o(u^2)$ quand u tend vers 0 et puisque $\psi(u) \in [0, u^2/2]$ on a :

★ Soit $x \in \mathbb{R}^d$ et $t \in \mathbb{R}_+$

$$\lim_{\lambda \rightarrow +\infty} \lambda \psi \left(\frac{\xi_{s,z}(x)t}{\lambda^{1/2}} \right) = \frac{(\xi_{s,z}(x))^2 t^2}{2}.$$

★ On a :

$$0 \leq \lambda \psi \left(\frac{\xi_{s,z}(x)t}{\lambda^{1/2}} \right) \leq \frac{[\xi_{s,z}(x)t]^2}{2}$$

Or,

$$\int_{\mathbb{R}^d} \int_0^{+\infty} \frac{[\xi_{s,z}(x)t]^2}{2} d\mathbb{P}_Y(t) dx = \mathbb{E}[Y_1^2] \int_{\mathbb{R}^d} \frac{\xi_{s,z}(x)^2}{2} dx \leq \mathbb{E}[Y_1^2] \frac{Mb_\ell}{2} \int_{\mathbb{R}^d} \xi_{s,z}(x) dx \leq \mathbb{E}[Y_1^2] \frac{Mb_\ell}{2} Mc_\ell < +\infty,$$

où $M = m \times \max_{1 \leq i \leq m} s_i$.

Donc, on peut passer la limite sous le signe intégrale en utilisant le théorème de convergence dominée :

$$\lim_{\lambda \rightarrow \infty} \mathcal{L}_{\tilde{I}_\lambda}(s, z) = \exp \left(\frac{\mathbb{E}[Y_1^2]}{2} \int_{\mathbb{R}^d} [\xi_{s,z}(x)]^2 dx \right).$$

Posons la matrice $K(z) = (L(z_i, z_j))_{1 \leq i, j \leq m}$ où

$$L(z_i, z_j) = \int_{\mathbb{R}^d} \ell(z_i - x) \ell(z_j - x) dx.$$

On a donc

$$\begin{aligned} \int_{\mathbb{R}^d} [\xi_{s,z}(x)]^2 dx &= \int_{\mathbb{R}^d} \left[\sum_{j=1}^m s_j \ell(z_j - x) \right]^2 dx \\ &= \int_{\mathbb{R}^d} \sum_{j,i=1}^m s_i \ell(z_i - x) s_j \ell(z_j - x) dx \\ &= \sum_{j,i=1}^m s_i s_j \int_{\mathbb{R}^d} \ell(z_i - x) \ell(z_j - x) dx \text{ par Fubini positif} \\ \int_{\mathbb{R}^d} [\xi_{s,z}(x)]^2 dx &= s^\top K(z) s. \end{aligned}$$

Donc,

$$\lim_{\lambda \rightarrow \infty} \mathcal{L}_{\tilde{I}_\lambda}(s, z) = \exp \left(\frac{\mathbb{E}[Y_1^2]}{2} s^\top K(z) s \right).$$

Par conséquent, l'assertion de la proposition est vérifiée. □

3.1.2 Démonstration en utilisant la fonction caractéristique

Dans les grandes lignes, la démonstration de la proposition 3.1.1 avec la fonction caractéristique reste dans les mêmes idées qu'avec la transformée de Laplace, cependant nous ne pouvons pas appliquer le lemme 3.1.5.

Démonstration de la proposition 3.1.1. Considérons la fonction caractéristique de dimension finie de $\tilde{I}_\lambda(z)$ dans (3.0.3) en $z = (z_1, \dots, z_m) \in \mathbb{R}^{d \times m}$ pour $m \in \mathbb{N}$; c'est-à-dire que pour $u^\top = (u_1, \dots, u_m) \in \mathbb{R}^m$:

$$\phi_{\tilde{I}_\lambda}(u, z) := \mathbb{E} \left[\exp \left(i \sum_{j=1}^m u_j \tilde{I}_\lambda(z_j) \right) \right].$$

Donc, en utilisant la définition de $\tilde{I}_\lambda$ on obtient :

$$\phi_{\tilde{I}_\lambda}(u, z) = \mathbb{E} \left[\exp \left(i \frac{1}{g(\lambda)} \sum_{j=1}^m u_j I_\lambda(z_j) \right) \right] \exp \left(- \frac{i}{g(\lambda)} \sum_{j=1}^m u_j \mathbb{E}[I_\lambda(z_j)] \right). \quad (3.1.7)$$

En appliquant (3.0.2), nous réduisons l'intérieur de la seconde exponentielle de la dernière expression ci-dessus à :

$$-\frac{i}{g(\lambda)} \sum_{j=1}^m u_j \mathbb{E}[I_\lambda(z_j)] = -\frac{i\lambda p}{g(\lambda)} \int_{\mathbb{R}^d} \xi_{u,z}(x) dx, \quad (3.1.8)$$

où $\xi_{u,z}(x) := \sum_{j=1}^m u_j \ell(z_j - x)$.

D'autre part, d'après la remarque 3.0.1 comme pour tout $j \in \{1, \dots, m\}$, $I_\lambda(z_j)$ est finie presque sûrement, on a qu'il existe un ensemble négligeable M tel que

$$\forall \omega \in \Omega \setminus M, \quad \forall j \in \{1, \dots, m\}, \quad I_\lambda(z_j)(\omega) < +\infty.$$

Ainsi, soit $\omega \in \Omega \setminus M$,

$$\sum_{j=1}^m \sum_{n=1}^{+\infty} |u_j| Y_n(\omega) \ell(z_j - X_n(\omega)) = \sum_{j=1}^m |u_j| I_\lambda(z_j)(\omega) < +\infty.$$

On a donc

$$\sum_{j=1}^m u_j \sum_{n=1}^{+\infty} Y_n(\omega) \ell(z_j - X_n(\omega)) = \sum_{n=1}^{+\infty} Y_n(\omega) \sum_{j=1}^m u_j \ell(z_j - X_n(\omega)).$$

Par conséquent,

$$\sum_{j=1}^m u_j \sum_{n=1}^{+\infty} Y_n \ell(z_j - X_n) = \sum_{n=1}^{+\infty} Y_n \sum_{j=1}^m u_j \ell(z_j - X_n) \text{ p.s.}$$

Ainsi, on a :

$$\begin{aligned} \mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{j=1}^m u_j I_\lambda(z_j) \right) \right] &= \mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{j=1}^m u_j \sum_{n=1}^{+\infty} Y_n \ell(z_j - X_n) \right) \right] \\ &= \mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{n=1}^{+\infty} Y_n \sum_{j=1}^m u_j \ell(z_j - X_n) \right) \right] \\ \mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{j=1}^m u_j I_\lambda(z_j) \right) \right] &= \mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{n=1}^{+\infty} Y_n \xi_{u,z}(X_n) \right) \right]. \end{aligned}$$

Posons pour $L > 0$:

$$f_L(x) = \xi_{u,z}(x) \mathbb{1}_{[-L,L]^d}(x).$$

On a :

$$\lim_{L \rightarrow +\infty} f_L(x) = \xi_{u,z}(x).$$

En gardant les mêmes notations que précédemment, soit $\omega \in \Omega \setminus M$, on a

$$\sum_{n=1}^{+\infty} |Y_n(\omega) f_L(X_n(\omega))| \leq \sum_{j=1}^m |u_j| I_\lambda(z_j)(\omega) < +\infty.$$

et pour tout $n \in \mathbb{N}^*$,

$$\lim_{L \rightarrow +\infty} Y_n(\omega) f_L(X_n(\omega)) = Y_n(\omega) \xi_{u,z}(X_n(\omega)).$$

Ainsi, par convergence dominée :

$$\sum_{n=1}^{+\infty} Y_n(\omega) \xi_{u,z}(X_n(\omega)) = \lim_{L \rightarrow +\infty} \sum_{n=1}^{+\infty} Y_n(\omega) \xi_{u,z}(X_n(\omega)) \mathbb{1}_{[-L,L]^d}(X_n(\omega)).$$

Donc,

$$\sum_{n=1}^{+\infty} Y_n \xi_{u,z}(X_n) = \lim_{L \rightarrow +\infty} \sum_{n=1}^{+\infty} Y_n \xi_{u,z}(X_n) \mathbb{1}_{[-L,L]^d}(X_n) \text{ p.s.}$$

Cela revient à compter le nombre de points du processus de Poisson qui sont tombés dans l'intervalle $[-L, L]^d$. Ainsi, si on note N_L la variable aléatoire de loi de Poisson de paramètre $\lambda|[-L, L]^d|$ et on note $(X_1, \dots, X_{N_L})$ les points, on obtient :

$$\sum_{n=1}^{+\infty} Y_n \xi_{u,z}(X_n) \mathbb{1}_{[-L, L]^d}(X_n) = \sum_{k=1}^{N_L} Y_k \xi_{u,z}(X_k) \text{ p.s.}$$

Par conséquent, en utilisant la convergence dominée (la domination est donnée par 1), on obtient :

$$\mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{n=1}^{+\infty} Y_n \sum_{j=1}^m u_j \ell(z_j - X_n) \right) \right] = \lim_{L \rightarrow +\infty} \mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{k=1}^{N_L} Y_k \xi_{u,z}(X_k) \right) \right].$$

Or,

$$\begin{aligned} \mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{k=1}^{N_L} Y_k \xi_{u,z}(X_k) \right) \right] &= \mathbb{E} \left[\prod_{k=1}^{N_L} \exp \left(i \frac{Y_k \xi_{u,z}(X_k)}{g(\lambda)} \right) \right] \\ &= \mathbb{E} \left[\mathbb{E} \left[\prod_{k=1}^{N_L} \exp \left(i \frac{Y_k \xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L \right] \right]. \end{aligned}$$

Soit $l \in \mathbb{N}$,

$$\begin{aligned} \mathbb{E} \left[\prod_{k=1}^{N_L} \exp \left(i \frac{Y_k \xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] &= \mathbb{E} \left[\prod_{k=1}^l \exp \left(i \frac{Y_k \xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] \\ &= \int_{\mathbb{R}^{2l}} \prod_{m=1}^l \exp \left(i \frac{y_m \xi_{u,z}(x_m)}{g(\lambda)} \right) d\mathbb{P}_{(Y_1, \dots, Y_l, X_1, \dots, X_l)}^{N_L=l}(y_1, \dots, y_l, x_1, \dots, x_l). \end{aligned}$$

En utilisant que $(Y_n)_n$ sont indépendantes entre elles, de même loi et indépendantes des $(X_n)_n$ et de N_L , on obtient :

$$\begin{aligned} \mathbb{E} \left[\prod_{k=1}^{N_L} \exp \left(i \frac{Y_k \xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] &= \int_{\mathbb{R}^l} \left(\int_{\mathbb{R}^l} \prod_{k=1}^l \exp \left(i \frac{y_k \xi_{u,z}(x_k)}{g(\lambda)} \right) d\mathbb{P}_{Y_1}(y_1) \dots d\mathbb{P}_{Y_l}(y_l) \right) d\mathbb{P}_{(X_1, \dots, X_l)}^{N_L=l}(x_1, \dots, x_l) \\ &= \int_{\mathbb{R}^l} \prod_{k=1}^l \mathbb{E} \left[\exp \left(i \frac{Y_1 \xi_{u,z}(x_k)}{g(\lambda)} \right) \right] d\mathbb{P}_{(X_1, \dots, X_l)}^{N_L=l}(x_1, \dots, x_l) \\ &= \int_{\mathbb{R}^l} \prod_{k=1}^l \phi_Y \left(\frac{\xi_{u,z}(x_k)}{g(\lambda)} \right) d\mathbb{P}_{(X_1, \dots, X_l)}^{N_L=l}(x_1, \dots, x_l) \\ \mathbb{E} \left[\prod_{k=1}^{N_L} \exp \left(i \frac{Y_k \xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] &= \mathbb{E} \left[\prod_{k=1}^{N_L} \phi_Y \left(\frac{\xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right], \end{aligned}$$

où $\phi_Y(t) = \mathbb{E}[e^{itY_1}]$ désigne la fonction caractéristique de Y_1 .

De plus, sachant que $N_L = l$, on a les variables aléatoires $X_1, \dots, X_{N_L}$ indépendantes et de même loi uniforme sur $[-L, L]^d$. Donc,

$$\begin{aligned} \mathbb{E} \left[\prod_{k=1}^{N_L} \phi_Y \left(\frac{\xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] &= \mathbb{E} \left[\prod_{k=1}^l \phi_Y \left(\frac{\xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] \\ &= \prod_{k=1}^l \mathbb{E} \left[\phi_Y \left(\frac{\xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] \text{ par indépendance} \\ &= \left(\mathbb{E} \left[\phi_Y \left(\frac{\xi_{u,z}(X_1)}{g(\lambda)} \right) \middle| N_L = l \right] \right)^l \text{ même loi} \\ \mathbb{E} \left[\prod_{k=1}^{N_L} \phi_Y \left(\frac{\xi_{u,z}(X_k)}{g(\lambda)} \right) \middle| N_L = l \right] &= \left(\frac{1}{|[-L, L]^d|} \int_{[-L, L]^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) dx \right)^l. \end{aligned}$$

Ainsi,

$$\begin{aligned} \mathbb{E} \left[\prod_{k=1}^{N_L} \phi_Y \left(\frac{\xi_{u,z}(X_k)}{g(\lambda)} \right) \right] &= \sum_{l=0}^{+\infty} \left(\frac{1}{|[-L, L]^d|} \int_{[-L, L]^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) dx \right)^l \mathbb{P}(N_L = l) \\ &= \sum_{l=0}^{+\infty} \left(\frac{1}{|[-L, L]^d|} \int_{[-L, L]^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) dx \right)^l e^{-\lambda|[-L, L]^d|} \frac{(\lambda|[-L, L]^d|)^l}{l!} \\ &= \exp \left(-\lambda|[-L, L]^d| + \lambda|[-L, L]^d| \frac{1}{|[-L, L]^d|} \int_{[-L, L]^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) dx \right) \\ \mathbb{E} \left[\prod_{k=1}^{N_L} \phi_Y \left(\frac{\xi_{u,z}(X_k)}{g(\lambda)} \right) \right] &= \exp \left(\lambda \int_{[-L, L]^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1 dx \right). \end{aligned}$$

Posons la fonction

$$h_L(x) := \mathbb{1}_{[-L, L]^d}(x) \left(\phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1 \right).$$

On a :

★ Pour tout $x \in \mathbb{R}^d$,

$$\lim_{L \rightarrow +\infty} h_L(x) = \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1.$$

★ Soit $L > 0$ et $x \in \mathbb{R}^d$,

$$|h_L(x)| = \left| \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1 \right| = \left| \mathbb{E} \left[\exp \left(\frac{iY \xi_{u,z}(x)}{g(\lambda)} \right) - 1 \right] \right| \leq \mathbb{E} \left[\left| \exp \left(\frac{iY \xi_{u,z}(x)}{g(\lambda)} \right) - 1 \right| \right] \leq \frac{\xi_{u,z}(x)}{g(\lambda)} \mathbb{E}[Y].$$

La fonction à droite est intégrable sur $\mathbb{R}^d$ et ne dépend pas de L .

On peut donc appliquer la convergence dominée, on en déduit

$$\lim_{L \rightarrow +\infty} \exp \left(\lambda \int_{[-L, L]^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1 dx \right) = \exp \left(\lambda \int_{\mathbb{R}^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1 dx \right).$$

Par conséquent,

$$\mathbb{E} \left[\exp \left(\frac{i}{g(\lambda)} \sum_{n=1}^{+\infty} Y_n \sum_{j=1}^m u_j \ell(z_j - X_n) \right) \right] = \exp \left(\lambda \int_{\mathbb{R}^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1 dx \right). \quad (3.1.9)$$

Par conséquent, en injectant (3.1.8) et (3.1.9) dans (3.1.7)

$$\begin{aligned} \phi_{\tilde{I}_\lambda}(u, z) &= \exp \left(\lambda \int_{\mathbb{R}^d} \left[\phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1 \right] dx \right) \exp \left(-\frac{i\lambda p}{g(\lambda)} \int_{\mathbb{R}^d} \xi_{u,z}(x) dx \right) \\ &= \exp \left(\lambda \int_{\mathbb{R}^d} \phi_Y \left(\frac{\xi_{u,z}(x)}{g(\lambda)} \right) - 1 - \frac{ip}{g(\lambda)} \xi_{u,z}(x) dx \right). \end{aligned}$$

Or,

$$\phi_Y(s) = \int_0^\infty e^{ist} d\mathbb{P}_Y(t), \quad 1 = \int_0^{+\infty} 1 d\mathbb{P}_Y(t) \quad \text{et} \quad p = \int_0^\infty t d\mathbb{P}_Y(t).$$

Donc, en posant

$$\psi(s) = e^{is} - 1 - is.$$

On obtient :

$$\phi_{\tilde{I}_\lambda}(u, z) = \exp \left(\lambda \int_{\mathbb{R}^d} \int_0^\infty \psi \left(\frac{\xi_{u,z}(x)}{g(\lambda)} t \right) d\mathbb{P}_Y(t) dx \right). \quad (3.1.10)$$

Prenons maintenant

$$g(\lambda) = \lambda^{1/2}.$$

Alors, puisque $\psi(s) = -s^2/2 + o(s^2)$ quand s tend vers 0 et puisqu'il existe une constante $C > 0$ tel que $|\psi(s)| \in [0, Cs^2]$ on a :

★ Soit $x \in \mathbb{R}^d$ et $t \in \mathbb{R}_+$

$$\lim_{\lambda \rightarrow +\infty} \lambda \psi \left(\frac{\xi_{u,z}(x)t}{\lambda^{1/2}} \right) = -\frac{(\xi_{u,z}(x))^2 t^2}{2}.$$

★ On a :

$$\left| \lambda \psi \left(\frac{\xi_{u,z}(x)t}{\lambda^{1/2}} \right) \right| \leq C[\xi_{u,z}(x)t]^2.$$

Or,

$$\int_{\mathbb{R}^d} \int_0^{+\infty} [\xi_{u,z}(x)t]^2 d\mathbb{P}_Y(t) dx = \mathbb{E}[Y_1^2] \int_{\mathbb{R}^d} \xi_{u,z}(x)^2 dx \leq \mathbb{E}[Y_1^2] M b_\ell \int_{\mathbb{R}^d} |\xi_{u,z}(x)| dx \leq \mathbb{E}[Y_1^2] M b_\ell M c_\ell < +\infty,$$

où $M = m \times \max_{1 \leq i \leq m} |u_i|$.

Donc, on peut passer la limite sous le signe intégrale en utilisant le théorème de convergence dominée :

$$\lim_{\lambda \rightarrow \infty} \phi_{\tilde{I}_\lambda}(u, z) = \exp \left(-\frac{\mathbb{E}[Y_1^2]}{2} \int_{\mathbb{R}^d} [\xi_{u,z}(x)]^2 dx \right).$$

Posons la matrice $K(z) = (L(z_i, z_j))_{1 \leq i, j \leq m}$ où

$$L(z_i, z_j) = \int_{\mathbb{R}^d} \ell(z_i - x) \ell(z_j - x) dx.$$

On a donc

$$\begin{aligned} \int_{\mathbb{R}^d} [\xi_{u,z}(x)]^2 dx &= \int_{\mathbb{R}^d} \left[\sum_{j=1}^m u_j \ell(z_j - x) \right]^2 dx \\ &= \int_{\mathbb{R}^d} \sum_{j,i=1}^m u_i \ell(z_i - x) u_j \ell(z_j - x) dx \\ &= \sum_{j,i=1}^m u_i u_j \int_{\mathbb{R}^d} \ell(z_i - x) \ell(z_j - x) dx \text{ par Fubini} \\ \int_{\mathbb{R}^d} [\xi_{u,z}(x)]^2 dx &= u^\top K(z) u. \end{aligned}$$

Donc,

$$\lim_{\lambda \rightarrow \infty} \phi_{\tilde{I}_\lambda}(u, z) = \exp \left(-\frac{\mathbb{E}[Y_1^2]}{2} u^\top K(z) u \right).$$

On reconnaît la fonction caractéristique d'un vecteur gaussien centré et de matrice de covariance donnée par 3.1.1. Par conséquent, l'assertion de la proposition est vérifiée. □

3.2 Distribution d'amplitude à variation régulière.

Dans cette sous-partie, on ne suppose plus que la variable aléatoire Y_1 admet un moment d'ordre deux, mais que la queue de distribution

$$\overline{F}_Y(t) = 1 - F_Y(t)$$

est à variation régulière d'indice $-\alpha$ pour $\alpha \in (1, 2)$; c'est-à-dire en utilisant le théorème de caractérisation de Karamata (théorème 2.2.1) que :

$$\lim_{t \rightarrow \infty} \frac{F_P(ct)}{F_P(t)} = c^{-\alpha}$$

pour tout $c > 0$.

Avant de démontrer vers quel processus $\tilde{I}_\lambda$ tend en loi nous énonçons et démontrons les résultats suivants, qui nous seront utiles !

Proposition 3.2.1 :

Sous ces conditions, on a :

- ★ $\mathbb{E}[Y_1] < +\infty$;
- ★ $\mathbb{E}[Y_1^2] = +\infty$.

De plus, on a :

$$\lim_{t \rightarrow +\infty} t \overline{F}_Y(t) = 0$$

Démonstration de la proposition 3.2.1. Commençons par l'espérance de Y_1 . On a :

$$\mathbb{E}[Y_1] = \int_0^{+\infty} \overline{F_Y}(t) dt.$$

Or, $\overline{F_Y}$ est à variation régulière, donc

$$\lim_{t \rightarrow +\infty} \frac{\overline{F_Y}(2t)}{\overline{F_Y}(t)} = 2^{-\alpha}.$$

Puisque $\alpha > 1$, alors $2^{-\alpha} < 2^{-1} = \frac{1}{2}$. On peut donc choisir une valeur k telle que :

$$2^{-\alpha} < k < \frac{1}{2}.$$

Pour t assez grand ($t > M$), on a l'inégalité :

$$\overline{F_Y}(2t) < k\overline{F_Y}(t).$$

Par une récurrence immédiate on obtient : pour tout $n \in \mathbb{N}$:

$$\overline{F_Y}(2^n t) < k^n \overline{F_Y}(t).$$

Donc comme $\overline{F_Y}$ est décroissante on a :

$$\begin{aligned} \mathbb{E}[Y_1] &\leq \int_0^M \overline{F_Y}(t) dt + \sum_{n=0}^{+\infty} \int_{2^n M}^{2^{n+1} M} \overline{F_Y}(t) dt \\ &\leq \int_0^M \overline{F_Y}(t) dt + \sum_{n=0}^{+\infty} \overline{F_Y}(2^n M) \times 2^n M \text{ car } \overline{F_Y} \text{ est décroissante} \\ &\leq \int_0^M \overline{F_Y}(t) dt + \sum_{n=0}^{+\infty} (2k)^n M \overline{F_Y}(M) \\ \mathbb{E}[Y_1] &\leq \int_0^M \overline{F_Y}(t) dt + M \overline{F_Y}(M) \sum_{n=0}^{+\infty} (2k)^n < +\infty \text{ car } k < \frac{1}{2}. \end{aligned}$$

Donc Y_1 est intégrable.

Passons maintenant à Y_1^2 . On a :

$$\mathbb{E}[Y_1^2] = \int_0^{+\infty} 2t \overline{F_Y}(t) dt.$$

On a toujours :

$$\lim_{t \rightarrow +\infty} \frac{\overline{F_Y}(2t)}{\overline{F_Y}(t)} = 2^{-\alpha}.$$

Puisque $\alpha < 2$, alors $2^{-\alpha} > 2^{-2} = \frac{1}{4}$. On peut donc choisir une valeur k telle que

$$2^{-\alpha} > k > \frac{1}{4}.$$

Pour t assez grand ($t > M$), on a l'inégalité :

$$\overline{F_Y}(2t) > k\overline{F_Y}(t).$$

Par une récurrence immédiate on obtient que pour tout $n \in \mathbb{N}$:

$$\overline{F_Y}(2^n t) > k^n \overline{F_Y}(t).$$

Donc comme $\overline{F_Y}$ est décroissante on a :

$$\begin{aligned} \mathbb{E}[Y_1^2] &\geq \sum_{n=0}^{+\infty} \int_{2^n M}^{2^{n+1} M} 2t \overline{F_Y}(t) dt \\ &\geq \sum_{n=0}^{+\infty} \overline{F_Y}(2^{n+1} M) \times 4^n M^2 \text{ car } \overline{F_Y} \text{ est décroissante} \\ &\geq \sum_{n=0}^{+\infty} (4k)^n k M^2 \overline{F_Y}(M) \end{aligned}$$

$$\mathbb{E}[Y_1^2] \geq kM^2 \overline{F_Y}(M) \sum_{n=0}^{+\infty} (4k)^n = +\infty \text{ car } k > \frac{1}{4}.$$

Donc Y_1^2 n'est pas intégrable.

Supposons par l'absurde que

$$\lim_{t \rightarrow +\infty} t \overline{F_Y}(t) > 0.$$

Soit $\varepsilon > 0$, il existe une suite $(t_n)_{n \in \mathbb{N}}$ telle que

$$\frac{t_{n+1}}{2} > t_n \quad \text{et} \quad t_n \overline{F_Y}(t_n) > \varepsilon.$$

Or,

$$\begin{aligned} \int_0^{+\infty} \overline{F_Y}(t) dt &\geq \sum_{n=0}^{+\infty} \int_{\frac{t_n}{2}}^{t_n} \overline{F_Y}(t) dt \\ &\geq \sum_{n=0}^{+\infty} \int_{\frac{t_n}{2}}^{t_n} \overline{F_Y}(t_n) dt \text{ car } \overline{F_Y} \text{ est décroissante} \\ \int_0^{+\infty} \overline{F_Y}(t) dt &\geq \sum_{n=0}^{+\infty} \frac{t_n}{2} \overline{F_Y}(t_n) \geq \sum_{n=0}^{+\infty} \frac{t_n}{2} \frac{\varepsilon}{t_n} \geq \sum_{n=0}^{+\infty} \frac{\varepsilon}{2} \geq +\infty. \end{aligned}$$

Ce qui est absurde car $\mathbb{E}[Y_1] < +\infty$. Donc,

$$\lim_{t \rightarrow +\infty} t \overline{F_Y}(t) = 0.$$

□

3.2.1 Démonstration en utilisant la transformée de Laplace

Pour cette partie, on pourra consulter [ABUR] dont la preuve est inspirée.

Lemme 3.2.2 :

Soit μ et ν deux mesures positives sigma-finies sur $\mathbb{R}$. Posons

$$F(t) = \mu((-\infty, t]) \quad \text{et} \quad G(t) = \nu((-\infty, t]).$$

Alors, pour $a, b \in \mathbb{R}$:

$$F(b)G(b) - F(a)G(a) = \int_{(a,b]} F(s^-) d\nu(s) + \int_{(a,b]} G(t) d\mu(t).$$

Démonstration. Soit $a, b \in \mathbb{R}$,

$$\begin{aligned} (F(b) - F(a))(G(b) - G(a)) &= \iint_{(a,b]^2} d\mu \otimes d\nu(t, s) \\ &= \iint_{(a,b]^2} \mathbb{1}_{t < s} d\mu(t) d\nu(s) + \iint_{(a,b]^2} \mathbb{1}_{s \leq t} d\nu(s) d\mu(t) \\ &= \int_{(a,b]} (F(s^-) - F(a)) d\nu(s) + \int_{(a,b]} (G(t) - G(a)) d\mu(t) \\ (F(b) - F(a))(G(b) - G(a)) &= \int_{(a,b]} F(s^-) d\nu(s) - F(a)(G(b) - G(a)) + \int_{(a,b]} G(t) d\mu(t) - G(a)(F(b) - F(a)). \end{aligned}$$

D'où le résultat

$$F(b)G(b) - F(a)G(a) = \int_{(a,b]} F(s^-) d\nu(s) + \int_{(a,b]} G(t) d\mu(t).$$

□

Théorème 3.2.3 :

Soit $\Phi_\lambda = \sum_{i=1}^\infty \delta_{X_i}$ un processus ponctuel de Poisson homogène d'intensité $\lambda \in (0, \infty)$. Supposons que $\overline{F_Y}$ soit à variation régulière d'indice $-\alpha$ pour $\alpha \in (1, 2)$ et soit g (défini en (3.0.3)) l'inverse asymptotique de $\frac{1}{\overline{F_Y}}$ (de sorte que g est à variation régulière d'indice $1/\alpha$).

Alors, lorsque $\lambda \rightarrow \infty$, le champ $\{\tilde{I}_\lambda(y)\}_{y \in \mathbb{R}^d}$ converge, au sens des distributions de dimension finie, vers un champ aléatoire α -stable $\{S(z)\}_{z \in \mathbb{R}^d}$ dont la transformée de Laplace de dimension finie est :

$$\begin{aligned} \mathcal{L}_S(\mathbf{s}, \mathbf{z}) &:= \mathbb{E} \left[\exp \left(- \sum_{j=1}^m s_j S(z_j) \right) \right] \\ &= \exp \left(\frac{\Gamma(2-\alpha)}{\alpha-1} \int_{\mathbb{R}^d} \left[\sum_{j=1}^m s_j \ell(z_j - x) \right]^\alpha dx \right), \end{aligned} \quad (3.2.1)$$

pour $m \in \mathbb{N}$, $\mathbf{s}^\top = (s_1, \dots, s_m) \in [0, \infty)^m$ et $\mathbf{z} = (z_1, \dots, z_m) \in \mathbb{R}^{d \times m}$.

Remarque 3.2.4 :

L'intégrale en (3.2.1) est finie. En effet, soit $\mathbf{s}^\top = (s_1, \dots, s_m) \in [0, \infty)^m$ et $\mathbf{z} = (z_1, \dots, z_m) \in \mathbb{R}^{d \times m}$. Puisque $\alpha > 1$, on a :

$$\begin{aligned} \int_{\mathbb{R}^d} \left[\sum_{j=1}^m s_j \ell(z_j - x) \right]^\alpha dx &= \int_{\mathbb{R}^d} \left[\sum_{j=1}^m s_j \ell(z_j - x) \right]^{\alpha-1} \left[\sum_{j=1}^m s_j \ell(z_j - x) \right] dx \\ &\leq \int_{\mathbb{R}^d} \left[\sum_{j=1}^m s_j b_\ell \right]^{\alpha-1} \left[\sum_{j=1}^m s_j \ell(z_j - x) \right] dx \\ &\leq \left[\sum_{j=1}^m s_j \right]^{\alpha-1} b_\ell^{\alpha-1} \sum_{j=1}^m s_j \int_{\mathbb{R}^d} \ell(z_j - x) dx \\ &\leq \left[\sum_{j=1}^m s_j \right]^{\alpha-1} b_\ell^{\alpha-1} \sum_{j=1}^m s_j c_\ell \\ \int_{\mathbb{R}^d} \left[\sum_{j=1}^m s_j \ell(z_j - x) \right]^\alpha dx &\leq b_\ell^{\alpha-1} c_\ell \left[\sum_{j=1}^m s_j \right]^\alpha < +\infty, \end{aligned}$$

où b_ℓ et c_ℓ sont définies dans 3.1.2

La dernière expression de (3.2.1) implique certainement que $\{S(z)\}_{z \in \mathbb{R}^d}$ est un champ aléatoire α -stable, puisque chaque combinaison linéaire $\sum_{j=1}^m s_j S(z_j)$ pour $m \in \mathbb{N}$, $\mathbf{s}^\top \in [0, \infty)^m$ et $\mathbf{z} \in \mathbb{R}^{d \times m}$ suit une loi α -stable $S_\alpha(\sigma_{s,z}, 1, 0)$ avec :

$$\sigma_{s,z} = \left(- \frac{\Gamma(2-\alpha)}{\alpha-1} \int_{\mathbb{R}^d} \left[\sum_{j=1}^m s_j \ell(z_j - x) \right]^\alpha dx \cos \frac{\pi\alpha}{2} \right)^{1/\alpha}.$$

Démonstration du théorème 3.2.3. On reprend notre expression 3.1.6 obtenue lors de la démonstration de la proposition 3.1.1

$$\mathcal{L}_{\tilde{I}_\lambda}(s, z) = \exp \left(\lambda \int_{\mathbb{R}^d} \int_0^\infty \psi \left(\frac{\xi_{s,z}(x)}{g(\lambda)} t \right) d\mathbb{P}_Y(t) dx \right), \quad (3.2.2)$$

où

$$\xi_{s,z}(x) = \sum_{j=1}^m s_j \ell(z_j - x) \quad \text{et} \quad \psi(u) = e^{-u} - 1 + u.$$

Soit $x \in \mathbb{R}^d$. Soit $T > 0$. Posons

$$a = \frac{\xi_{s,z}(x)}{g(\lambda)}.$$

On souhaite appliquer le lemme 3.2.2 pour cela on prend $\nu = \mathbb{P}_Y$ et μ est la mesure de la fonction $h(t) = a(1 - e^{-at}) \mathbb{1}_{t \geq 0}$

contre la mesure de Lebesgue. On a

$$G(t) = F_Y(t) \quad \text{et} \quad F(t) = \int_0^t a(1 - e^{-ax}) \, dx.$$

On remarque que

$$F(t) = \psi(at).$$

De plus, F est continue par le théorème fondamental de l'Analyse.

Ainsi, par le lemme 3.2.2, on obtient

$$F(T)G(T) - F(0)G(0) = \int_0^T F_Y(s)a(1 - e^{-as}) \, ds + \int_0^T F(t) \, d\mathbb{P}_Y(t).$$

Donc,

$$\int_0^T F(t) \, d\mathbb{P}_Y(t) = [F(t)F_Y(t)]_0^T - \int_0^T F_Y(t)a(1 - e^{-at}) \, dt.$$

Or, $F_Y(t) = 1 - \overline{F_Y}(t)$ donc,

$$\begin{aligned} \int_0^T F_Y(t)a(1 - e^{-at}) \, dt &= a \int_0^T F_Y(t)(1 - e^{-at}) \, dt \\ &= a \int_0^T (1 - e^{-at}) \, dt - a \int_0^T (1 - e^{-at})\overline{F_Y}(t) \, dt \\ \int_0^T F_Y(t^-)a(1 - e^{-at}) \, dt &= e^{-aT} + aT - 1 - a \int_0^T (1 - e^{-at})\overline{F_Y}(t) \, dt. \end{aligned}$$

De plus,

$$\begin{aligned} [F(t)F_Y(t)]_0^T &= F(T)F_Y(T) - F(0)F_Y(0) \\ &= F(T)F_Y(T) \\ &= (e^{-aT} + aT - 1)F_Y(T). \end{aligned}$$

Donc, en assemblant, on obtient :

$$\begin{aligned} \int_0^T F(t) \, d\mathbb{P}_Y(t) &= (e^{-aT} + aT - 1)F_Y(T) - (e^{-aT} + aT - 1) + a \int_0^T (1 - e^{-at})\overline{F_Y}(t) \, dt \\ &= -(e^{-aT} + aT - 1)\overline{F_Y}(T) + a \int_0^T (1 - e^{-at})\overline{F_Y}(t) \, dt. \end{aligned}$$

Maintenant nous allons justifier le passage à la limite quand $T \rightarrow +\infty$.

★ On a :

$$|F(t)| \leq |e^{-at} - 1| + at \leq 1 + at.$$

Or, d'après la proposition 3.2.1

$$\int_0^{+\infty} 1 + at \, d\mathbb{P}_Y(t) = 1 + a\mathbb{E}[Y_1] < +\infty.$$

Par le théorème de convergence dominée, on obtient :

$$\lim_{T \rightarrow +\infty} \int_0^T F(t) \, d\mathbb{P}_Y(t) = \int_0^{+\infty} F(t) \, d\mathbb{P}_Y(t).$$

★ On utilise le théorème de convergence monotone car la suite $(\mathbb{1}_{[0,T]}(t)(1 - e^{-at})\overline{F_Y}(t))$ est croissante selon la variable T donc

$$\lim_{T \rightarrow +\infty} a \int_0^T (1 - e^{-at})\overline{F_Y}(t) \, dt = a \int_0^{+\infty} (1 - e^{-at})\overline{F_Y}(t) \, dt.$$

★ Il ne reste plus le terme de bord en T , pour cela on utilise le lemme 3.2.1 qui nous permet donc de nous donner que

$$\lim_{T \rightarrow +\infty} (e^{-aT} + aT - 1)\overline{F_Y}(T) = 0.$$

On en déduit donc,

$$\int_0^{+\infty} \psi\left(\frac{\xi_{s,z}(x)}{g(\lambda)}t\right) d\mathbb{P}_Y(t) = \frac{\xi_{s,z}(x)}{g(\lambda)} \int_0^{+\infty} \left(1 - \exp\left(-\frac{\xi_{s,z}(x)}{g(\lambda)}t\right)\right) \overline{F}_Y(t) dt.$$

En posant le changement de variable $u = \frac{t}{g(\lambda)}$ dans l'intégrale de droite on obtient :

$$\int_0^{+\infty} \psi\left(\frac{\xi_{s,z}(x)}{g(\lambda)}t\right) d\mathbb{P}_Y(t) = \xi_{s,z}(x) \int_0^{+\infty} (1 - \exp(-\xi_{s,z}(x)u)) \overline{F}_Y(g(\lambda)u) du.$$

Donc l'équation 3.2.2 devient

$$\mathcal{L}_{\tilde{I}_\lambda}(s, z) = \exp\left(\lambda \int_{\mathbb{R}^d} \xi_{s,z}(x) \int_0^{+\infty} (1 - \exp(-\xi_{s,z}(x)u)) \overline{F}_Y(g(\lambda)u) du dx\right). \quad (3.2.3)$$

En utilisant le théorème 2.4.1 et que $g(\lambda) \rightarrow +\infty$ quand $\lambda \rightarrow +\infty$, on a :

$$\lambda \sim \frac{1}{\overline{F}_Y(g(\lambda))}.$$

Donc

$$\begin{aligned} \lambda \int_{\mathbb{R}^d} \xi_{s,z}(x) \int_0^{+\infty} (1 - \exp(-\xi_{s,z}(x)u)) \overline{F}_Y(g(\lambda)u) du dx \\ \sim \int_{\mathbb{R}^d} \xi_{s,z}(x) \int_0^{+\infty} (1 - \exp(-\xi_{s,z}(x)u)) \frac{\overline{F}_Y(g(\lambda)u)}{\overline{F}_Y(g(\lambda))} du dx. \end{aligned}$$

De plus, on a :

$$\lim_{\lambda \rightarrow +\infty} \frac{\overline{F}_Y(g(\lambda)u)}{\overline{F}_Y(g(\lambda))} = u^{-\alpha}.$$

Si l'ordre de la limite et de l'intégrale est interchangeable (ce qui est confirmé ci-dessous), on obtient :

$$\begin{aligned} \lim_{\lambda \rightarrow +\infty} \int_{\mathbb{R}^d} \xi_{s,z}(x) \int_0^{+\infty} (1 - \exp(-\xi_{s,z}(x)u)) \frac{\overline{F}_Y(g(\lambda)u)}{\overline{F}_Y(g(\lambda))} du dx \\ = \int_{\mathbb{R}^d} \xi_{s,z}(x) \int_0^{+\infty} (1 - \exp(-\xi_{s,z}(x)u)) u^{-\alpha} du dx. \end{aligned} \quad (3.2.4)$$

En posant le changement de variable $v = \xi_{s,z}(x)u$, on obtient :

$$\begin{aligned} \int_{\mathbb{R}^d} \xi_{s,z}(x) \int_0^{+\infty} (1 - \exp(-\xi_{s,z}(x)u)) u^{-\alpha} du dx &= \int_{\mathbb{R}^d} [\xi_{s,z}(x)]^\alpha dx \int_0^{+\infty} (1 - e^{-v}) v^{-\alpha} dv \\ &= \frac{\Gamma(2-\alpha)}{\alpha-1} \int_{\mathbb{R}^d} [\xi_{s,z}(x)]^\alpha dx. \end{aligned}$$

Donc,

$$\lim_{\lambda \rightarrow +\infty} \mathcal{L}_{\tilde{I}_\lambda}(s, z) = \exp\left(\frac{\Gamma(2-\alpha)}{\alpha-1} \int_{\mathbb{R}^d} [\xi_{s,z}(x)]^\alpha dx\right).$$

Il reste à démontrer l'interchangeabilité de l'ordre de la limite et de l'intégrale en (3.2.4) Posons pour $\lambda > 0, u > 0$ et $x \in \mathbb{R}^d$

$$j(\lambda, x, u) = \xi_{s,z}(x) (1 - \exp(-\xi_{s,z}(x)u)) \frac{\overline{F}_Y(g(\lambda)u)}{\overline{F}_Y(g(\lambda))}.$$

On a déjà que pour tout $x \in \mathbb{R}^d$ et $u \in (0, +\infty)$ que

$$\lim_{\lambda \rightarrow +\infty} j(\lambda, x, u) = \xi_{s,z}(x) (1 - \exp(-\xi_{s,z}(x)u)) u^{-\alpha}.$$

De plus, puisque $\overline{F}_Y$ est à variation régulière d'indice $-\alpha$, on a :

$$\overline{F}_Y(s) = s^{-\alpha} L_0(s)$$

avec L_0 de la forme 2.3.2 c'est-à-dire il existe s_0 tels que pour tout $s \geq s_0$,

$$L_0(s) = \exp \left(\eta(s) + \int_a^s \frac{\varepsilon(u)}{u} du \right),$$

où $\eta(x)$ et $\varepsilon(x)$ sont des fonctions mesurables bornées, avec $\eta(x) \rightarrow d \in \mathbb{R}$ et $\varepsilon(x) \rightarrow 0$ quand $x \rightarrow \infty$. Comme $g(\lambda) \rightarrow +\infty$ quand $\lambda \rightarrow +\infty$, il existe donc λ_0 tels que pour tout $\lambda \geq \lambda_0$ $g(\lambda) \geq s_0$.

On peut donc définir les constantes η^* et ε^* par :

$$\eta^* = \sup_{\lambda \geq \lambda_0} |\eta(g(\lambda))|, \quad \varepsilon^* = \sup_{\lambda \geq \lambda_0} |\varepsilon(g(\lambda))|.$$

Puisque $\lim_{\lambda \rightarrow +\infty} \varepsilon(g(\lambda)) = 0$, on peut choisir notre constante λ_0 telle que $\varepsilon^* < \alpha - 1$. Par conséquent, pour $\lambda \geq \lambda_0$ et $u \geq 1$,

$$\begin{aligned} \frac{\overline{F_Y}(g(\lambda)u)}{\overline{F_Y}(g(\lambda))} &= u^{-\alpha} \frac{\exp \left(\eta(g(\lambda)u) + \int_{\lambda_0}^{g(\lambda)u} \frac{\varepsilon(t)}{t} dt \right)}{\exp \left(\eta(g(\lambda)) + \int_{\lambda_0}^{g(\lambda)} \frac{\varepsilon(t)}{t} dt \right)} \\ &= u^{-\alpha} \exp \left(\eta(g(\lambda)u) + \int_{\lambda_0}^{g(\lambda)u} \frac{\varepsilon(t)}{t} dt - \eta(g(\lambda)) - \int_{\lambda_0}^{g(\lambda)} \frac{\varepsilon(t)}{t} dt \right) \\ &= u^{-\alpha} \exp \left(\eta(g(\lambda)u) - \eta(g(\lambda)) + \int_{g(\lambda)}^{g(\lambda)u} \frac{\varepsilon(t)}{t} dt \right) \\ &\leq u^{-\alpha} \exp \left(2\eta^* + \varepsilon^* \int_{g(\lambda)}^{g(\lambda)u} \frac{dt}{t} \right) \\ \frac{\overline{F_Y}(g(\lambda)u)}{\overline{F_Y}(g(\lambda))} &\leq e^{2\eta^*} u^{-(\alpha-\varepsilon^*)}. \end{aligned}$$

Il reste plus qu'à traiter le cas où $u \in (0, 1)$. Comme $\overline{F_Y}$ est variation régulière d'indice $-\alpha$, en utilisant le théorème de caractérisation de Karamata (théorème 2.2.1), il existe une fonction L à variation lente telle que pour tout

$$\overline{F_Y}(t) = t^{-\alpha} L(t).$$

On a donc,

$$\frac{\overline{F_Y}(g(\lambda)u)}{\overline{F_Y}(g(\lambda))} = u^{-\alpha} \frac{L(g(\lambda)u)}{L(g(\lambda))}.$$

Soit $\delta > 0$ tel que $\alpha + \delta \in (1, 2)$. D'après le théorème de Potter (théorème 2.3.4), il existe un $X > 0$ tel que pour tout $x, y \geq X$ ($y \leq x$) :

$$\frac{L(y)}{L(x)} \leq 2 \left(\frac{y}{x} \right)^{-\delta}.$$

De plus, on peut supposer que $L(X) > 0$. Ainsi, si $0 < y \leq X < x$,

$$\frac{L(y)}{L(x)} \leq \frac{L(y)}{L(X)} \frac{L(X)}{L(x)} \leq \frac{2L(y)}{L(X)} \left(\frac{y}{x} \right)^{-\delta} \leq \frac{K}{L(X)} \left(\frac{y}{x} \right)^{-\delta}, \quad \text{où } K = \frac{\sup_{y \in [0, X]} 2L(y)}{L(X)}.$$

On a $K \leq \frac{2X^\alpha}{L(X)} < +\infty$ car $\overline{F_Y}$ est bornée sur $\mathbb{R}$. Ainsi, si on pose $C = \max\{2, K\}$ on a qu'il existe λ_1 tel que pour tout $\lambda \geq \lambda_1$,

$$\frac{\overline{F_Y}(g(\lambda)u)}{\overline{F_Y}(g(\lambda))} \leq Cu^{-\alpha-\delta}.$$

Par conséquent,

$$\xi_{s,z}(x) (1 - \exp(-\xi_{s,z}(x)u)) \frac{\overline{F_Y}(g(\lambda)u)}{\overline{F_Y}(g(\lambda))} \leq [\xi_{s,z}(x)]^2 Cu^{1-(\alpha+\delta)} \mathbb{1}_{(0,1)}(u) + \xi_{s,z}(x) e^{2\eta^*} u^{-(\alpha-\varepsilon^*)} \mathbb{1}_{[1,+\infty)}(u).$$

On sait déjà que $\xi_{s,z}(x)$, $[\xi_{s,z}(x)]^2$ sont intégrables sur $\mathbb{R}^d$ et puisque $\varepsilon^* < \alpha - 1$ et $\alpha + \delta \in (1, 2)$ on a :

$$\int_1^{+\infty} u^{-(\alpha-\varepsilon^*)} du < +\infty \quad \text{et} \quad \int_0^1 u^{1-(\alpha+\delta)} du < +\infty.$$

Tout cela nous donne que la fonction $[\xi_{s,z}(x)]^2 e^{2\eta^*} u^{1-(\alpha+\varepsilon^*)} \mathbb{1}_{(0,1)}(u) + \xi_{s,z}(x) e^{2\eta^*} u^{-(\alpha-\varepsilon^*)} \mathbb{1}_{[1,+\infty)}(u)$ est intégrable par rapport à la mesure $dx du$ et qui ne dépend pas de λ . Ainsi, on peut donc appliquer le théorème de convergence dominée. $\square$

3.2.2 Démonstration en utilisant la fonction caractéristique

Théorème 3.2.5 :

Soit $\Phi_\lambda = \sum_{i=1}^{\infty} \delta_{X_i}$ un processus ponctuel de Poisson homogène d'intensité $\lambda \in (0, \infty)$. Supposons que $\overline{F_Y}$ soit à variation régulière d'indice $-\alpha$ pour $\alpha \in (1, 2)$ et soit g (défini en (3.0.3)) l'inverse asymptotique de $\frac{1}{\overline{F_Y}}$ (de sorte que g est à variation régulière d'indice $1/\alpha$).

Alors, lorsque $\lambda \rightarrow \infty$, le champ $\{\tilde{I}_\lambda(y)\}_{y \in \mathbb{R}^d}$ converge, au sens des distributions de dimension finie, vers un champ aléatoire α -stable $\{S(z)\}_{z \in \mathbb{R}^d}$ dont la fonction caractéristique de dimension finie est :

$$\begin{aligned} \phi_S(u, z) &:= \mathbb{E} \left[\exp \left(i \sum_{j=1}^m u_j S(z_j) \right) \right] \\ &= \exp \left(- \int_{\mathbb{R}^d} \frac{\Gamma(2-\alpha)}{1-\alpha} |\xi_{u,z}(x)|^\alpha \cos \left(\frac{\pi\alpha}{2} \right) \left(1 - i \operatorname{sign}(\xi_{u,z}(x)) \tan \left(\frac{\pi\alpha}{2} \right) \right) dx \right), \end{aligned} \quad (3.2.5)$$

pour $m \in \mathbb{N}$, $u^\top = (u_1, \dots, u_m) \in \mathbb{R}^m$ et $z = (z_1, \dots, z_m) \in \mathbb{R}^{d \times m}$.

Remarque 3.2.6 :

La dernière expression de (3.2.5) implique toujours que $\{S(z)\}_{z \in \mathbb{R}^d}$ est un champ aléatoire α -stable, puisque chaque combinaison linéaire $\sum_{j=1}^m u_j S(z_j)$ pour $m \in \mathbb{N}$, $u^\top \in \mathbb{R}^m$ et $z \in \mathbb{R}^{d \times m}$ suit une loi α -stable $S_\alpha(\sigma_{u,z}, \beta_{u,z}, 0)$ avec :

$$\sigma_{s,z} = \left(- \frac{\Gamma(2-\alpha)}{\alpha-1} \int_{\mathbb{R}^d} \left| \sum_{j=1}^m u_j \ell(z_j - x) \right|^\alpha dx \cos \frac{\pi\alpha}{2} \right)^{1/\alpha}$$

et

$$\beta_{u,z} = \frac{\int_{\mathbb{R}^d} \operatorname{sign} \left(\sum_{j=1}^m u_j \ell(z_j - x) \right) \left| \sum_{j=1}^m u_j \ell(z_j - x) \right|^\alpha dx}{\int_{\mathbb{R}^d} \left| \sum_{j=1}^m u_j \ell(z_j - x) \right|^\alpha dx}.$$

Remarque 3.2.7 :

Si on prend tous les $u_j \geq 0$ on trouve $\beta_{u,z} = 1$.

Lemme 3.2.8 :

On considère l'intégrale pour $\mu \in (0, 2)$

$$I(\mu) = \int_0^{+\infty} \frac{x^{\mu-1}}{1+x^2} dx$$

Alors,

$$I(\mu) = \frac{\pi}{2 \sin \left(\frac{\pi\mu}{2} \right)}.$$

Démonstration du lemme 3.2.8. Le convergence de l'intégrale est laissée en exercice. On effectue alors le changement de variable pour $\theta \in (0, \frac{\pi}{2})$

$$x = \tan(\theta)$$

Ainsi,

$$I(\mu) = \int_0^{\frac{\pi}{2}} \tan(\theta)^{\mu-1} d\theta$$

Donc,

$$I(\mu) = \int_0^{\frac{\pi}{2}} \sin(\theta)^{\mu-1} \cos(\theta)^{1-\mu} d\theta.$$

Or, cette intégrale est juste la fonction bêta au point $a = \frac{\mu}{2}$ et $b = 1 - \frac{\mu}{2}$ à une constante près. Ainsi,

$$I(\mu) = \frac{1}{2} B \left(\frac{\mu}{2}, 1 - \frac{\mu}{2} \right).$$

Par une propriété sur la fonction bêta, on obtient

$$I(\mu) = \frac{1}{2} \Gamma \left(\frac{\mu}{2} \right) \Gamma \left(1 - \frac{\mu}{2} \right) = \frac{\pi}{2 \sin \left(\frac{\pi\mu}{2} \right)}.$$

□

Proposition 3.2.9 :

Pour $\alpha \in (1, 2)$, l'intégrale

$$J(\alpha) = \int_0^{+\infty} (e^{iv} - 1)v^{-\alpha} dv$$

est convergente et vaut

$$J(\alpha) = i \frac{\Gamma(2 - \alpha)}{1 - \alpha} e^{-i \frac{\pi\alpha}{2}}.$$

Démonstration de la proposition 3.2.9. La convergence est encore une fois laissée au lecteur. Calculons $J(\alpha)$. Pour cela on part de

$$\Gamma(\alpha) = \int_0^{+\infty} e^{-t} t^{\alpha-1} dt.$$

En effectuant le changement de variable $t = vs$ pour $v > 0$, on obtient

$$v^{-\alpha} = \frac{1}{\Gamma(\alpha)} \int_0^{+\infty} e^{-vs} s^{\alpha-1} ds.$$

On a donc

$$J(\alpha) = \int_0^{+\infty} \int_0^{+\infty} (e^{iv} - 1) \frac{1}{\Gamma(\alpha)} e^{-vs} s^{\alpha-1} ds dv.$$

On a

$$\int_0^{+\infty} \int_0^{+\infty} \left| (e^{iv} - 1) \frac{1}{\Gamma(\alpha)} e^{-vs} s^{\alpha-1} \right| ds dv = \int_0^{+\infty} |(e^{iv} - 1)| v^{-\alpha} dv < +\infty.$$

On peut donc appliquer Fubini et on obtient

$$\begin{aligned} J(\alpha) &= \frac{1}{\Gamma(\alpha)} \int_0^{+\infty} s^{\alpha-1} \int_0^{+\infty} (e^{iv} - 1) e^{-vs} dv ds \\ &= \frac{1}{\Gamma(\alpha)} \int_0^{+\infty} s^{\alpha-1} \left(\frac{1}{s-i} - \frac{1}{s} \right) ds \\ J(\alpha) &= \frac{i}{\Gamma(\alpha)} \int_0^{+\infty} \frac{s^{\alpha-2}}{s-i} ds. \end{aligned}$$

Or,

$$\int_0^{+\infty} \frac{s^{\alpha-2}}{s-i} ds = \int_0^{+\infty} \frac{s^{\alpha-1}}{1+s^2} ds + i \int_0^{+\infty} \frac{s^{\alpha-2}}{1+s^2} ds.$$

On applique le lemme 3.2.8 et on obtient,

$$\int_0^{+\infty} \frac{s^{\alpha-2}}{s-i} ds = \frac{\pi}{2 \sin\left(\frac{\pi\alpha}{2}\right)} + i \frac{\pi}{2 \sin\left(\frac{\pi(\alpha-1)}{2}\right)} = \frac{\pi e^{-i \frac{\pi\alpha}{2}}}{\sin(\pi\alpha)}.$$

Or,

$$\Gamma(\alpha)\Gamma(1-\alpha) = \frac{\pi}{\sin(\pi\alpha)}.$$

Ainsi,

$$J(\alpha) = i \frac{\Gamma(2-\alpha)}{1-\alpha} e^{-i \frac{\pi\alpha}{2}}.$$

□

Corollaire 3.2.10 :

Soient $x \in \mathbb{R}^*$ et $\alpha \in (1, 2)$. On a alors :

$$\int_0^{+\infty} (e^{i \operatorname{sign}(x) v} - 1) v^{-\alpha} dv = \operatorname{sign}(x) i \frac{\Gamma(2-\alpha)}{1-\alpha} \exp\left(-\operatorname{sign}(x) i \frac{\pi\alpha}{2}\right).$$

Démonstration du corollaire 3.2.10. On applique le conjugué à la proposition 3.2.9.

□

Démonstration du théorème 3.2.5. On reprend notre expression 3.1.10 obtenue lors de la démonstration de la proposition 3.1.1

$$\phi_{\tilde{I}_\lambda}(u, z) = \exp \left(\lambda \int_{\mathbb{R}^d} \int_0^\infty \psi \left(\frac{\xi_{u,z}(x)}{g(\lambda)} t \right) d\mathbb{P}_Y(t) dx \right). \quad (3.2.6)$$

où

$$\xi_{u,z}(x) = \sum_{j=1}^m u_j \ell(z_j - x) \quad \text{et} \quad \psi(s) = e^{is} - 1 - is.$$

Soit $x \in \mathbb{R}^d$. Soit $T > 0$. Posons

$$a = \frac{\xi_{u,z}(x)}{g(\lambda)}.$$

Posons

$$G(t) = F_Y(t) \quad \text{et} \quad F(t) = \int_0^t ia(e^{ias} - 1) ds.$$

On remarque que

$$F(t) = \psi(at).$$

De plus, F est de classe C^1 sur $\mathbb{R}^+$.

Ainsi, par la formule d'intégration par parties de Riemann-Stieltjes et comme F est de classe C^1 (on pourra consulter [LI]), on obtient pour $T > 0$:

$$F(T)G(T) - F(0)G(0) = \int_0^T F_Y(s)ia(e^{ias} - 1) ds + \int_0^T F(t) d\mathbb{P}_Y(t).$$

Donc,

$$\int_0^T F(t) d\mathbb{P}_Y(t) = [F(t)F_Y(t)]_0^T - \int_0^T F_Y(t)ia(e^{iat} - 1) dt.$$

Or, $F_Y(t) = 1 - \overline{F_Y}(t)$ donc,

$$\begin{aligned} \int_0^T F_Y(t)ia(e^{iat} - 1) dt &= ia \int_0^T F_Y(t)(e^{iat} - 1) dt \\ &= ia \int_0^T (e^{iat} - 1) dt - ia \int_0^T (e^{iat} - 1)\overline{F_Y}(t) dt \\ \int_0^T F_Y(t)a(e^{iat} - 1) dt &= e^{iaT} - 1 - iaT - ia \int_0^T (e^{iat} - 1)\overline{F_Y}(t) dt. \end{aligned}$$

De plus,

$$\begin{aligned} [F(t)F_Y(t)]_0^T &= F(T)F_Y(T) - F(0)F_Y(0) \\ &= F(T)F_Y(T) \\ &= (e^{iaT} - 1 - iaT)F_Y(T). \end{aligned}$$

Donc, en assemblant, on obtient :

$$\int_0^T F(t) d\mathbb{P}_Y(t) = -(e^{iaT} - 1 - iaT)\overline{F_Y}(T) + ia \int_0^T (e^{iat} - 1)\overline{F_Y}(t) dt.$$

Maintenant nous allons justifier le passage à la limite quand $T \rightarrow +\infty$.

★ On a :

$$|F(t)| \leq 2 + at.$$

Or, d'après la proposition 3.2.1

$$\int_0^{+\infty} 2 + at d\mathbb{P}_Y(t) = 2 + a\mathbb{E}[Y_1] < +\infty.$$

Par le théorème de convergence dominée, on obtient :

$$\lim_{T \rightarrow +\infty} \int_0^T F(t) d\mathbb{P}_Y(t) = \int_0^{+\infty} F(t) d\mathbb{P}_Y(t).$$

★ On a :

$$|\mathbb{1}_{[0,T]}(t)ia(e^{iat} - 1)\overline{F_Y}(t)| \leq 2a\overline{F_Y}(t).$$

Or, Y admet une espérance, donc $2a\overline{F_Y}$ est intégrable. Par conséquent par convergence dominée

$$\lim_{T \rightarrow +\infty} ia \int_0^T (e^{iat} - 1)\overline{F_Y}(t) dt = ia \int_0^{+\infty} (e^{iat} - 1)\overline{F_Y}(t) dt.$$

★ Il ne reste plus le terme de bord en T , pour cela on utilise le lemme 3.2.1 que nous permet donc de nous donner que

$$\lim_{T \rightarrow +\infty} (e^{iaT} - 1 - iaT)\overline{F_Y}(T) = 0.$$

On en déduit donc,

$$\int_0^{+\infty} \psi\left(\frac{\xi_{u,z}(x)}{g(\lambda)}t\right) d\mathbb{P}_Y(t) = i\frac{\xi_{u,z}(x)}{g(\lambda)} \int_0^{+\infty} \left(\exp\left(i\frac{\xi_{u,z}(x)}{g(\lambda)}t\right) - 1\right) \overline{F_Y}(t) dt.$$

En posant le changement de variable $s = \frac{t}{g(\lambda)}$ dans l'intégrale de droite, on obtient :

$$\int_0^{+\infty} \psi\left(\frac{\xi_{u,z}(x)}{g(\lambda)}t\right) d\mathbb{P}_Y(t) = i\xi_{u,z}(x) \int_0^{+\infty} (\exp(i\xi_{u,z}(x)s) - 1) \overline{F_Y}(g(\lambda)s) ds.$$

Donc l'équation 3.2.6 devient

$$\phi_{\tilde{I}_\lambda}(u, z) = \exp\left(i\lambda \int_{\mathbb{R}^d} \xi_{u,z}(x) \int_0^{+\infty} (\exp(i\xi_{u,z}(x)s) - 1) \overline{F_Y}(g(\lambda)s) ds dx\right). \quad (3.2.7)$$

En utilisant le théorème 2.4.1 et que $g(\lambda) \rightarrow +\infty$ quand $\lambda \rightarrow +\infty$, on a :

$$\lambda \sim \frac{1}{\overline{F_Y}(g(\lambda))}.$$

Donc,

$$\begin{aligned} i\lambda \int_{\mathbb{R}^d} \xi_{u,z}(x) \int_0^{+\infty} (\exp(i\xi_{u,z}(x)s) - 1) \overline{F_Y}(g(\lambda)s) ds dx \\ \sim i \int_{\mathbb{R}^d} \xi_{u,z}(x) \int_0^{+\infty} (\exp(i\xi_{u,z}(x)s) - 1) \frac{\overline{F_Y}(g(\lambda)s)}{\overline{F_Y}(g(\lambda))} ds dx. \end{aligned}$$

De plus, on a :

$$\lim_{\lambda \rightarrow +\infty} \frac{\overline{F_Y}(g(\lambda)s)}{\overline{F_Y}(g(\lambda))} = s^{-\alpha}.$$

On aimerait passer à la limite quand $\lambda \rightarrow +\infty$. Posons pour $\lambda > 0, s > 0$ et $x \in \mathbb{R}^d$

$$j(\lambda, x, s) = i\xi_{u,z}(x) (\exp(i\xi_{u,z}(x)s) - 1) \frac{\overline{F_Y}(g(\lambda)s)}{\overline{F_Y}(g(\lambda))}.$$

On a déjà que pour tout $x \in \mathbb{R}^d$ et $s \in (0, +\infty)$ que

$$\lim_{\lambda \rightarrow +\infty} j(\lambda, x, s) = i\xi_{u,z}(x) (\exp(i\xi_{u,z}(x)s) - 1) s^{-\alpha}.$$

De plus pour $x \in \mathbb{R}^d$ et $s \in (0, +\infty)$

$$\begin{aligned} |j(\lambda, x, s)| &= |\xi_{u,z}(x)| |\exp(i\xi_{u,z}(x)s) - 1| \frac{\overline{F_Y}(g(\lambda)s)}{\overline{F_Y}(g(\lambda))} \\ &\leq |\xi_{u,z}(x)|^2 C s^{1-(\alpha+\delta)} \mathbb{1}_{(0,1)}(s) + 2|\xi_{u,z}(x)| e^{2\eta^*} s^{-(\alpha-\varepsilon^*)} \mathbb{1}_{[1,+\infty)}(s), \end{aligned}$$

en gardant les mêmes notations que lors de la démonstration avec la transformée de Laplace.

On sait déjà que $|\xi_{u,z}(x)|, |\xi_{u,z}(x)|^2$ sont intégrables sur $\mathbb{R}^d$ et

$$\int_1^{+\infty} s^{-(\alpha-\varepsilon^*)} ds < +\infty \quad \text{et} \quad \int_0^1 s^{1-(\alpha+\delta)} ds < +\infty.$$

Tout cela nous donne que la fonction $|\xi_{u,z}(x)|^2 C s^{1-(\alpha+\delta)} \mathbb{1}_{(0,1)}(s) + 2|\xi_{u,z}(x)| e^{2\eta^*} s^{-(\alpha-\varepsilon^*)} \mathbb{1}_{[1,+\infty)}(s)$ est intégrable par rapport à la mesure $dx ds$ et qui ne dépend pas de λ . Ainsi, on peut donc appliquer le théorème de convergence dominée.

Ainsi, on obtient :

$$\begin{aligned} \lim_{\lambda \rightarrow +\infty} i \int_{\mathbb{R}^d} \xi_{u,z}(x) \int_0^{+\infty} (\exp(i\xi_{u,z}(x)s) - 1) \frac{\overline{F_Y}(g(\lambda)s)}{\overline{F_Y}(g(\lambda))} ds dx \\ = i \int_{\mathbb{R}^d} \xi_{u,z}(x) \int_0^{+\infty} (\exp(i\xi_{u,z}(x)s) - 1) s^{-\alpha} ds dx. \end{aligned} \quad (3.2.8)$$

En posant le changement de variable $v = |\xi_{u,z}(x)|s$, on obtient :

$$\begin{aligned} i \int_{\mathbb{R}^d} \xi_{u,z}(x) \int_0^{+\infty} (\exp(i\xi_{u,z}(x)s) - 1) s^{-\alpha} ds dx \\ = i \int_{\mathbb{R}^d} \text{sign}(\xi_{u,z}(x)) |\xi_{u,z}(x)|^\alpha \int_0^{+\infty} \left(e^{i \text{sign}(\xi_{u,z}(x)) v} - 1 \right) v^{-\alpha} dv dx. \end{aligned}$$

En appliquant le corollaire 3.2.10 on obtient

$$\begin{aligned} i \int_{\mathbb{R}^d} \xi_{u,z}(x) \int_0^{+\infty} (\exp(i\xi_{u,z}(x)s) - 1) s^{-\alpha} ds dx \\ = i \int_{\mathbb{R}^d} \text{sign}(\xi_{u,z}(x)) |\xi_{u,z}(x)|^\alpha \text{sign}(\xi_{u,z}(x)) i \frac{\Gamma(2-\alpha)}{1-\alpha} e^{-\text{sign}(\xi_{u,z}(x)) i \frac{\pi\alpha}{2}} dx \\ = -\frac{\Gamma(2-\alpha)}{1-\alpha} \int_{\mathbb{R}^d} |\xi_{u,z}(x)|^\alpha e^{-\text{sign}(\xi_{u,z}(x)) i \frac{\pi\alpha}{2}} dx \\ = -\int_{\mathbb{R}^d} \frac{\Gamma(2-\alpha)}{1-\alpha} |\xi_{u,z}(x)|^\alpha \cos\left(\frac{\pi\alpha}{2}\right) \left(1 - i \text{sign}(\xi_{u,z}(x)) \tan\left(\frac{\pi\alpha}{2}\right)\right) dx. \end{aligned}$$

Ainsi,

$$\lim_{\lambda \rightarrow +\infty} \phi_{\tilde{I}_\lambda}(u, z) = \exp\left(-\int_{\mathbb{R}^d} \frac{\Gamma(2-\alpha)}{1-\alpha} |\xi_{u,z}(x)|^\alpha \cos\left(\frac{\pi\alpha}{2}\right) \left(1 - i \text{sign}(\xi_{u,z}(x)) \tan\left(\frac{\pi\alpha}{2}\right)\right) dx\right).$$

□

4 Différentes simulations

Ici, j'explique juste comment simuler $\tilde{I}_\lambda(z)$ et je montre les résultats.

4.1 Mise en place du code

- ★ **Étapes n°1 :** On se donne un réel $L > 0$, un réel $0 < \lambda < +\infty$, un entier $d \geq 1$, un réel $z \in \mathbb{R}^d$ et une fonction ℓ intégrable sur $\mathbb{R}^d$.
- ★ **Étapes n°2 :** On simule une loi de Poisson de paramètre $\lambda|[-L, L]^d|$: $N_L \sim \mathcal{P}(\lambda|[-L, L]^d|)$.
- ★ **Étapes n°3 :** On simule $(U_1, \dots, U_N)$, N_L variables aléatoires indépendantes de même loi, à savoir de loi uniforme sur $[-L, L]^d$: $U_i \sim \mathcal{U}([-L, L]^d)$.
De plus, on simule $(P_1, \dots, P_N)$ N_L variables aléatoires indépendantes de même loi, à savoir de loi Y_1 et indépendantes des (U_i) .
- ★ **Étapes n°4 :** On calcule la quantité

$$T = \sum_{n=1}^N P_n \ell(z - U_n).$$

- ★ **Étapes n°5 :** On calcule l'espérance de T . On peut la calculer de deux manières :
 1. On fait un calcul explicite :

$$\begin{aligned} \mathbb{E}[T \mid N = k] &= \mathbb{E} \left[\sum_{n=1}^N P_n \ell(z - U_n) \mid N = k \right] \\ &= \mathbb{E}[P_1] \mathbb{E} \left[\sum_{n=1}^k \ell(z - U_n) \mid N = k \right] \text{ car } (P_i) \text{ indépendants de } (U_i) \text{ et } N \\ &= \mathbb{E}[P_1] \sum_{n=1}^k \mathbb{E}[\ell(z - U_n) \mid N = k] \\ &= k \mathbb{E}[P_1] \mathbb{E}[\ell(z - U_1)]. \end{aligned}$$

Ainsi

$$\mathbb{E}[T \mid N] = \sum_{k=0}^{+\infty} k \mathbb{E}[P_1] \mathbb{E}[\ell(z - U_1)] \mathbb{1}_{N=k}.$$

Par conséquent, en utilisant Fubini positif,

$$\mathbb{E}[T] = \mathbb{E}[N] \mathbb{E}[P_1] \mathbb{E}[\ell(z - U_1)] = \lambda |[-L, L]^d| p \frac{1}{|[-L, L]^d|} \int_{[-L, L]^d} \ell(z - x) dx = \lambda p \int_{[-L, L]^d} \ell(z - x) dx.$$

2. Sinon on fait une moyenne empirique.

- ★ **Étapes n°6 :** On calcule ensuite $\tilde{I}_\lambda(z)$

Pour montrer les résultats de convergence (proposition 3.1.1 et théorème 3.2.5), on utilise la méthode de Monte-Carlo.

4.2 Simulations

```
In [1]: import numpy as np
import numpy.random as alea
import matplotlib.pyplot as plt
import scipy.stats as stats
from scipy.special import gamma
from scipy.spatial import cKDTree
```

Simulation de la convergence dans le cas où Y_1 admet un moment d'ordre 2 :

Cas de la dimension 1 :

Amplitude : loi exponentielle

Pour les paramètres on prends :

```
In [2]: lambda_ = 50      # intensité du processus de poisson
L = 30      # fenêtre spatiale [-L,L]
z = 0.0     # point de l'évaluation
nbsample = 2000 # nombre de simulation
```

Pour les amplitudes on prend de loi exponentiel de paramètre μ :

$$Y_1 \sim \mathcal{E}(\mu)$$

```
In [3]: mu = 0.5          # paramètre de la loi
EY = 1/mu                # Esperance
EY2 = 2/(mu**2)          # second moment
print("Le paramètre de la loi exponentielle est", mu)
print("L'espérance est égale à", EY)
print("Le second moment d'ordre 2 est égale à", EY2)
```

Le paramètre de la loi exponentielle est 0.5

L'espérance est égale à 2.0

Le second moment d'ordre 2 est égale à 8.0

Définissons la fonction réponse :

$$\ell(x) = \exp(-|x|)$$

```
In [4]: def exp(x):
return np.exp(-np.abs(x))
```

Calcul de la quantité si $z \in [-L, L]$:

$$\lambda p \int_{-L}^L \ell(z-x) dx = 2 - \exp(-(z+L)) - \exp(-(L-z))$$

```
In [5]: def moyenne_empirique(z,L,EY,lambda_):
int_ell = 2 - np.exp(-(z+L)) - np.exp(-(L-z))
moyenne_I = lambda_ * EY * int_ell
```

```

return moyenne_I
print(moyenne_empirique(z,L,EY,lambda_))

```

199.9999999999813

Simulation de $\tilde{I}_\lambda(z)$

```

In [6]: Z = np.linspace(-L,L,1000)    # Liste d'évaluation de notre processus : z

plt.figure(figsize=(14, 5))

nbtrajectoire = 5                      # Nombre de trajectoires

for _ in range(nbtrajectoire):
    N = stats.poisson.rvs(lambda_ * (2*L))    # Nombre de points du PPP dans [-L, L]
    X = stats.uniform.rvs(loc=-L, scale=2*L,size=N)    # Position de X_n
    Y = stats.expon.rvs(scale=1/mu, size=N)    # Amplitudes Y_n


    I_tilde = np.zeros(len(Z))

    for i in range(len(Z)) :
        I_tilde[i] = (np.sum(Y * exp(Z[i] - X)) - moyenne_empirique(Z[i],L,EY,lambda_)) /
        np.sqrt(lambda_) # Calcul de notre processus I_lambda

    plt.plot(Z,I_tilde)    # On affiche la trajectoire

plt.xlabel(r"$z$")
plt.ylabel(r"$\tilde{I}_\lambda(z)$")
plt.title(r"Simulation de $\tilde{I}_\lambda(z)$ avec $L={}$, $Y_1 \sim \text{varepsilon}({})$, $\lambda={}$ ".format(L,mu,lambda_))
plt.xlim(-L+5,L+5)
plt.show()

```



Simulation de la convergence :

```

In [7]: z=20
Lambda_ =[0.1,0.5,2,10,50,200]
L = 200

fig, ax = plt.subplots(2,3,figsize=(15,8))

for i in range(0,2):

```

```

for j in range(0,3):
    if i == 0:
        k = j
    else :
        k = 3 + j

    lambda_ = Lambda_[k]
    moyenne_I = moyenne_empirique(z,L,EY,lambda_)

    I_tilde = np.zeros(nbsample)

    for k in range(nbsample):
        N = stats.poisson.rvs(lambda_ * (2*L))           # Nombre de points du PPP dans
        [-L, L]# simulation
        X = stats.uniform.rvs(loc=-L, scale=2*L,size=N)   # Position de  $X_n$ 
        Y = stats.expon.rvs(scale=1/mu, size=N)           # Amplitudes  $Y_n$ 
        I = np.sum(Y * exp(z - X))                       # Calcule de  $I_{\lambda}(z)$ 


        I_tilde[k] = (I - moyenne_I) / np.sqrt(lambda_)  # Calcule de
        \tilde{I}_{\lambda}(z)

    x = np.linspace(min(I_tilde), max(I_tilde), 400)

    ax[i,j].hist(I_tilde, bins=20, density=True, alpha=0.4, label="Histogramme")

    ax[i,j].plot(x, stats.norm.pdf(x, loc=0, scale=np.sqrt(EY2)), 'r', lw=2, label="N(0,
    {})".format(EY2)) # Densité de la loi normale

    ax[i,j].set_xlabel(r"$\tilde{I}_{\lambda}(0)$")
    ax[i,j].set_ylabel("Densité")
    ax[i,j].set_title(r"$\lambda = {}$ ".format(lambda_))
    ax[i,j].legend()
    ax[i,j].grid(alpha=0.3)
fig.suptitle(r"$\tilde{I}_{\lambda}(z)$ avec $L={}$, $z={}$, $Y_1 \sim \text{varepsilon}({})$".format(L,z,mu))
fig.tight_layout()
    
```



Amplitude : loi de Bernoulli

```
In [8]: lambda_ = 50      # intensité du processus de poisson
L = 30      # fenêtre spatiale [-L,L]
z = 0.0     # point de l'évaluation
nbsample = 2000 # nombre de simulation
```

Pour les amplitudes on prend de loi de Bernoulli de paramètre $p \in]0, 1[$:

$$Y_1 \sim \mathcal{B}(p)$$

```
In [9]: p = 0.5          # paramètre de la loi de Bernoulli
EY = p                  # Espérance
EY2 = p                 # second moment
print("Le paramètre de la loi Bernoulli est", p)
print("L'espérance est égale à", EY)
print("Le second moment d'ordre 2 est égale à", EY2)
```

Le paramètre de la loi Bernoulli est 0.5

L'espérance est égale à 0.5

Le second moment d'ordre 2 est égale à 0.5

```
In [10]: Z = np.linspace(-L,L,1000) # Liste d'évaluation de notre processus : z

plt.figure(figsize=(15, 5))

nbtrajectoire = 20 # Nombre de trajectoires


for _ in range(nbtrajectoire):
    N = stats.poisson.rvs(lambda_ * (2*L)) # Nombre de points du PPP dans [-L, L]
    X = stats.uniform.rvs(loc=-L, scale=2*L, size=N) # Position de X_n
    Y = stats.bernoulli.rvs(p, loc=0, size=N) # Amplitudes Y_n

    I_tilde = np.zeros(len(Z))

    for i in range(len(Z)) :
        I_tilde[i] = (np.sum(Y * exp(Z[i] - X)) - moyenne_empirique(Z[i],L,EY,lambda_)) /
np.sqrt(lambda_) # Calcul de notre processus I_lambda

    plt.plot(Z,I_tilde) # On affiche la trajectoire

plt.xlabel(r"$z$")
plt.ylabel(r"$\tilde{I}_\lambda(z)$")
plt.title(r"Simulation de $\tilde{I}_\lambda(z)$ avec $L=\{ \}$, $Y_1 \sim \mathcal{B}(\{ \})$, $\lambda = \{ \}$".format(L,p,lambda_))
plt.xlim(-L+5,L-5)
plt.show()
```



```
In [11]: z=20
Lambda_=[0.1,0.5,2,10,50,100]
L = 200

fig, ax = plt.subplots(2,3,figsize=(15,8))

for i in range(0,2):
    for j in range(0,3):
        if i == 0:
            k = j
        else :
            k= 3 +j

        lambda_ = Lambda_[k]
        moyenne_I = moyenne_empirique(z,L,EY,lambda_)

        I_tilde = np.zeros(nbsample)

        for k in range(nbsample):
            N = stats.poisson.rvs(lambda_ * (2*L))           # Nombre de points du PPP dans
            [-L, L]# simulation
            X = stats.uniform.rvs(loc=-L, scale=2*L,size=N)   # Position de X_n
            Y = stats.bernoulli.rvs(p,loc=0, size=N)          # Amplitudes Y_n
            I = np.sum(Y * exp(z - X))                        # Calcul de I_Lambda(z)


            I_tilde[k] = (I - moyenne_I) / np.sqrt(lambda_)   # Calcul de
            \tilde{I}_\lambda(z)

            x = np.linspace(min(I_tilde), max(I_tilde), 400)

            ax[i,j].hist(I_tilde, bins=20, density=True, alpha=0.4, label="Histogramme")

            ax[i,j].plot(x, stats.norm.pdf(x, loc=0, scale=np.sqrt(EY2)), 'r', lw=2, label="N(0,
            {})".format(EY2)) # Densité de la loi normale

            ax[i,j].set_xlabel(r"$\tilde{I}_\lambda(0)$")
            ax[i,j].set_ylabel("Densité")
            ax[i,j].set_title(r" $\lambda$ ={} ".format(lambda_))
            ax[i,j].legend()
            ax[i,j].grid(alpha=0.3)
fig.suptitle(r"$\tilde{I}_\lambda(z)$ avec $L={}$, $z={}$, $Y_1 \sim B({})$".format(L,z,p))
fig.tight_layout()
```



Cas de la dimension 2 :

On définit les paramètres :

```
In [12]: R = 5 # Rayon de la boule
lambda_2 = 10 # intensité du processus de poisson
L = 80 # fenêtre spatiale [-L,L] ON PREND L > R
z = np.array([0.0, 0.0]) # point de l'évaluation
nbsample = 2000 # nombre de simulation
```

Pour les amplitudes on prend de loi exponentiel de paramètre μ :

$$Y_1 \sim \mathcal{E}(\mu)$$

```
In [13]: mu = 1.0 # paramètre de la loi
EY = 1/mu # Esperance
EY2 = 2/(mu**2) # second moment
print(EY)
print(EY2)
```

1.0

2.0

Définissons la fonction réponse, on prend la boule de rayon R :

$$\ell(x) = 1_{\|x\| \leq R}(x).$$

```
In [14]: def boule(x):
return (np.linalg.norm(x, axis=1) <= R).astype(float)
```

```
In [15]: def moyenne_empirique2D(R,EY,lambda_2):
int_ell = np.pi*R**2
moyenne_I = lambda_2 * EY * int_ell
return moyenne_I
```

```
In [16]: R = 5                                # Rayon de la boule
lambda_2 = 0.1                              # intensité du processus de poisson
L = 50                                       # fenêtre spatiale [-L,L]

N = stats.poisson.rvs(lambda_2 * 4*(L)**2)
X = stats.uniform.rvs(loc=-L,scale=2*L, size=(N,2))
Y = stats.expon.rvs(scale=1/mu, size=N)


grid = np.linspace(-L+2*R, L-2*R, 200)

I_tilde = np.zeros((len(grid), len(grid)))

for i, x in enumerate(grid):
    for j, y in enumerate(grid):
        z = np.array([x, y])
        I_tilde[i, j] = (np.sum(Y * boule(z - X)) -
moyenne_empirique2D(R,EY,lambda_2))/np.sqrt(lambda_2)

plt.figure(figsize=(8, 8))

plt.imshow(I_tilde,extent = [grid[0], grid[-1], grid[0],
grid[-1]],origin="lower",cmap="viridis")
plt.colorbar(label=r"$\tilde{I}_\lambda(x,y)$")
plt.contour(I_tilde,levels=0,extent = [grid[0], grid[-1], grid[0], grid[-1]],colors="white")
plt.xlabel("x")
plt.ylabel("y")
plt.title(r"Shot-Noise Fields $\tilde{I}_\lambda(x,y)$")
plt.show()
```



```
In [17]: R = 5                                # Rayon de la boule
lambda_2 = 20                                # intensité du processus de poisson
L = 50                                        # fenêtre spatiale [-L,L]

N = stats.poisson.rvs(lambda_2 * 4*(L)**2)
X = stats.uniform.rvs(loc=-L,scale=2*L, size=(N,2))
Y = stats.expon.rvs(scale=1/mu, size=N)

grid = np.linspace(-L+2*R, L-2*R, 200)


I_tilde = np.zeros((len(grid), len(grid)))

for i, x in enumerate(grid):
    for j, y in enumerate(grid):
        z = np.array([x, y])
        I_tilde[i, j] = (np.sum(Y * boule(z - X)) -
moyenne_empirique2D(R,EY,lambda_2))/np.sqrt(lambda_2)

plt.figure(figsize=(8, 8))

plt.imshow(I_tilde,extent = [grid[0], grid[-1], grid[0],
grid[-1]],origin="lower",cmap="viridis")
plt.colorbar(label=r"$\tilde{I}_\lambda(x,y)$")
```

```
plt.contour(I_tilde, levels=0, extent = [grid[0], grid[-1], grid[0], grid[-1]], colors="white")
plt.xlabel("x")
plt.ylabel("y")
plt.title(r"Shot-Noise Fields  $\tilde{I}_\lambda(x,y)$ ")
plt.show()
```



```
In [18]: Lambda_2 = [0.005, 0.05, 0.1, 2, 10, 30]
L = 40.0
z = np.array([5.0, 0.0]) # On prend z dans [-L+2*R, L-2*R]x[-L+2*R, L-2*R]

fig, ax = plt.subplots(2,3,figsize=(15,8))

for i in range(0,2):
    for j in range(0,3):
        if i == 0:
            k = j
        else :
            k = 3 + j

        lambda_2 = Lambda_2[k]

        I = np.zeros(nbsample)
```

```

for k in range(nbsample):
    N = stats.poisson.rvs(lambda_2 * (4*L**2))
    X = stats.uniform.rvs(loc=-L, scale=2*L, size=(N,2))
    Y = stats.expon.rvs(scale=1/mu, size=N)
    I[k] = np.sum(Y * boule(z - X))

I_tilde = (I - np.mean(I)) / np.sqrt(lambda_2)


x = np.linspace(min(I_tilde), max(I_tilde), 400)

ax[i,j].hist(I_tilde, bins=30, density=True, alpha=0.4, label="Histogramme")

sigma2 = EY2* np.pi*R**2
ax[i,j].plot(x, stats.norm.pdf(x, loc=0, scale=np.sqrt(sigma2)), 'r', lw=2, label="N(0, {})".format(round(sigma2)))

ax[i,j].set_xlabel(r"$\tilde{I}_\lambda(\{z\})$".format(z))
ax[i,j].set_ylabel("Densité")
ax[i,j].set_title(r"$\lambda_\lambda = \{z\}$".format(lambda_2))
ax[i,j].legend()
ax[i,j].grid(alpha=0.3)

fig.suptitle(r"Simulation de la proposition 3.1.1, en dimension 2")
fig.tight_layout()
    
```



Simulation de la convergence dans le cas où Y_1 n'admet pas de moment d'ordre 2 :

Cas de la dimension 1 :

Pour les paramètres on prends :

```

In [19]: lambda_ = 50      # intensité du processus de poisson
         L = 50           # fenêtre spatiale [-L,L]
    
```

```
z = 0.0          # point de l'évaluation
nbsample = 2000  # nombre de simulation
```

Pour les amplitudes on prend de loi de pareto de paramètre $(1, \alpha)$ avec $\alpha \in (1, 2)$:

$$Y_1 \sim \mathcal{Pa}(1, \alpha)$$

```
In [20]: alpha = 1.5          # paramètre de la loi
        EY = alpha/(alpha-1)  # Esperance

        print("Le paramètre de la loi de Pareto est", alpha)
        print("L'espérance est égale à", EY)
```

Le paramètre de la loi de Pareto est 1.5
L'espérance est égale à 3.0

Définissons la fonction réponse :

$$\ell(x) = \exp(-|x|)$$

```
In [21]: def exp(x):
        return np.exp(-np.abs(x))
```

Calcul de la quantité si $z \in [-L, L]$:

$$\lambda p \int_{-L}^L \ell(z-x) dx = 2 - \exp(-(z+L)) - \exp(-(L-z))$$

```
In [22]: def moyenne_empirique(z,L,EY,lambda_):
        int_e11 = 2 - np.exp(-(z+L)) - np.exp(-(L-z))
        moyenne_I = lambda_ * EY * int_e11
        return moyenne_I
        print(moyenne_empirique(z,L,EY,lambda_))
```

300.0

```
In [23]: Z = np.linspace(-L,L,1000)  # Liste d'évaluation de notre processus : z

        plt.figure(figsize=(15, 5))

        nbtrajectoire = 5              # Nombre de trajectoires

        for _ in range(nbtrajectoire):
            N = stats.poisson.rvs(lambda_ * (2*L))          # Nombre de points du PPP dans [-L, L]
            X = stats.uniform.rvs(loc=-L, scale=2*L, size=N)  # Position de X_n
            Y = stats.pareto.rvs(alpha, scale=1, size=N)      # Amplitudes Y_n


            I_tilde = np.zeros(len(Z))

            for i in range(len(Z)) :
                I_tilde[i] = (np.sum(Y * exp(Z[i] - X)) - moyenne_empirique(Z[i],L,EY,lambda_)) /
                (lambda_ ** (1/alpha))  # Calcul de notre processus I_lambda

            plt.plot(Z,I_tilde)          # On affiche la trajectoire

        plt.xlabel(r"$z$")
        plt.ylabel(r"$\tilde{I}_\lambda(z)$")
        plt.title(r"Simulation de $\tilde{I}_\lambda(z)$ avec $L=\{ \}$, $Y_1 \sim \mathcal{Pa}(1,\{ \})$, $\lambda = \{ \}$")
```

```
{}
```

 ".format(L,alpha,lambda_)
plt.xlim(-L+5,L+5)
plt.show()


```
In [24]: z=20
Lambda_ =[0.1,0.5,2,10,50,100]
L = 30

fig, ax = plt.subplots(2,3,figsize=(15,8))

for i in range(0,2):
    for j in range(0,3):
        if i == 0:
            k = j
        else :
            k = 3 +j

        lambda_ = Lambda_[k]
        moyenne_I = moyenne_empirique(z,L,EY,lambda_)

        I_tilde = np.zeros(nbsample)

        for k in range(nbsample):
            N = stats.poisson.rvs(lambda_ * (2*L))           # Nombre de points du PPP dans
            [-L, L]# simulation
            X = stats.uniform.rvs(loc=-L, scale=2*L,size=N)   # Position de X_n
            Y = stats.pareto.rvs(alpha, scale=1, size=N)       # Amplitudes Y_n
            I = np.sum(Y * exp(z - X))                        # Calcul de I_Lambda(z)


            I_tilde[k] = (I - moyenne_I) / (lambda_ ** (1/alpha)) # Calcul de
            \tilde{I}_Lambda(z)

        ax[i,j].hist(I_tilde, bins=500, density=True, alpha=0.4, label="Histogramme")

        # -----
        # Calcul de sigma pour la loi alpha stable
        # -----
        sigma_alpha = (gamma(2 - alpha)* np.cos(np.pi * alpha / 2)/ (alpha - 1)* (2/alpha))
        sigma = (-sigma_alpha) ** (1 / alpha)
        x= np.linspace(-10,20,1000)
        pdf = stats.levy_stable.pdf(x,alpha=1.5,beta=1,scale=sigma,loc=0.0) # simulation de la
        loi alpha stable

        ax[i,j].plot(x, pdf, '--', label="Densité théorique")
```

```
ax[i,j].set_xlabel(r"$\tilde{I}_{\lambda}(z)$".format(z))
ax[i,j].set_ylabel("Densité")
ax[i,j].set_title(r"$\lambda = {}$ ".format(lambda_))
ax[i,j].legend()
ax[i,j].grid(alpha=0.3)
ax[i,j].set_xlim(-10,20)
fig.suptitle(r"$\tilde{I}_{\lambda}(z)$ avec $L={}$, $z={}$, $Y_1 \sim Pa(1, {})$".format(L,z,alpha))
fig.tight_layout()
```



Cas de la dimension 2 :

On définit les paramètres :

```
In [25]: R = 5 # Rayon de la boule
lambda_2 = 10 # intensité du processus de poisson
L = 80 # fenêtre spatiale [-L,L] ON PREND L > R
z = np.array([0.0, 0.0]) # point de l'évaluation
nbsample = 2000 # nombre de simulation
```

Pour les amplitudes on prend de loi de pareto de paramètre $(1, \alpha)$ avec $\alpha \in (1, 2)$:

$$Y_1 \sim \mathcal{Pa}(1, \alpha)$$

```
In [26]: alpha = 1.5 # paramètre de la Loi
EY = EY = alpha/(alpha-1) # Esperance

print("Le paramètre de la loi de Pareto est", alpha)
print("L'espérance est égale à", EY)
```

Le paramètre de la loi de Pareto est 1.5
L'espérance est égale à 3.0

Définissons la fonction réponse, on prend la boule de rayon R :

$$\ell(x) = 1_{\|x\| \leq R}(x).$$

```
In [27]: def boule(x):
         return (np.linalg.norm(x, axis=1) <= R).astype(float)
```

```
In [28]: def moyenne_empirique2D(R,EY,lambda_2):
         int_ell = np.pi*R**2
         moyenne_I = lambda_2 * EY * int_ell
         return moyenne_I
```

```
In [29]: R = 5                                # Rayon de la boule
         lambda_2 = 10                        # intensité du processus de poisson
         L = 50                               # fenêtre spatiale [-L,L]

         N = stats.poisson.rvs(lambda_2 * 4*(L)**2)
         X = stats.uniform.rvs(loc=-L,scale=2*L, size=(N,2))
         Y = stats.pareto.rvs(alpha, scale=1, size=N)


         grid = np.linspace(-L+2*R, L-2*R, 200)

         I_tilde = np.zeros((len(grid), len(grid)))

         for i, x in enumerate(grid):
             for j, y in enumerate(grid):
                 z = np.array([x, y])
                 I_tilde[i, j] = (np.sum(Y * boule(z - X)) -
                                moyenne_empirique2D(R,EY,lambda_2))/(lambda_2 ** (1/alpha))

         plt.figure(figsize=(8, 8))

         plt.imshow(I_tilde,extent = [grid[0], grid[-1], grid[0],
                                     grid[-1]],origin="lower",cmap="viridis")
         plt.colorbar(label=r"$\tilde{I}_\lambda(x,y)$")
         plt.contour(I_tilde,levels=0,extent = [grid[0], grid[-1], grid[0], grid[-1]],colors="white")
         plt.xlabel("x")
         plt.ylabel("y")
         plt.title(r"Shot-Noise Fields $\tilde{I}_\lambda(x,y)$")
         plt.show()
```



```
In [30]: z=np.array([0.0, 0.0])
Lambda_ =[0.1,0.5,2,10,50,100]
L = 30

fig, ax = plt.subplots(2,3,figsize=(15,8))

for i in range(0,2):
    for j in range(0,3):
        if i == 0:
            k = j
        else :
            k= 3 +j

        lambda_2 = Lambda_[k]
        moyenne_I = moyenne_empirique(z,L,EY,lambda_2)

        I = np.zeros(nbsample)

        for k in range(nbsample):
            N = stats.poisson.rvs(lambda_2*4*(L)**2)
            X = stats.uniform.rvs(-L, 2*L,size=(N,2))
            Y = stats.pareto.rvs(alpha, scale=1, size=N)
            I[k] = np.sum(Y * boule(z - X))
```

```


I_tilde = (I - np.mean(I))/(lambda_2 ** (1/alpha))

ax[i,j].hist(I_tilde, bins=500, density=True, alpha=0.4, label="Histogramme")

# -----
# Calcul de sigma pour la loi alpha stable
# -----
sigma_alpha = (gamma(2 - alpha)* np.cos(np.pi * alpha / 2)/ (alpha - 1)* (np.pi*R**2))
sigma = (-sigma_alpha) ** (1 / alpha)
x= np.linspace(-200,200,500)
pdf = stats.levy_stable.pdf(x,alpha=alpha,beta=1,scale=sigma,loc=0.0) # simulation de
la loi alpha stable

ax[i,j].plot(x, pdf, '--', label="Densité théorique")

ax[i,j].set_xlabel(r"$\tilde{I}_{\lambda}(z)$".format(z))
ax[i,j].set_ylabel("Densité")
ax[i,j].set_title(r" $\lambda$ ={} ".format(lambda_2))
ax[i,j].legend()
ax[i,j].grid(alpha=0.3)
ax[i,j].set_xlim(-200,200)
fig.suptitle(r"$\tilde{I}_{\lambda}(z)$ avec $L={}$, $z={}$, $Y_1 \sim Pa(1, {})$".format(L,z,alpha))
fig.tight_layout()
    
```



5 Conclusion

Dans ce mémoire, j'ai avons étudié les limites d'échelle des champs de type shot-noise associés à un processus ponctuel de Poisson homogène, en mettant en évidence l'influence déterminante de la loi des amplitudes sur le comportement asymptotique du champ.

Après avoir présenté les outils fondamentaux de la théorie de la variation régulière (notamment les théorèmes de caractérisation et de représentation de Karamata, ainsi que la notion d'inverse asymptotique) j'ai avons disposé d'un cadre analytique précis pour traiter les situations à queue légère comme à queue lourde.

Deux régimes principaux sont apparus :

- ★ Lorsque les amplitudes admettent un moment d'ordre deux fini, une normalisation en $\sqrt{\lambda}$ conduit à une convergence en loi des distributions finies vers un champ gaussien centré. La covariance limite s'exprime explicitement en fonction de la fonction de réponse ℓ , traduisant un phénomène de type théorème central limite.
- ★ Lorsque la distribution des amplitudes est à variation régulière, la normalisation doit être adaptée à l'indice de variation régulière, et la limite obtenue est un champ α -stable, révélant un comportement profondément non gaussien dominé par les contributions extrêmes.

Enfin, les simulations numériques présentées confirment visuellement ces phénomènes théoriques et permettent d'illustrer concrètement la différence de structure entre les deux régimes limites.

Ce travail ouvre naturellement plusieurs perspectives. On pourrait notamment s'intéresser :

- ★ à des fonctions de réponse moins régulières ou non intégrables,
- ★ ou encore à l'étude des processus ponctuels plus généraux que le processus de Poisson homogène.

Ainsi, cette étude souligne la richesse des interactions entre processus ponctuels et analyse asymptotique, montre combien la théorie de la variation régulière constitue un outil central dans la compréhension des phénomènes à queues lourdes.

Références

- [ABUR] **T. Aburayama et N. Miyoshi**, *Scaling limits of stationary determinantal shot-noise fields*. Tokyo Institute of Technology, 11 août 2023
- [BACC] **F. Baccelli, B. Blaszczyzyn, and M. Kadhem Karray**, *Random Measures, Point Processes, and Stochastic Geometry*. 1 Juillet 2024
- [BING] **N.H. Bingham, C.M. Goldie, and J.L. Teugles**, *Regular variation*. Cambridge University Press, Cambridge, 1987
- [GARE] **O. GARET et A. KURTZMANN**, *De l'intégration aux probabilités*, Ellipses
- [KING] **J.F.C Kingman**, *Poisson processes*. University of Bristol, Oxford
- [LAST] **G. Last et M. Penrose**, *Lectures on the Poisson Process*. Cambridge University Press, Cambridge, 2017
- [LACR] **Y. LACROIX et L. MAZLIAK**, *Probabilités*, Ellipses
- [LI] **D. Li**, *Notions fondamentales d'analyse réelle et complexe : espaces de Hardy et interpolation : avec exercices corrigés*. Ellipses, 2022
- [SAMO] **G. Samorodnitsky et M.S. Taqqu**, *Stable non-gaussian random processes : stochastic models with infinite variance*. Chapman et Hall/CRC, Boca Raton, 1994
- [VIGO] **V. VIGON et L. Bois**, *Python, Poba, Stat*