

Guide de survie pour l'épreuve de modélisation



Auteur
Lilian THÉBAUD

Année universitaire 2025-2026 - M2 Mathématiques

Table des matières

1	Différents mode de convergence et les théorème Limite	3
1.1	Les modes de convergence	3
1.2	Les théorème limites	4
2	Vecteur Gaussien	4
2.1	Définition et première propriétés	4
2.2	Théorème central limite en dimension d	5
2.3	Convergence vers la loi du chi-carré	5
3	Martingale	5
3.1	Définition et première propriétés	5
3.2	Décomposition de Doob	6
3.3	Théorème d'arrêt	6
3.4	Théorème de convergence	7
4	Estimateur et intervalle de confiance	7
4.1	Estimateur	7
4.2	Exemples classiques	8
4.3	Intervalle de confiance	8
4.4	Intervalle de confiance pour la moyenne	8
4.4.1	Rappels sur les quantiles	8
4.4.2	Cas gaussien avec variance connue	9
4.4.3	Cas gaussien avec variance inconnue	9
4.4.4	Méthode asymptotique (TCL)	10
4.5	Intervalles de confiance via convergence en loi générale	10
4.6	Conclusion	10
5	Regression linéaire ou multiple	10
5.1	Les données	11
5.2	Estimation de $\hat{\beta}$	11
5.3	Décomposition de la variance et le coefficient de corrélation multiple R	13
5.4	Loi des estimateurs sous le modèle gaussien	14
5.5	Intervalles de confiance	16
6	La théorie sur les tests	16
6.1	Deux hypothèses	16
6.2	Une statistique positive	17
6.3	Le principe des 5%	17
6.4	Puissance d'un test	18
6.5	Restreindre l'ensemble des cas	18
6.6	p -valeur	18
6.7	Avec une statistique signée	19
7	Tests du χ^2 et test de Kolmogorov-Smirnov	20
7.1	Test d'adéquation du χ^2	20
7.2	Test d'indépendance du χ^2	20
7.3	Test de Kolmogorov-Smirnov	21
7.4	Interprétation	22

8	Processus de Poisson	22
8.1	Retour sur la loi exponentielle	22
8.2	Statistique d'ordre	23
8.3	Processus de Poisson	24
9	Chaîne de Markov	25
9.1	Définitions et premières propriétés	25
9.1.1	Définition d'une Chaîne de Markov	25
9.1.2	Homogénéité et Matrice de transitionHomogénéité	25
9.1.3	Loi d'une Chaîne de Markov	25
9.2	Chaîne de Markov canonique et lois marginales	25
9.2.1	Chaîne de Markov canonique	25
9.2.2	Relation de Chapman-Kolmogorov	26
9.2.3	Mesure invariante et réversibilité	26
9.3	Propriétés de Markov	26
9.3.1	Propriété de Markov faible	26
9.3.2	Propriété de Markov forte	27
9.4	Classification des états et récurrence	27
9.4.1	Structure de classe	27
9.4.2	Récurrence et Transience	27
9.4.3	Retour sur les mesures invariantes	28
9.5	Comportement asymptotique	28
9.5.1	Théorèmes ergodiques	28
9.5.2	Convergence en loi	28

1 Différents mode de convergence et les théorème Limite

1.1 Les modes de convergence

Soit $(X_n)_{n \geq 1}$ et X des variables aléatoires réelles

Définition 1.1.1 : Convergence presque surement.

On dit que la suite $(X_n)_{n \geq 1}$ converge presque surement vers X , si

$$\mathbb{P}(\{\omega \in \Omega : X(\omega) = \lim_{n \rightarrow +\infty} X_n(\omega)\}) = 1$$

Définition 1.1.2 : Convergence dans L^p .

Si $X_n \in L^p$. On dit que la suite $(X_n)_{n \geq 1}$ converge dans L^p vers X , si

$$\lim_{n \rightarrow +\infty} \mathbb{E}[|X_n - X|^p] = 0$$

Définition 1.1.3 : Convergence en probabilité.

On dit que la suite $(X_n)_{n \geq 1}$ converge en probabilité vers X , si

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0$$

Définition 1.1.4 : Convergence en loi.

On dit que la suite $(X_n)_{n \geq 1}$ converge en loi vers X , si pour tout fonction continue bornée g ,

$$\lim_{n \rightarrow +\infty} \mathbb{E}[g(X_n)] = \mathbb{E}[g(X)]$$

Théorème 1.1.5 : Théorème de Lévy.

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires réelles. La suite converge en loi vers X si et seulement si la suite des fonctions caractéristique Φ_{X_n} converge vers la fonction caractéristique de X :

$$\forall t \in \mathbb{R}, \quad \lim_{n \rightarrow +\infty} \Phi_{X_n}(t) = \Phi_X(t).$$

Théorème 1.1.6 :

Soit $(X_n)_{n \geq 1}$ et X des variables aléatoires réelles dont on note F_{X_n} et F_X les fonctions de répartition. La suite $(X_n)_{n \geq 1}$ converge en loi vers X si et seulement si pour tout point de continuité de F_X ,

$$\lim_{n \rightarrow +\infty} F_{X_n}(t) = F_X(t).$$

Proposition 1.1.7 : Lien entre les différents modes de convergence.

- ★ La convergence dans L^p implique la convergence en probabilité.
- ★ La convergence presque surement implique la convergence en probabilité.
- ★ La convergence en probabilité implique la convergence en loi. La réciproque est fausse en général sauf si elle converge vers une constante.

1.2 Les théorème limites

Théorème 1.2.1 : Loi faible des grands nombres.

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires de même loi, admettant un moment d'ordre 2 et deux à deux non corrélées. Alors

$$\lim_{n \rightarrow +\infty} \frac{1}{n} \sum_{k=1}^n X_k = \mathbb{E}[X_1] \text{ en } \mathbb{P}.$$

Théorème 1.2.2 : Loi forte des grands nombres.

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires de même loi, admettant un moment d'ordre 1 et deux à deux indépendantes. Alors

$$\lim_{n \rightarrow +\infty} \frac{1}{n} \sum_{k=1}^n X_k = \mathbb{E}[X_1] \text{ p.s.}$$

Théorème 1.2.3 : Théorème centrale limite.

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires de même loi, admettant un moment d'ordre 2 et deux à deux non corrélées. On note $\mu = \mathbb{E}[X_1]$, $\sigma^2 = \mathbb{V}[X_1]$, et la moyenne empirique

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

Alors

$$\lim_{n \rightarrow +\infty} \sqrt{n}(\bar{X}_n - \mu) = N \text{ en } \mathcal{L}$$

où $N \sim \mathcal{N}(0, \sigma^2)$.

Lemme 1.2.4 : Lemme de Slutsky.

Soient $(X_n)_{n \geq 1}$ et $(Y_n)_{n \geq 1}$ deux suites de variables aléatoires réelles, telles que $(X_n)_{n \geq 1}$ converge en loi vers une variables aléatoires X et $(Y_n)_{n \geq 1}$ converge en loi vers une variable aléatoire a constante. Alors le couple (X_n, Y_n) converge en loi vers le couple (X, a) .

On en déduit en particulier que $(X_n + Y_n)$ converge en loi vers $X + a$ et que $(X_n Y_n)$ converge en loi vers aX .

Proposition 1.2.5 : Delta-méthode.

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires réelles. Soit $(a_n)_{n \geq 1}$ une suite de réelles qui converge vers plus l'infinie. On suppose qu'il existe μ un réelles et X une variables aléatoires réelles tels que

$$\lim_{n \rightarrow +\infty} a_n(X_n - \mu) = X \text{ en } \mathcal{L}.$$

Soit g une fonction C^1 au voisinage de μ . Alors

$$\lim_{n \rightarrow +\infty} a_n(g(X_n) - g(\mu)) = g'(\mu)X \text{ en } \mathcal{L}.$$

2 Vecteur Gaussien

2.1 Définition et première propriétés

Définition 2.1.1 :

On dit qu'un vecteur aléatoire $X \in \mathbb{R}^d$ est gaussien si pour tout $a \in \mathbb{R}^d$ la variable aléatoire $\langle X, a \rangle$ est gaussienne.

Proposition 2.1.2 :

L'image d'un vecteur gaussien X d'espérance m_X et de matrice de covariance C_X par une application affine $x \mapsto Ax + b$ est un vecteur gaussien d'espérance $m_Y = Am_X + b$ et de matrice de covariance $C_Y = AC_X A^t$

Théorème 2.1.3 :

Si un vecteur gaussien $X = (X_1, \dots, X_n)$ a une matrice de covariance dont tous les termes non-diagonaux sont nuls, alors $X_1, \dots, X_n$ sont des variables aléatoires indépendantes.

2.2 Théorème central limite en dimension d

Théorème 2.2.1 : Théorème central limite en dimension d .

Soit (X_n) une suite de vecteur aléatoires à valeurs dans $\mathbb{R}^d$, indépendants et identiquement distribués de carrée intégrable. On note m l'espérance et C la matrice de covariance. Alors

$$\lim_{n \rightarrow +\infty} \frac{X_1 + \dots + X_n - nm}{\sqrt{n}} = N \text{ en loi,}$$

où $N \sim \mathcal{N}(0, C)$.

2.3 Convergence vers la loi du chi-carré

Proposition 2.3.1 :

Soit X un vecteur gaussien dans $\mathbb{R}^n$ de loi $\mathcal{N}(0, I_n)$. Alors la loi de $\|X\|_2^2$ est une loi à densité. On l'appelle loi du chi-deux à n degrés de liberté et on la note $\chi^2(n)$.

Théorème 2.3.2 : Théorème de Cochran.

Soit $(X_1, \dots, X_n)$ un vecteur gaussien centré réduit. Pour F un sous-espace vectoriel de $\mathbb{R}^n$ de dimension p , on note p_F (resp. $p_{F^\perp}$) la projection orthogonal sur F (resp. $F^\perp$). Alors les vecteurs aléatoires $p_F(X)$ et $p_{F^\perp}(X)$ sont gaussiens indépendants, $p_F(X)$ suit la loi $\mathcal{N}(0, p_F)$ et $p_{F^\perp}(X)$ suit la loi $\mathcal{N}(0, p_{F^\perp})$. De plus, les variables aléatoires $\|p_F(X)\|_2^2$ et $\|p_{F^\perp}(X)\|_2^2$ sont indépendantes, $\|p_F(X)\|_2^2$ suit la loi $\chi^2(p)$ et $\|p_{F^\perp}(X)\|_2^2$ suit la loi $\chi^2(n - p)$

Théorème 2.3.3 : Convergence vers la loi du chi-deux.

Soit ν une loi sur $\{1, \dots, q\}$, (X_n) une suite de variables aléatoires indépendantes de loi ν . On note N_j^n le nombre de variables aléatoires X_i parmi $X_1, \dots, X_n$ qui sont égales à j et on pose

$$T_n := \sum_{j=1}^q \frac{N_j^n - n\nu_j}{n\nu_j}.$$

Alors

$$\lim_{n \rightarrow +\infty} T_n = T \text{ en loi}$$

où $T \sim \chi^2(q - 1)$

3 Martingale

On munit $(\Omega, \mathcal{A}, \mathbb{P})$ d'une filtration $\mathcal{F} = (\mathcal{F}_n)$.

3.1 Définition et première propriétés

Définition 3.1.1 :

Une suite (X_n) de variable aléatoires est dit adaptée à $\mathcal{F}$ si pour tout $n \geq 0$, X_n est $\mathcal{F}_n$ mesurable.

Définition 3.1.2 :

Soit (X_n) une suite de variables aléatoires réelles.

1. (X_n) est une martingale (MG), si pour tout $n \geq 0$, X_n est intégrable et

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] = X_n \text{ p.s.}$$

2. (X_n) est une sous-martingale (sMG), si pour tout $n \geq 0$, X_n est intégrable (plus faible X_n^+ intégrable) et

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] \geq X_n \text{ p.s.}$$

3. (X_n) est une surmartingale (SMG), si pour tout $n \geq 0$, X_n est intégrable (plus faible X_n^- intégrable) et

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] \leq X_n \text{ p.s.}$$

Proposition 3.1.3 :

Si (X_n) est une martingale (resp, une surmartingale, une sous-martingale), la suite $(\mathbb{E}[X_n])$ est constante (resp. décroissante, croissante).

Proposition 3.1.4 :

Si (X_n) est une martingale (resp, une surmartingale, une sous-martingale), on a pour $m < n$,

$$\mathbb{E}[X_n|\mathcal{F}_m] = X_m \text{ p.s. (resp. } \leq, \geq)$$

Proposition 3.1.5 :

Si (X_n) est une martingale et f est une fonction convexe réelle telle que $f(X_n)$ est intégrable pour tout $n \geq 0$ alors $Y_n = f(X_n)$ est une sous-martingale. En particulier si (X_n) est une martingale alors $(|X_n|)$ et (X_n^2) sont des sous-martingales.

3.2 Décomposition de Doob

Définition 3.2.1 :

On dit d'une suite de variable aléatoires (A_n) est un processus croissant prévisible si $A_0 = 0$, $A_n \geq A_{n+1}$ et pour tout $n \geq 1$, A_n est $\mathcal{F}_{n-1}$ mesurable.

Théorème 3.2.2 : Décomposition de Doob.

Soit (X_n) est une sur-martingale. Alors, elle se décompose de manière unique sous la forme

$$X_n = M_n + A_n$$

où (M_n) est une martingale et (A_n) est un processus croissant prévisible et intégrable, appelé le compensateur de (X_n)

3.3 Théorème d'arrêt

Proposition 3.3.1 :

Soit (X_n) une martingale (resp, une surmartingale, une sous-martingale) et soit T un temps d'arrêt adapté à $\mathcal{F}$. Alors, le processus arrêté $(X_{\min(n,T)})$ est également une martingale (resp, une surmartingale, une sous-martingale).

Théorème 3.3.2 :

Soient une martingale (resp, une surmartingale, une sous-martingale) intégrable ou positive et S et T deux temps d'arrêt bornés avec $S \leq T$; alors on a

$$\mathbb{E}[X_T|\mathcal{F}_S] = X_S \text{ p.s (resp. } \leq, \geq)$$

3.4 Théorème de convergence

Théorème 3.4.1 :

Soit (X_n) une martingale de carré intégrable tels que

$$\sup_{n \geq 0} \mathbb{E}[X_n^2] < +\infty.$$

Alors, il existe $X_\infty \in L^2$ tels que

$$\lim_{n \rightarrow +\infty} X_n = X_\infty \text{ dans } L^2 \text{ et p.s.}$$

De plus pour tout $n \in \mathbb{N}$

$$X_n = \mathbb{E}[X_\infty | \mathcal{F}_n] \text{ p.s.}$$

Remarque 3.4.2 :

On a le même résultat si (X_n) est une martingale bornée dans L^p $p > 1$.

Proposition 3.4.3 :

Soit (X_n) une martingale tels qu'il existe $X_\infty \in L^1$ et

$$\lim_{n \rightarrow +\infty} X_n = X_\infty \text{ dans } L^1.$$

Alors

$$\lim_{n \rightarrow +\infty} X_n = X_\infty \text{ p.s.}$$

Théorème 3.4.4 :

Soit (X_n) une sous/sur-martingale bornée dans L^1 . Alors (X_n) converge presque sûrement.

Corollaire 3.4.5 :

Si (X_n) est une surmartingale positive, alors (X_n) converge presque sûrement.

4 Estimateur et intervalle de confiance

4.1 Estimateur

Définition 4.1.1 :

Soit $(X_1, \dots, X_n)$ un échantillon de variables aléatoires de loi dépendant d'un paramètre $\theta \in \Theta$.

Un **estimateur** de θ est une variable aléatoire $\hat{\theta} = T(X_1, \dots, X_n)$.

Définition 4.1.2 : Biais.

Le biais de $\hat{\theta}$ est défini par :

$$\text{Biais}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta.$$

On dit que $\hat{\theta}$ est **sans biais** si $\mathbb{E}[\hat{\theta}] = \theta$.

Définition 4.1.3 : Variance.

La variance de l'estimateur est :

$$\mathbb{V}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2].$$

Définition 4.1.4 : Risque quadratique.

Le risque quadratique est :

$$R(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \mathbb{V}(\hat{\theta}) + \text{Biais}(\hat{\theta})^2.$$

Définition 4.1.5 : Consistance.

Un estimateur $\hat{\theta}_n$ est **consistant** si :

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta.$$

et **fortement consistant** si

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{p.s.} \theta.$$

4.2 Exemples classiques

★ Moyenne empirique :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

est un estimateur sans biais de $\mathbb{E}[X_1]$.

★ Variance empirique :

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

est un estimateur sans biais de $\mathbb{V}(X_1)$. En revanche

$$S_n'^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

est un estimateur biaisé de la variance de $\mathbb{V}[X_1]$

Ces deux estimateurs de la moyenne et de la variance sont fortement consistants (on utilise la loi forte des grands nombres pour montrer ce résultat).

4.3 Intervalle de confiance

Définition 4.3.1 :

Un **intervalle de confiance** au niveau $1 - \alpha$ pour θ est un intervalle aléatoire I_n tel que :

$$\mathbb{P}(\theta \in I_n) = 1 - \alpha.$$

4.4 Intervalle de confiance pour la moyenne

4.4.1 Rappels sur les quantiles

Définition 4.4.1 :

Soit $Z \sim \mathcal{N}(0, 1)$. On note $z_{1-\alpha/2}$ le quantile d'ordre $1 - \alpha/2$, c'est-à-dire :

$$\mathbb{P}(Z \leq z_{1-\alpha/2}) = 1 - \alpha/2.$$

Ainsi :

$$\mathbb{P}(-z_{1-\alpha/2} \leq Z \leq z_{1-\alpha/2}) = 1 - \alpha.$$

Définition 4.4.2 : Loi de Student.

Soit $Z \sim \mathcal{N}(0, 1)$ et $U \sim \chi^2(q)$ indépendantes. La variable

$$T = \frac{Z}{\sqrt{U/q}}$$

suit une **loi de Student** à q degrés de liberté, notée t_q .

On note $t_q(1 - \alpha/2)$ son quantile d'ordre $1 - \alpha/2$:

$$\mathbb{P}(T \leq t_q(1 - \alpha/2)) = 1 - \alpha/2.$$

Remarque 4.4.3 :

La loi de Student a des queues plus épaisses que la loi normale. On a :

$$t_q(1 - \alpha/2) \xrightarrow{q \rightarrow \infty} z_{1-\alpha/2}.$$

4.4.2 Cas gaussien avec variance connue

Soit $(X_1, \dots, X_n)$ un échantillon i.i.d. de loi $\mathcal{N}(\mu, \sigma^2)$ avec σ^2 connue.

On a :

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

Ainsi :

$$\mathbb{P}\left(-z_{1-\alpha/2} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{1-\alpha/2}\right) = 1 - \alpha.$$

Donc un intervalle de confiance est :

$$\mu \in \left[\bar{X}_n - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X}_n + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

avec probabilité $1 - \alpha$.

4.4.3 Cas gaussien avec variance inconnue

On pose :

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

Alors :

$$\frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} \sim t_{n-1}.$$

Donc :

$$\mathbb{P}\left(-t_{n-1}(1 - \alpha/2) \leq \frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} \leq t_{n-1}(1 - \alpha/2)\right) = 1 - \alpha.$$

On obtient l'intervalle de confiance :

$$\mu \in \left[\bar{X}_n - t_{n-1}(1 - \alpha/2) \frac{S_n}{\sqrt{n}}, \bar{X}_n + t_{n-1}(1 - \alpha/2) \frac{S_n}{\sqrt{n}} \right].$$

Remarque 4.4.4 :

On remplace σ inconnu par S_n , ce qui introduit une incertitude supplémentaire : $\rightarrow$ on utilise donc la loi de Student (plus large que la normale).

4.4.4 Méthode asymptotique (TCL)

Si :

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2),$$

alors pour n grand :

$$\frac{\hat{\theta}_n - \theta}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1).$$

Donc un intervalle de confiance asymptotique est :

$$\theta \in \left[\hat{\theta}_n - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \hat{\theta}_n + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

Remarque 4.4.5 :

En pratique, σ est remplacé par un estimateur $\hat{\sigma}$ pour cela on utilise le lemme de Slutsky.

4.5 Intervalles de confiance via convergence en loi générale

Dans certains cas, on dispose d'un estimateur $\hat{\theta}_n$ tel que :

$$T_n = a_n(\hat{\theta}_n - \theta) \xrightarrow{\mathcal{L}} T,$$

où T est une variable aléatoire de loi connue (pas nécessairement gaussienne).

Soit $q_{1-\alpha/2}$ et $q_{\alpha/2}$ les quantiles de la loi de T , c'est-à-dire :

$$\mathbb{P}(T \leq q_{1-\alpha/2}) = 1 - \alpha/2, \quad \mathbb{P}(T \leq q_{\alpha/2}) = \alpha/2.$$

Alors, pour n grand :

$$\mathbb{P}(q_{\alpha/2} \leq T_n \leq q_{1-\alpha/2}) \approx 1 - \alpha.$$

Donc :

$$\mathbb{P}\left(q_{\alpha/2} \leq a_n(\hat{\theta}_n - \theta) \leq q_{1-\alpha/2}\right) \approx 1 - \alpha.$$

En inversant :

$$\theta \in \left[\hat{\theta}_n - \frac{q_{1-\alpha/2}}{a_n}, \hat{\theta}_n - \frac{q_{\alpha/2}}{a_n} \right].$$

4.6 Conclusion

La construction d'intervalles de confiance repose uniquement sur :

- ★ une convergence en loi,
- ★ la connaissance (ou l'approximation) des quantiles de la loi limite.

La normalité n'est donc pas nécessaire, mais elle est souvent utilisée car :

- ★ elle apparaît naturellement (TCL),
- ★ ses quantiles sont bien tabulés.

5 Regression linéaire ou multiple

Dans cette partie nous faisons les preuves car cela pourrait bien être utile pour l'épreuve.

5.1 Les données

Les données consistent en des variables observées Y_i et des variables explicatives (ou régresseurs) x_i , $i = 1, \dots, n$, chaque paire (Y_i, x_i) représentant une expérience. On les arrange dans un tableau de la façon suivante :

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad X = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} 1 & x_{12} & \dots & x_{1p} \\ \vdots & & & \vdots \\ 1 & x_{n2} & \dots & x_{np} \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} \quad \text{et} \quad 1_n = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

x_i est donc un vecteur ligne. On notera $x_{.j}$ la j -ième colonne. On convient généralement que le premier régresseur est la constante, mais ce n'est pas obligatoire. Le modèle s'exprime sous la forme :

$$Y_i = x_i \beta + u_i = \beta_1 + \sum_{j=2}^p x_{ij} \beta_j + u_i, \quad i = 1, \dots, n.$$

où les u_i sont des variables aléatoire quelconque qui représente l'erreur de notre modèle.

Ce qui se réécrit de manière plus compacte :

$$Y = X\beta + u, \tag{5.1.1}$$

et la prédiction linéaire de Y_i par x_i est :

$$\hat{Y}_i = x_i \beta, \quad \text{où} \quad \hat{Y} = X\beta.$$

Remarquer que $X\beta$ n'est autre que la combinaison linéaire des colonnes de X avec les coefficients $\beta_1, \dots, \beta_p$. Le modèle linéaire gaussien se réécrit simplement :

$$Y \sim \mathcal{N}(X\beta, \sigma^2 Id).$$

La forme 5.1.1 est le modèle général. On suppose toujours le vecteur u centré de variance finie.

5.2 Estimation de $\hat{\beta}$

Définition 5.2.1 :

Pour tout β , on définit l'erreur quadratique moyenne d'ajustement (ou erreur résiduelle) $S(\beta)$ comme

$$S(\beta) = \frac{1}{n} \|y - X\beta\|^2 = \frac{1}{n} \sum_{i=1}^n (y_i - x_i \beta)^2.$$

Le vecteur des coefficients de régression calculés aux moindres carrés ordinaires est

$$\hat{\beta} = \arg \min_{\beta} S(\beta)$$

Proposition 5.2.2 :

On suppose la matrice $X^T X$ inversible. Alors $\hat{\beta}$ est donnée par

$$\hat{\beta} = (X^T X)^{-1} X^T Y.$$

Démonstration de la proposition 5.2.2. On a

- ★ la fonction que à $\beta \mapsto y_i - x_i\beta$ est affine donc convexe
- ★ Le fonction carrée est strictement convexe.

Ainsi, S est une fonction strictement convexe et de plus S est de classe C^∞ .

On peut donc calculer ses dérivées partielles : soit $j \in \{0, \dots, n\}$

$$\frac{\partial S}{\partial \beta_j}(\beta) = \frac{1}{n} \sum_{i=1}^n 2x_{ij}(y_i - x_i\beta) = \frac{2}{n}(X^T(y - X\beta))_j.$$

Ainsi, β^* est un point critique de S si

$$X^T(y - X\beta^*) = 0 \iff X^T y - X^T X\beta^* = 0 \iff \beta^* = (X^T X)^{-1} X^T y$$

car la matrice $X^T X$ est inversible. Par conséquent $\hat{\beta}$ est donnée en remplaçant l'observation y par le vecteur aléatoire Y c'est-à-dire :

$$\hat{\beta} = (X^T X)^{-1} X^T Y.$$

□

Proposition 5.2.3 :

On suppose que les u_i sont centrés décorrélés et de variance σ^2 . Alors, $\hat{\beta}$ est un estimateur non biaisé de β et sa matrice de covariance est donnée par $(X^T X)^{-1}$.

Démonstration de la proposition 5.2.3. D'après la proposition 5.2.2 on a :

$$\hat{\beta} = (X^T X)^{-1} X^T Y.$$

Ainsi,

$$\mathbb{E}[\hat{\beta}] = \mathbb{E}[(X^T X)^{-1} X^T Y] = (X^T X)^{-1} X^T \mathbb{E}[Y].$$

Or, d'après la formule 5.1.1

$$\mathbb{E}[Y] = X\beta + \mathbb{E}[u] = X\beta$$

Donc,

$$\mathbb{E}[\hat{\beta}] = (X^T X)^{-1} X^T X\beta = \beta.$$

On note $\text{Cov}(\hat{\beta})$ la matrice de covariance de $\hat{\beta}$. Pour la variance on procède de la même manière :

$$\text{Cov}(\hat{\beta}) = \text{Cov}((X^T X)^{-1} X^T Y) = (X^T X)^{-1} X^T \text{Cov}(u) ((X^T X)^{-1} X^T)^T = \sigma^2 (X^T X)^{-1}.$$

□

Définition 5.2.4 :

- ★ Vecteur des valeurs ajustées (ou prédites) :

$$\hat{Y} = X\hat{\beta}, \quad \text{soit} \quad \hat{Y}_i = x_i\hat{\beta}.$$

- ★ Vecteur des résidus :

$$\hat{u} = Y - \hat{Y} = Y - X\hat{\beta}, \quad \text{soit} \quad u_i = Y_i - x_i\hat{\beta}.$$

Dans tout la suite on supposera la matrice $X^T X$ inversible.

5.3 Décomposition de la variance et le coefficient de corrélation multiple R

On va voir que le vecteur $\hat{u}$ est orthogonal aux colonnes de X , ce qui a des conséquences importantes. On suppose ici que la première colonne de X est constituée de 1. On notera la variance empirique de la fa₃con suivante : si $v = (v_1, \dots, v_n)$ est un vecteur de données,

$$\bar{v} = \frac{1}{n} \sum_{i=1}^n v_i \quad s_v^2 = \frac{1}{n} \sum_{i=1}^n v_i^2 - \bar{v}^2$$

Proposition 5.3.1 :

On a :

$$\hat{u} \perp x_{.j}, \quad j = 1, \dots, p \quad \text{et} \quad s_Y^2 = s_{\hat{Y}}^2 + s_{\hat{u}}^2$$

La variabilité des données se décompose donc en la somme de deux termes, le premier ne dépendant que des variables explicatives et un deuxième terme étant la variabilité de ce que l'on ne peut expliquer. En d'autres termes, la connaissance du modèle et son estimation fait que l'incertitude sur Y , qui est représentée par s_Y , ne se réduit plus, pour quelqu'un qui a accès aux variables explicatives, qu'à $s_{\hat{u}}$.

Cette interprétation doit être pondérée par le fait que ces quantités ne sont que des estimées des variabilités d'intérêt.

Démonstration de la proposition 5.3.1. Commençons par démontrer l'orthogonalité. Il suffit pour cela de voir que $X^T \hat{u} = 0$.

$$\begin{aligned} X^T \hat{u} &= X^T (Y - \hat{y}) \text{ par la définition 5.2.4} \\ &= X^T Y - X^T X \hat{\beta} \\ &= X^T Y - X^T X (X^T X)^{-1} X^T Y \\ &= X^T Y - X^T X Y \\ X^T \hat{u} &= 0 \end{aligned}$$

Pour la deuxième affirmation, rappelons que

$$Y = \hat{Y} + \hat{u}.$$

Mais l'orthogonalité de $\hat{u}$ au vecteur $\mathbf{1}$ (c'est-à-dire $x_{.1}$ implique que

$$\bar{\hat{u}} = \frac{1}{n} \sum_{i=1}^n 1 \times u_i = 0,$$

et donc

$$\bar{Y} = \bar{\hat{Y}} + \bar{\hat{u}} = \bar{\hat{Y}}.$$

D'où

$$Y - \bar{Y}1_n = (\hat{Y} - \bar{\hat{Y}}1_n) + \hat{u}.$$

Le fait que $\hat{Y} - \bar{\hat{Y}}1_n$ est combinaison linéaire des colonnes de X et que $\hat{u}$ est orthogonal à ces dernières implique que l'on peut appliquer le théorème de Pythagore, ce qui conduit à

$$\|Y - \bar{Y}1_n\|^2 = \|\hat{Y} - \bar{\hat{Y}}1_n\|^2 + \|\hat{u}\|^2$$

Or,

$$s_Y^2 = \frac{1}{n} \|Y - \bar{Y}1_n\|^2 \quad s_{\hat{Y}}^2 = \frac{1}{n} \|\hat{Y} - \bar{\hat{Y}}1_n\|^2$$

et comme $\bar{\hat{u}} = 0$, on a

$$s_{\hat{u}}^2 = \frac{1}{n} \|\hat{u} - \bar{\hat{u}}1_n\|^2 = \frac{1}{n} \|\hat{u}\|^2.$$

Ainsi,

$$s_Y^2 = s_{\hat{Y}}^2 + s_{\hat{u}}^2.$$

□

Définition 5.3.2 :

On définit le coefficient de détermination R^2 est le rapport de la "variance expliquée" par la "variance totale" :

$$R = \frac{s_{\hat{Y}}}{s_Y}, \quad R^2 = \frac{s_{\hat{Y}}^2}{s_Y^2} = \frac{s_Y^2 - s_{\hat{u}}^2}{s_Y^2} = 1 - \frac{s_{\hat{u}}^2}{s_Y^2}.$$

Plus R est proche de 1, plus le modèle est adéquat sur les données. R^2 est donc une mesure de comparaison entre la prédiction par le modèle et la prédiction par une constante, via les erreurs d'ajustement.

5.4 Loi des estimateurs sous le modèle gaussien

Rappelons que la covariance de deux vecteurs aléatoires U et V est la matrice formée des covariances $\text{Cov}(U_i, V_j)$, soit :

$$\text{Cov}(U, V) = E[UV^T] - E[U]E[V]^T$$

Rappelons également quelques propriétés de base des vecteurs gaussiens :

Proposition 5.4.1 :

Soit $X_1, \dots, X_n$ une suite indépendante de variables aléatoires gaussiennes, alors $X = (X_1, \dots, X_n)$ est un vecteur gaussien.

- ★ Pour toute matrice A et tout vecteur m de taille adéquate, la variable $AX + m$ est encore un vecteur gaussien.
- ★ Si X est un vecteur gaussien et A et B deux matrices de tailles adéquates, alors si AX et BX sont décorrélés, ils sont indépendants.

Proposition 5.4.2 :

Sous l'hypothèse que $Y \sim \mathcal{N}(X\beta, \sigma^2 Id)$, l'estimateur $\hat{\beta}$ suit la loi $\mathcal{N}(\beta, (X^T X)^{-1} \sigma^2)$. De plus,

$$\hat{\sigma}^2 = \frac{1}{n-p} \sum_{i=1}^n \hat{u}_i^2$$

est un estimateur non biaisé de σ^2 ;

$$(n-p) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p}^2$$

et est indépendant de $\hat{\beta}$.

Démonstration de la proposition 5.4.2. Montrons la loi de β : On a

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Comme $Y \sim \mathcal{N}(X\beta, \sigma^2 Id)$, on a $\hat{\beta}$ est un vecteur gaussien (proposition 5.4.1) et par la proposition 5.2.3 on obtient,

$$\mathbb{E}[\hat{\beta}] = \beta \quad \text{et} \quad \text{Cov}(\hat{\beta}) = \sigma^2(X^T X)^{-1}.$$

Ainsi on a le résultat voulue :

$$\hat{\beta} \sim \mathcal{N}(\beta, (X^T X)^{-1} \sigma^2)$$

Montrons que $\hat{\sigma}^2$ est un estimateur non biaisé de σ^2 .

Soit $\mathcal{G}$ le sous espace vectoriel de $\mathbb{R}^n$ engendré par les colonnes de la matrice X . On a $\dim \mathcal{G} = p$ car la matrice $X^T X$ est inversible. De plus

$$\mathcal{G} = \{Xu, u \in \mathbb{R}^p\}.$$

On a

$$\min_{z \in \mathcal{G}} \|Y - z\|^2 = \min_{u \in \mathbb{R}^p} \|Y - Xu\|^2.$$

Ainsi en utilisant la proposition 5.2.2, on obtient que la projection orthogonal de Y sur $\mathcal{G}$ est

$$\pi_{\mathcal{G}}(Y) = X\hat{\beta} = X(X^T X)^{-1} X^T Y.$$

Posons $P = X(X^T X)^{-1} X^T$ ainsi P est la matrice de la projection orthogonale de Y sur $\mathcal{G}$ De plus

$$\pi_{\mathcal{G}^\perp}(Y) = Y - \pi_{\mathcal{G}}(Y) = Y - X\hat{\beta} = (I - P)Y.$$

Posons

$$Z = \frac{Y - X\beta}{\sigma}$$

Comme $Y \sim \mathcal{N}(X\beta, \sigma^2 Id)$ on a donc $Z \sim \mathcal{N}(0, Id)$.

Ainsi par le théorème de Cochran

$$\pi_{\mathcal{G}^\perp}(Z) \text{ indépendant de } \pi_{\mathcal{G}}(Z)$$

et

$$\|\pi_{\mathcal{G}^\perp}(Z)\|^2 \sim \chi^2(\dim \mathcal{G}^\perp), \quad \|\pi_{\mathcal{G}}(Z)\|^2 \sim \chi^2(\dim \mathcal{G})$$

On en déduit :

$$\pi_{\mathcal{G}^\perp}(Y) \text{ indépendant de } \pi_{\mathcal{G}}(Y).$$

Comme $X\beta \in \mathcal{G}$ on a donc

$$\pi_{\mathcal{G}^\perp}(Z) = \frac{1}{\sigma} \pi_{\mathcal{G}^\perp}(Y).$$

Ainsi,

$$\|\pi_{\mathcal{G}^\perp}(Y)\|^2 = \|\hat{u}\|^2 = \sum_{i=1}^n \hat{u}_i.$$

De plus, en posant $Q = I - P$ et comme $Y = X\beta + u$ on a

$$\begin{aligned} \mathbb{E}[\|\hat{u}\|^2] &= \mathbb{E}[\|QY\|^2] = \mathbb{E}[\|Qu\|^2] = \mathbb{E}[\text{Tr}(\|Qu\|^2)] = \mathbb{E}[\text{Tr}(Quu^T Q^T)] \\ &= \text{Tr}(Q\mathbb{E}[uu^T]Q^T) \\ &= \sigma^2 \text{Tr}(QQ^T) \\ &= \sigma^2 \text{Tr}(Q) \end{aligned}$$

$$= \sigma^2 \dim \mathcal{G}^\perp$$

$$\mathbb{E}[\|\hat{u}\|^2] = \sigma^2(n-p)$$

Par conséquent, on obtient que

$$\hat{\sigma}^2 = \frac{1}{n-p} \sum_{i=1}^n \hat{u}_i^2$$

est un estimateur non biaisé de σ^2 ;

$$(n-p) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p}^2$$

et est indépendant de $\hat{\beta}$ (pour l'indépendance on utilise que $\hat{\beta} = (X^T X)^{-1} X^T \pi_{\mathcal{G}}(Y)$ et $\pi_{\mathcal{G}^\perp}(Y)$ indépendant de $\pi_{\mathcal{G}}(Y)$) $\square$

5.5 Intervalles de confiance

Rappelons que la loi de Student de paramètre q est celle du rapport d'une gaussienne standard par une racine de χ_q^2 . On désignera par t_q sa fonction quantile.

La loi donnée pour $(\hat{\beta}, \hat{\sigma}^2)$ implique qu'en posant $\hat{\sigma}_j^2 = \hat{\sigma}^2((X^T X)^{-1})_{jj}$:

$$\frac{\hat{\beta}_j - \beta_j^*}{\hat{\sigma}_j} = \frac{\hat{\beta}_j - \beta_j^*}{\sigma((X^T X)^{-1})_{jj}^{1/2}} \frac{\sigma}{\hat{\sigma}} \sim \text{Student}(n-p).$$

Cette variable aléatoire appartient donc avec probabilité $1 - \alpha$ à l'intervalle

$$[-t_{n-p}(1 - \alpha/2), t_{n-p}(1 - \alpha/2)]$$

et par conséquent on a l'intervalle de confiance :

$$\beta_j \in [\hat{\beta}_j - \delta, \hat{\beta}_j + \delta], \quad \delta = \hat{\sigma}_j t_{n-p}(1 - \alpha/2) \text{ avec probabilité de confiance } 1 - \alpha.$$

Si 0 est en dehors de l'intervalle de confiance, on dit que $\hat{\beta}_j$ est significativement non-nul au niveau de confiance α .

6 La théorie sur les tests

6.1 Deux hypothèses

Nous sommes en présence de deux hypothèses : H_0 et son contraire H_1 .

Exemple 1 : on suppose que les éléphants d'Afrique ont une espérance de vie de 56 ans.

- H_0 : les éléphants d'une réserve ont une espérance de vie de 56 ans.
- H_1 : les éléphants d'une réserve n'ont pas une espérance de vie de 56 ans.

Exemple 2 :

- ★ H_0 : l'échantillon observé a une distribution gaussienne.
- ★ H_1 : l'échantillon observé n'a pas une distribution gaussienne.

Exemple 3 :

- ★ H_0 : Le QI et le sexe sont indépendants.
- ★ H_1 : Le QI et le sexe ne sont pas indépendantes.

Notez que les deux hypothèses ne sont pas interchangeables :

- ★ H_0 est une hypothèse "précise",
- ★ H_1 est une hypothèse "vague".

L'une des deux hypothèses est vraie. On dira :

- ★ "sous $H_0 \dots$ " pour dire qu'on se place dans le cas où H_0 est vraie.
- ★ "sous $H_1 \dots$ " pour l'autre alternative.

Mais en fait, nous allons devoir parier sur laquelle des hypothèses est la bonne à partir de l'observation d'un échantillon $X_0, X_1, \dots, X_i, \dots$ (ex : des durées de vie d'éléphants de réserve). On va élaborer une règle de décision et on dira

- ★ $\{H_0 \text{ choisie}\}$ pour dire qu'on parie sur H_0
- ★ $\{H_1 \text{ choisie}\}$ pour dire qu'on parie sur H_1

Attention : Nous en sommes au stade de la modélisation : pour l'instant, notre échantillon n'est pas une suite de nombres, mais une suite de variables aléatoires qui ont toutes la même loi. Naturellement, cette loi n'est pas la même sous H_0 et sous H_1 .

6.2 Une statistique positive

Nous construisons une "statistique" positive $D = D(X_0, X_1, \dots)$ qui vérifie :

- ★ sous H_0 , D est petit.
- ★ sous H_1 , D est grand.

On se fixe ensuite une règle de décision pour quand l'échantillon sera observé. Quand on aura $X_0 = x_0, X_1 = x_1, \dots$, on calculera $D = D(x_0, x_1, \dots)$ et :

- ★ $D \leq \text{seuil} \Rightarrow \{H_0 \text{ choisie}\}$
- ★ $D > \text{seuil} \Rightarrow \{H_1 \text{ choisie}\}$

Mais comment déterminer le seuil ? En fait, en construisant D , on doit s'arranger pour avoir :

- ★ sous H_0 , la statistique D suit une loi de fonction de répartition F bien connue (ex : χ_2).
- ★ sous H_1 , la statistique D a une forte probabilité d'être très grande.

Dans la suite, on va utiliser la connaissance précise de la loi de D sous H_0 pour déterminer le seuil.

6.3 Le principe des 5%

La règle des tests est que :

"sous H_0 , l'évènement $\{H_1 \text{ choisie}\}$ doit être peu probable"

On se fixe un α petit, c'est le niveau du test. En général on prend $5\% = 0.05$. On souhaite que, sous H_0 , la probabilité de choisir H_1 soit de α . Ainsi, sous H_0 :

$$\begin{aligned} \mathbb{P}[\{H_1 \text{ choisi}\}] &= \mathbb{P}[D > \text{seuil}] = \alpha \\ &\Leftrightarrow \mathbb{P}[D \leq \text{seuil}] = 1 - \alpha \\ &\Leftrightarrow F(\text{seuil}) = 1 - \alpha \\ &\Leftrightarrow \text{seuil} = F^{-1}(1 - \alpha) \end{aligned}$$

Donc en résumé :

- ★ $D \leq F^{-1}(1 - \alpha) \Rightarrow \{H_0 \text{ choisie}\}$
- ★ $D > F^{-1}(1 - \alpha) \Rightarrow \{H_1 \text{ choisie}\}$

6.4 Puissance d'un test

Pour construire le test, on aurait pu se baser sur la règle symétrique à la précédente :

“sous H_1 , l'évènement $\{H_0 \text{ choisie}\}$ doit être **peu probable**”

Mais c'est beaucoup plus dur car, H_1 étant une hypothèse vague, on connaît mal la loi de la statistique D sous H_1 .

Cependant, on dit qu'un test a la puissance β lorsque, sous H_1 , la probabilité de $\{H_1 \text{ choisie}\}$ est toujours plus grande que β . Par exemple, un test de niveau 5% et de puissance 1 est quasi parfait :

- ★ Sous H_1 , il ne se trompe jamais.
- ★ Sous H_0 , ils ne se trompe que dans 5% des cas.

Il est parfois très difficile de déterminer la puissance d'un test, mais tous les tests “simples” que nous allons rencontrer par la suite ont une puissance proche de 1 quand la taille de l'échantillon est grande.

Remarque : Un test de puissance 0 serait très dangereux : cela signifie que, dans certains cas, sous H_1 on choisit H_0 avec proba 1 !

6.5 Restreindre l'ensemble des cas

Parfois H_1 est contraire de H_0 mais “dans un contexte donné”. Par exemple on peut supposer que les éléphants d'une réserve vivent au moins aussi vieux que ceux qui vivent à l'extérieur. Toujours en supposant que les éléphants d'Afrique ont une espérance de vie de 56 ans, le test devient :

- ★ H_0 : les éléphants d'une réserve ont une espérance de vie de 56 ans (comme tous les autres).
- ★ H_1 : les éléphants d'une réserve ont une espérance de vie de plus de 56 ans.

Ce que cela change ? Cela augmente la puissance du test bien sûr. Nous verrons à la fin l'exemple du test de Mann-whitney où l'on est obligé de réduire H_1 , sinon le test a une puissance dérisoire (et donc il est dangereux).

6.6 p -valeur

Mais l'histoire ne s'arrête pas là, car on aimerait avoir un critère quantitatif pour dire si on choisit H_1 franchement, ou du bout des lèvres. On a :

$$\begin{aligned} \{H_1 \text{ choisie}\} &\Leftrightarrow D > F^{-1}(1 - \alpha) \\ &\Leftrightarrow F(D) > 1 - \alpha \\ &\Leftrightarrow 1 - F(D) \leq \alpha \end{aligned}$$

On définit alors $p\text{-valeur} = 1 - F(D)$ et du coup, plus cette p -valeur est petite et plus l'hypothèse H_1 est la bonne.

$$p\text{-valeur} \sim 0 \quad H_1 \text{ est } \star \star \star$$

$p\text{-valeur} \sim 0.01$	H_1 est $\star\star$
$p\text{-valeur} \sim 0.05$	H_1 est $\star$
$p\text{-valeur} \sim 0.1$	H_1 est bof-bof

6.7 Avec une statistique signée

C'est une très légère variante du test avec une statistique positive. On écrit quand même les détails, car le diable s'y cache.

On est en présence de deux hypothèses H_0 et son contraire H_1 . On construit une "statistique" $T = T(X_0, X_1, \dots) \in \mathbb{R}$ pour qu'en loi :

- $\star$ sous H_0 , $|T|$ est petit.
- $\star$ sous H_1 , $|T|$ est grand

Une fois que l'on dispose d'une réalisation de notre échantillon, on calcule T et :

- $\star |T| \leq \text{seuil} \Rightarrow \{H_0 \text{ choisie}\}$
- $\star |T| > \text{seuil} \Rightarrow \{H_1 \text{ choisie}\}$

Jusqu'à présent, tout se passe comme si on s'intéressait à la statistique positive $D = |T|$. La différence va être dans la détermination du seuil, qui va reposer sur la fonction de répartition de T , et non de $|T|$.

On suppose que T est symétrique.

En fait, quand on construit T , on doit faire en sorte que :

- $\star$ sous H_0 , T suive une loi de fonction de répartition F connue (ex : gaussienne ou student).
- $\star$ sous H_1 , T soit très grande en valeur absolue.

On souhaite que, sous H_0 , la probabilité de choisir H_1 soit de α . Ainsi : Sous H_0 :

$$\begin{aligned} \mathbf{P}[|T| > \text{seuil}] = \alpha &\Leftrightarrow \mathbf{P}[|T| \leq \text{seuil}] = 1 - \alpha \\ &\Leftrightarrow \mathbf{P}[-\text{seuil} \leq T \leq \text{seuil}] = 1 - \alpha \\ &\Leftrightarrow \text{seuil} = F^{-1}\left(1 - \frac{\alpha}{2}\right) \end{aligned}$$

Donc en résumé

- $\star |T| \leq F^{-1}\left(1 - \frac{\alpha}{2}\right) \Rightarrow \{H_0 \text{ choisie}\}$
- $\star |T| > F^{-1}\left(1 - \frac{\alpha}{2}\right) \Rightarrow \{H_1 \text{ choisie}\}$

On aimerait avoir un critère quantitatif pour dire si on choisit H_1 franchement, ou du bout des lèvres.

On a :

$$\begin{aligned} \{\text{choisir } H_1\} &\Leftrightarrow |T| > F^{-1}\left(1 - \frac{\alpha}{2}\right) \\ &\Leftrightarrow F(|T|) > \left(1 - \frac{\alpha}{2}\right) \\ &\Leftrightarrow 1 - F(|T|) \leq \frac{\alpha}{2} \\ &\Leftrightarrow 2[1 - F(|T|)] \leq \alpha \end{aligned}$$

On définit alors $p\text{-valeur} = 2[1 - F(|T|)]$ et du coup, plus cette $p\text{-valeur}$ est petite et plus l'hypothèse H_1 est la bonne.

7 Tests du χ^2 et test de Kolmogorov-Smirnov

7.1 Test d'adéquation du χ^2

Définition 7.1.1 : Cadre.

Soit $X_1, \dots, X_n$ un échantillon i.i.d. à valeurs dans un ensemble fini $1, \dots, k$. On souhaite tester :

$$H_0 : \mathbb{P}(X = i) = p_i, \quad i = 1, \dots, k,$$

où $(p_1, \dots, p_k)$ est une loi de probabilité connue.

Définition 7.1.2 : Effectifs observés et théoriques.

On note :

- ★ N_i : nombre d'observations dans la catégorie i ,
- ★ $E_i = np_i$: effectif théorique sous H_0 .

Définition 7.1.3 : Statistique du χ^2 .

La statistique de test est :

$$\chi^2 = \sum_{i=1}^k \frac{(N_i - E_i)^2}{E_i}.$$

Théorème 7.1.4 :

Sous H_0 , si n est grand et si $E_i \geq 5$ pour tout i , alors :

$$\chi^2 \xrightarrow{\mathcal{L}} \chi_{k-1}^2.$$

Proposition 7.1.5 : Règle de décision.

On rejette H_0 au niveau α si :

$$\chi^2 > q_{1-\alpha},$$

où $q_{1-\alpha}$ est le quantile d'ordre $1 - \alpha$ de la loi χ_{k-1}^2 .

Remarque 7.1.6 :

Si des paramètres sont estimés à partir des données, le nombre de degrés de liberté devient :

$$k - 1 - p,$$

où p est le nombre de paramètres estimés.

7.2 Test d'indépendance du χ^2

Définition 7.2.1 : Cadre.

Soient X et Y deux variables aléatoires discrètes prenant respectivement k et l modalités. On observe un échantillon $(X_1, Y_1), \dots, (X_n, Y_n)$.

Définition 7.2.2 : Hypothèses.

$$H_0 : X \text{ et } Y \text{ sont indépendantes}$$

$$H_1 : X \text{ et } Y \text{ ne sont pas indépendantes}$$

Définition 7.2.3 : Table de contingence.

On note :

- ★ N_{ij} : effectif observé dans la case (i, j) ,
- ★ $N_{i\cdot}$ et $N_{\cdot j}$: totaux marginaux.

Définition 7.2.4 : Effectifs théoriques.

Sous H_0 , les effectifs attendus sont :

$$E_{ij} = \frac{N_{i.} N_{.j}}{n}.$$

Définition 7.2.5 : Statistique du χ^2 .

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{(N_{ij} - E_{ij})^2}{E_{ij}}.$$

Théorème 7.2.6 :

Sous H_0 et pour n grand :

$$\chi^2 \xrightarrow{\mathcal{L}} \chi_{(k-1)(l-1)}^2.$$

Proposition 7.2.7 : Règle de décision.

On rejette H_0 au niveau α si :

$$\chi^2 > q_{1-\alpha},$$

où $q_{1-\alpha}$ est le quantile de la loi $\chi_{(k-1)(l-1)}^2$.

Remarque 7.2.8 :

Comme pour le test d'adéquation, il est nécessaire que les effectifs théoriques soient suffisamment grands (typiquement $E_{ij} \geq 5$).

7.3 Test de Kolmogorov-Smirnov

Définition 7.3.1 : Fonction de répartition empirique.

La fonction de répartition empirique est définie par :

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{X_i \leq x}.$$

Théorème 7.3.2 : Glivenko-Cantelli.

On a la convergence uniforme presque sûre :

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \xrightarrow{a.s.} 0.$$

Remarque 7.3.3 :

Ce résultat justifie le test de Kolmogorov-Smirnov : il garantit que sous H_0 , F_n est proche de F_0 lorsque n est grand.

Définition 7.3.4 : Cadre du test.

On souhaite tester :

$$H_0 : F = F_0$$

où F_0 est une fonction de répartition continue connue.

Définition 7.3.5 : Statistique de Kolmogorov-Smirnov.

$$D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F_0(x)|.$$

Définition 7.3.6 : La loi de Kolmogorov-Smirov.

La loi de Kolmogorov-Smirov, c'est la loi dont la fonction de répartition est donnée par

$$F_{KS}(u) = 1 + 2 \sum_{k>0} (-1)^k \exp(-2k^2 u^2)$$

Théorème 7.3.7 :

Sous H_0 et si F_0 est continue :

$$\sqrt{n}D_n \xrightarrow{\mathcal{L}} KS$$

où KS suit une loi de Kolmogorov-Smirov.

Proposition 7.3.8 : Règle de décision.

On rejette H_0 si :

$$D_n > \frac{c_\alpha}{\sqrt{n}},$$

où c_α est une constante dépendant du niveau α .

7.4 Interprétation

- ★ Le test du χ^2 compare des **effectifs**.
- ★ Le test de Kolmogorov-Smirnov compare des **fonctions de répartition**.
- ★ Le test de Kolmogorov-Smirnov est non paramétrique et plus sensible aux écarts globaux.
- ★ Le χ^2 dépend du découpage en classes, contrairement à Kolmogorov-Smirnov.

8 Processus de Poisson

8.1 Retour sur la loi exponentielle

Proposition 8.1.1 : Absence de mémoire.

Soit T une variable aléatoire positive à densité. Alors T est la loi exponentielle si et seulement si

$$\forall s, t \in \mathbb{R}_+, \quad \mathbb{P}(T > t + s \mid T > s) = \mathbb{P}(T > t).$$

Proposition 8.1.2 :

Soit T, S deux variables aléatoires de loi exponentielle, $T \sim \mathcal{E}(\lambda)$, $S \sim \mathcal{E}(\mu)$. On a $\forall t \in \mathbb{R}_+$

$$\mathbb{P}(T > t + S \mid T > S) = \mathbb{P}(T > t).$$

Proposition 8.1.3 :

La somme de n variables aléatoires indépendantes de même loi $\mathcal{E}(\lambda)$ est une variable aléatoire de loi $\Gamma(n, \lambda)$.

Proposition 8.1.4 :

Soit $(T_n)_{n \geq 1}$ une suite de variables aléatoires indépendantes de lois $\mathcal{E}(\lambda_n)$. On note

$$T = \sum_{n \geq 1} T_n.$$

On a :

$$1) \text{ Si } \sum_{n \geq 1} \frac{1}{\lambda_n} < +\infty,$$

$$\mathbb{P}(T < +\infty) = 1 \quad (T \text{ fini p.s.})$$

2) Si $\sum_{n \geq 1} \frac{1}{\lambda_n} = +\infty$,

$$\mathbb{P}(T < +\infty) = 0$$

Proposition 8.1.5 :

Soit $(T_n)_{n \geq 1}$ une suite de variables aléatoires indépendantes de loi $\mathcal{E}(\lambda_n)$. On suppose que

$$\sum_{n \geq 1} \lambda_n = \lambda < +\infty.$$

On note

$$T = \inf_{k \geq 1} T_k$$

Alors avec probabilité 1 cet infimum est atteint pour un unique indice K (aléatoire), et on a :

$$\mathbb{P}(K = k) = \frac{\lambda_k}{\lambda} \quad \text{et } K \text{ et } T \text{ sont indépendants}$$

De plus

$$T \sim \mathcal{E}(\lambda).$$

8.2 Statistique d'ordre

On considère un échantillon de n variables i.i.d.. La loi admet une densité f ; on note F la fonction de répartition (F continue) : $(x_1, \dots, x_n)$

On a

$$\mathbb{P}(\exists i \neq j, X_i = X_j) = 0$$

On les ordonne :

$$X_{\sigma(1)} < X_{\sigma(2)} < \dots < X_{\sigma(n)}$$

où σ est une permutation aléatoire.

Notation : $X_{\sigma(i)} := X_{i,n}$

Proposition 8.2.1 :

On a σ est de loi uniforme sur l'ensemble des permutations. De plus, $(X_{(1,n)}, \dots, X_{(n,n)})$ admet pour densité la fonction :

$$(x_1, \dots, x_n) \mapsto n! \mathbf{1}_{\{x_1 < x_2 < \dots < x_n\}} f(x_1) \dots f(x_n)$$

et de plus elles sont indépendantes.

Proposition 8.2.2 :

Soient $x \in \mathbb{R}$ et $1 \leq k \leq n$. On a :

$$\mathbb{P}(X_{(k,n)} \leq x) = \sum_{r=k}^n \binom{n}{r} F(x)^r [1 - F(x)]^{n-r}$$

et

$$\mathbb{P}(X_{(k,n)} \leq x) = \frac{n!}{(k-1)!(n-k)!} \int_0^{F(x)} t^{k-1} (1-t)^{n-k} dt$$

8.3 Processus de Poisson

Définition 8.3.1 :

Soit $(J_n)_{n \geq 1}$ une suite de variables aléatoires positives. On définit $T_n = J_1 + \dots + J_n \quad \forall n \geq 1$.

$$N_t = \sum_{n \geq 1} 1_{\{T_n \leq t\}}$$

N_t est appelé **processus de comptage**.

Définition 8.3.2 :

Un processus de comptage associé à une suite de v.a. i.i.d. $(J_n)_{n \geq 1}$ de loi $\mathcal{E}(\lambda)$ est appelé **processus de Poisson d'intensité λ**

Proposition 8.3.3 :

Avec les mêmes notations, pour (N_t) processus de Poisson d'intensité λ :

- ★ T_n est de loi $\Gamma(\lambda, n)$
- ★ La loi jointe de $(T_1, \dots, T_n)$ admet pour densité :

$$f(t_1, \dots, t_n) = 1_{\{0 \leq t_1 < \dots < t_n\}} \lambda^n e^{-\lambda t_n}$$

Proposition 8.3.4 :

Soit $(N_t)_{t \in \mathbb{R}^+}$ processus de Poisson d'intensité λ :

- ★ la loi de N_t est une loi de Poisson $\mathcal{P}(\lambda t)$
- ★ la loi de $(T_1, \dots, T_n)$ sachant que $N_t = n$ est la loi de n variables aléatoires i.i.d. de loi uniforme sur $[0, t]$ réordonnées

Définition 8.3.5 :

Un processus de comptage est dit à **accroissements stationnaires** si pour tout t, s, h avec $0 \leq s \leq t$ et $h > 0$:

$$N_{t+h} - N_{s+h} \quad \text{et} \quad N_t - N_s \quad \text{ont même loi}$$

Définition 8.3.6 :

Un processus de comptage est dit à **accroissements indépendants** si pour tous $0 \leq s_1 < t_1 < s_2 < t_2 < \dots < s_n < t_n$, les accroissements

$$N_{t_1} - N_{s_1}, \dots, N_{t_n} - N_{s_n} \quad \text{sont des v.a. indépendantes}$$

Proposition 8.3.7 :

Un processus de Poisson est à **accroissements indépendants et stationnaires**. [cite : 1]

Théorème 8.3.8 :

Soit $(N_t)_{t \in \mathbb{R}^+}$ un processus de comptage à accroissements indépendants et stationnaires tel que $N_0 = 0$ et N_t de loi $\mathcal{P}(\lambda t)$.

Alors (N_t) est un processus de Poisson d'intensité λ .

Proposition 8.3.9 : Superposition.

Soient $(N_t), (M_t)$ deux processus de Poisson, d'intensité λ et μ , indépendants. Alors $(P_t = N_t + M_t)$ est un processus de Poisson d'intensité $\lambda + \mu$.

Proposition 8.3.10 : Amincissement.

(N_t) un processus de Poisson d'intensité λ

Soit $(B_n)_{n \in \mathbb{N}^*}$ une suite de v.a. i.i.d. $\mathcal{B}(p)$ indépendante de (N_t)

On définit

$$N_t^{(1)} = \sum_{n \geq 1} B_n 1_{\{T_n \leq t\}} \quad \text{et} \quad N_t^{(2)} = \sum_{n \geq 1} (1 - B_n) 1_{\{T_n \leq t\}}$$

Alors $(N_t^{(1)})$ et $(N_t^{(2)})$ sont des processus de Poisson indépendants d'intensité λp et $\lambda(1-p)$.

9 Chaîne de Markov

9.1 Définitions et premières propriétés

9.1.1 Définition d'une Chaîne de Markov

Soit E un ensemble au plus dénombrable, appelé espace d'états.

Définition 9.1.1 :

Une suite de variables aléatoires $(X_n)_{n \in \mathbb{N}}$ à valeurs dans E est une Chaîne de Markov si pour tout $n \in \mathbb{N}$ et tout $(x_0, \dots, x_{n+1}) \in E^{n+2}$ tels que $\mathbb{P}(X_0 = x_0, \dots, X_n = x_n) > 0$:

$$\mathbb{P}(X_{n+1} = x_{n+1} | X_0 = x_0, \dots, X_n = x_n) = \mathbb{P}(X_{n+1} = x_{n+1} | X_n = x_n)$$

Interprétation : Le futur (X_{n+1}) ne dépend du passé $(X_0, \dots, X_{n-1})$ qu'à travers le présent (X_n) .

9.1.2 Homogénéité et Matrice de transition

Définition 9.1.2 : Homogénéité.

Une chaîne est dite homogène si la probabilité de transition ne dépend pas du temps n :

$$\mathbb{P}(X_{n+1} = y | X_n = x) = P(x, y)$$

pour tout n .

Définition 9.1.3 : Matrice de transition.

On appelle matrice de transition la matrice

$$P = (P(x, y))_{x, y \in E}$$

où chaque ligne est une loi de probabilité sur E :

$$\forall x, y \in E, P(x, y) \geq 0, \quad \forall x \in E, \sum_{y \in E} P(x, y) = 1.$$

9.1.3 Loi d'une Chaîne de Markov

La loi d'une chaîne de Markov est entièrement déterminée par :

- ★ Sa loi initiale μ définie par $\mu(x) = \mathbb{P}(X_0 = x)$ pour tout $x \in E$.
- ★ Sa matrice de transition P .

On note alors que la suite est une $CM(\mu, P)$.

9.2 Chaîne de Markov canonique et lois marginales

9.2.1 Chaîne de Markov canonique

Définition 9.2.1 :

Soit P une matrice de transition sur E . On appelle chaîne de Markov canonique la donnée de $(\Omega, \mathcal{A}, (\mathcal{F}_n)_n, (X_n)_n, (\mathbb{P}_x)_{x \in E})$ où :

- ★ $(\Omega, \mathcal{A})$ est un espace mesurable. $(\mathcal{F}_n)_n$ est une filtration sur $\mathcal{A}$.
- ★ Pour tout $x \in E$, $\mathbb{P}_x$ est une mesure de probabilité sur $(\Omega, \mathcal{A})$ telle que $\mathbb{P}_x(X_0 = x) = 1$.

★ Pour tout $n \in \mathbb{N}$ et $x, x_0, \dots, x_n \in E$:

$$\mathbb{P}_x(X_0 = x_0, \dots, X_n = x_n) = \delta_x(x_0)P(x_0, x_1) \dots P(x_{n-1}, x_n).$$

Loi initiale quelconque : Si μ est une mesure de probabilité sur E , on définit

$$\mathbb{P}_\mu(A) = \sum_{x \in E} \mu(x) \mathbb{P}_x(A)$$

pour tout $A \in \mathcal{A}$. Sous $\mathbb{P}_\mu$, (X_n) est une CM(μ, P).

9.2.2 Relation de Chapman-Kolmogorov

Définition 9.2.2 :

Si P et Q sont deux matrices de transition, leur produit

$$PQ(x, y) = \sum_{z \in E} P(x, z)Q(z, y)$$

est aussi une matrice de transition. On définit par récurrence

$$P^n = P^{n-1}P$$

avec $P^0 = I$ (matrice identité).

Théorème 9.2.3 : de Chapman-Kolmogorov.

Soit (X_n) une CM canonique de matrice P . Alors pour tout $n \in \mathbb{N}$: $\mathbb{P}_x(X_n = y) = P^n(x, y)$. Pour une loi initiale μ , $\mathbb{P}_\mu(X_n = y) = (\mu P^n)(y) = \sum_{x \in E} \mu(x) P^n(x, y)$.

9.2.3 Mesure invariante et réversibilité

Définition 9.2.4 : Mesure invariante.

Une mesure π sur E est dite invariante pour P si

$$\pi P = \pi.$$

Si $\sum_{x \in E} \pi(x) = 1$, c'est une probabilité invariante.

Proposition 9.2.5 :

Si E est fini, il existe toujours au moins une probabilité invariante.

Définition 9.2.6 : Mesure réversible.

Une mesure π est dite réversible pour P si pour tout $x, y \in E$:

$$\pi(x)P(x, y) = \pi(y)P(y, x).$$

Proposition 9.2.7 :

Toute mesure réversible est invariante.

9.3 Propriétés de Markov

9.3.1 Propriété de Markov faible

Théorème 9.3.1 :

Soit (X_n) une CM(μ, P). Conditionnellement à $\{X_k = x\}$, le processus translaté $(X_{k+n})_{n \geq 0}$ est une CM de loi initiale δ_x et de matrice P , indépendante de $(X_0, \dots, X_k)$.

9.3.2 Propriété de Markov forte

Théorème 9.3.2 :

Soit T un $(\mathcal{F}_n)$ -temps d'arrêt. Conditionnellement à $\{T < +\infty, X_T = x\}$, le processus $(X_{T+n})_{n \geq 0}$ est une CM de loi initiale δ_x et de matrice P , indépendante de la tribu du passé $\mathcal{F}_T$.

9.4 Classification des états et récurrence

9.4.1 Structure de classe

Définition 9.4.1 : Communication.

x conduit à y ($x \rightarrow y$) s'il existe $n \geq 0$ tel que $P^n(x, y) > 0$.

Définition 9.4.2 : Intercommunication.

$x \leftrightarrow y$ si $x \rightarrow y$ et $y \rightarrow x$. C'est une relation d'équivalence.

Définition 9.4.3 : Irréductibilité.

Une chaîne est irréductible si elle ne possède qu'une seule classe de communication.

Définition 9.4.4 : Classe fermé.

Une classe C est fermée si $\forall x \in C, \mathbb{P}_x(X_1 \in C) = 1$.

9.4.2 Récurrence et Transience

Soit

$$T_x^+ = \inf\{n \geq 1, X_n = x\}$$

le premier temps de retour et

$$N(x) = \sum_{n=0}^{\infty} 1_{\{X_n=x\}}$$

le nombre total de passages. On note

$$p_x = \mathbb{P}_x(T_x^+ < +\infty)$$

Définition 9.4.5 : État Récurrent.

Un état x est dit récurrent si $p_x = 1$. Alors

$$\mathbb{P}_x(N(x) = +\infty) = 1 \quad \text{et} \quad \mathbb{E}_x[N(x)] = \sum_{n=0}^{\infty} P^n(x, x) = +\infty.$$

Définition 9.4.6 : État Transient.

Un état x est dit transient si $p_x < 1$.

Proposition 9.4.7 :

Si x est un état transient alors $N(x)$ suit une loi géométrique sous $\mathbb{P}_x$ et $\mathbb{E}_x[N(x)] < +\infty$.

Proposition 9.4.8 : Propriété de classe.

Dans une même classe, tous les états sont de même nature (soit tous récurrents, soit tous transients).

Théorème 9.4.9 :

Toute classe récurrente est fermée.

Théorème 9.4.10 :

Toute classe fermée finie est récurrente.

9.4.3 Retour sur les mesures invariantes

Théorème 9.4.11 :

Soit $(X_n)_n$ une CM de matrice de transition P irréductible récurrente, alors $(X_n)_n$ possède une unique mesure invariante π à une constante multiplicative près. Il y a 2 cas possibles :

i) $\pi(E) < +\infty$ et alors

$$\forall x \in E, \quad \mathbb{E}_x(T_x^+) < +\infty \quad \text{et} \quad \pi(x) = \frac{1}{\mathbb{E}_x(T_x^+)}$$

permet de définir l'unique probabilité invariante. On dit que la chaîne est **récurrente positive**.

ii) $\pi(E) = +\infty$ et alors

$$\forall x \in E, \mathbb{E}_x(T_x^+) = +\infty$$

On dit que la chaîne est **récurrente nulle**.

9.5 Comportement asymptotique

9.5.1 Théorèmes ergodiques

Théorème 9.5.1 : (Nombre de visites).

Soit (X_n) une CM irréductible récurrente positive de probabilité invariante π . Alors pour tout état x :

$$\frac{N_n(x)}{n} \xrightarrow{n \rightarrow +\infty} \pi(x) = \frac{1}{\mathbb{E}_x[T_x^+]} \quad \mathbb{P}_\mu\text{-p.s.}$$

Théorème 9.5.2 : Ergodique généralisé.

Pour toute fonction f telle que $\sum |f(x)|\pi(x) < +\infty$:

$$\frac{1}{n} \sum_{k=1}^n f(X_k) \xrightarrow{n \rightarrow +\infty} \sum_{x \in E} f(x)\pi(x) \quad \mathbb{P}_\mu\text{-p.s.}$$

9.5.2 Convergence en loi

Définition 9.5.3 : Période.

La période d'un état x est

$$d(x) = \text{pgcd}\{n \geq 1, P^n(x, x) > 0\}.$$

Si $d(x) = 1$, l'état est apériodique.

Théorème 9.5.4 : de convergence.

Si la chaîne est irréductible, récurrente positive et apériodique, alors pour toute loi initiale μ : pour tout $x \in E$

$$\lim_{n \rightarrow +\infty} \mathbb{P}_\mu(X_n = x) = \pi(x)$$